3D 소나의 3차원 특징벡터 기반 수중 다이버 탐지 알고리즘

이지원 · 박유진 · 신재정
서울대학교 조선해양공학과 능동인식 및 로봇지능 연구실

A 3D Feature Vector-based Underwater Diver Detection Algorithm using 3D SONAR

Jiwon Lee, Eugene Park, Jaejeong Shin
Active Perception and Robot Intelligence Lab, Seoul National University

Key Words : AUV 무인잠수정, 3D object detection 3차원 객체 탐지, 3D SONAR 3차원 소나

Abstract : There still exist complicated underwater operations that require divers, who are exposed to unpredictable hazards and heavy physical and mental workloads. To improve diver safety and operational efficiency, autonomous underwater robots should recognize divers to assist their jobs. As a first step, this study addresses diver detection, defined as estimating the diver's position and full 3D orientation. A 3D SONAR (Sound Navigation And Ranging) is chosen as a sensing modality in this study because it provides 3D information without projection and is robust to light attenuation and turbidity. Existing 3D SONAR-based methods compress point clouds into 2D bird's-eye-view features, losing elevation information. We therefore adopt a sparse 3D backbone that preserves the 3D structure of features and design a detection head that predicts the full 3D orientation of the diver, together with Gaussian heatmap-based presence prediction and a corner auxiliary loss. On the publicly available Diver3D dataset, the proposed method achieves an AP@0.35 of 0.745 and an SDS of 0.678, outperforming the existing 3D SONAR-based diver detection method by 23.0 percentage points and 0.104, respectively.

1. 개요

수중 작업은 해양 구조물 점검, 해양 플랜트 건설, 수색 및 구조 등 다양한 분야에서 이루어지며, 그 대부분은 여전히 다이버가 수행하고 있다. 이러한 작업은 시야 제한, 조류, 감압 등 예측하기 어려운 위험 요소가 많고, 다이버에게 큰 정신적·육체적 부담을 준다. 따라서 다이버의 안전과 작업 효율을 높이기 위해서는 다이버의 상태를 인식하고 작업을 보조할 수 있는 수중 자율로봇 기술이 필요하나, 이 기술은 아직 충분히 연구되지 않았다 [1]. 이에 본 연구에서는 그 첫 단계로서, 로봇이 주변 다이버의 위치와 3차원 자세를 추정하는 다이버 탐지 방법을 다룬다.

수중 환경에서는 빛이 흡수와 산란으로 인해 크게 감쇠되므로, 주변 환경을 인식하기 위해 음파를 이용하는 소나가 주로 사용된다. 최근 Water Linked 사의 Sonar 3D-15와 같이 비교적 저렴한 3D 소나가 개발되면서, 탁도가 높거나 빛이 없어 시야가 제한된 환경에서도 3차원 점군을 이용해 물체를 탐지하는 연구가 주목받고 있다 [2], [3]. 그러나 기존의 3D 소나 기반 객체 탐지 연구는 3차원 점군을 2차원 BEV(Bird's Eye View) 특징 맵으로 압축하여 처리하기 때문에 높이 방향의 정보가 손실되며, 이로 인해 다이버를 안정적으로 탐지하는 데 한계가 있다. 이에 본 연구에서는 FCAF3D [4]와 같은 실내 3차원 객체 탐지 방식을 참고하여 특징의 3차원 구조를 유지하는 희소(sparse) 3차원 백본을 구성하고, 이 3차원 특징에 맞는 탐지 헤드를 설계하여 3D 소나 기반 다이버 탐지 알고리즘의 성능을 향상시키고자 한다.

* 이지원 : 서울대학교 조선해양공학과
010-4157-3634, *smilejion@snu.ac.kr*
* 박유진 : 서울대학교 조선해양공학과
010-8238-1315, peg0525*@snu.ac.kr*
* 신재정 : 서울대학교 조선해양공학과
010-9935-9494, janeshin*@snu.ac.kr*

2. 3차원 객체 탐지 관련 연구

3D 소나가 상용화되기 이전, 소나 기반 수중 객체 탐지 연구는 주로 2차원 영상을 생성하는 FLS(Forward-Looking Sonar)를 이용하여 이루어졌으며, 합성곱 신경망(CNN) 기반의 다양한 탐지 방법이 제안되었다 [5]. 그러나 FLS는 거리와 방위각으로 이루어진 2차원 영상만을 제공하며, 고도각 방향의 정보는 하나의 픽셀로 투영되어 사라진다. 최근에는 고도각 정보까지 획득할 수 있는 3D 소나가 상용화되면서, 3차원 점군을 이용한 객체 탐지 연구가 이루어지고 있다. SonarPoint [2]는 3D 소나를 이용하여 여러 종류의 수중 객체를 탐지하였으며, SonarVoxNet [3]은 3D 소나 기반 다이버 탐지에 초점을 맞추었다. 그러나 두 연구 모두 3차원 점군을 2차원 BEV 특징 맵으로 압축하여 처리하므로, 센서가 제공하는 높이 방향의 정보를 충분히 활용하지 못한다.

이러한 한계를 해결하기 위해 본 연구에서는 3D 소나의 점군이 3D LiDAR의 점군과 동일한 형식을 가진다는 점에서, LiDAR 기반 3차원 객체 탐지 방법을 검토하였다. 지상 자율주행을 위한 LiDAR 기반 객체 탐지 연구 [6] - [9]는 차량과 보행자가 대부분 지면 위에 위치하여 높이 방향의 정보가 탐지에 미치는 영향이 적으므로, 앞서 언급한 3D 소나 기반 연구와 같이 3차원 특징을 BEV 특징 맵으로 압축하여 처리한다. 반면 실내 3차원 객체 탐지 연구는 다양한 높이에 놓인 물체를 구분해야 하므로 특징을 3차원 구조로 유지한다. GSDN [10]은 희소 3차원 합성곱을 이용하여 3차원 특징을 유지한 채 객체를 탐지하였으며, FCAF3D [4]는 이를 사전에 정의된 상자(anchor) 없이 각 위치에서 객체의 중심과 크기를 직접 예측하는 anchor-free 방식으로 확장하여, 다양한 크기와 형태의 객체를 탐지하였다. 수중의 다이버는 지면에 고정되지 않고 3차원

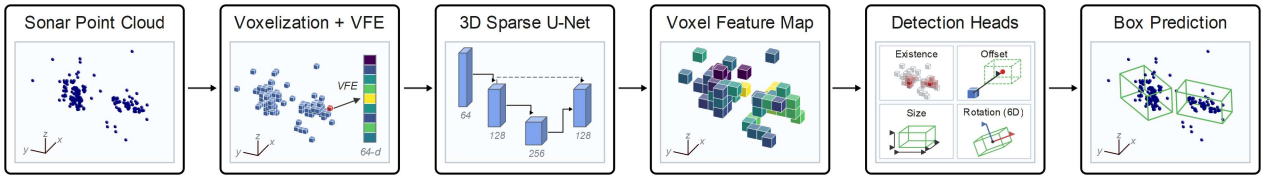


Figure 1. Overall architecture of the proposed diver detection algorithm

공간에서 다양한 자세로 움직이므로, 실내 객체 탐지와 같이 높이 방향의 정보가 탐지에 중요하다. 본 연구에서는 특징의 3차원 구조를 유지하는 백본 구조를 기반으로 다이버 탐지 알고리즘을 구성한다.

3. 수중 다이버 탐지 알고리즘

제안하는 알고리즘의 구조는 Fig. 1과 같으며, 복셀화, 희소 3차원 백본, 탐지 헤드로 구성된다.

3.1. 복셀화

3D 소나로부터 획득된 점군 $P=\{\boldsymbol{p}_i\}_{i=1,\dots,N}$ 의 각 점 $p_i=[x_i, y_i, z_i, r_i]^T$는 3차원 위치와 반사 세기로 구성된다. 탐지 범위는 전방 X ∈ [0, 12] m, 좌우 Y ∈ [-5, 5] m, 상하 Z ∈ [-2.5, 2.5] m로 설정하고, 이 공간을 한 변이 0.2 m인 정육면체 복셀로 나누어 60×50×25 격자를 구성한다. 점의 위치만으로는 복셀 내부의 국소 형상을 표현하기 어려우므로, 점이 존재하는 M개의 복셀 중 m번째 복셀에 속한 점 p_i에 복셀의 통계 정보를 더해 다음과 같은 특징 f_i를 구성한다.

$$f_i=[\boldsymbol{p}_i^T, [\boldsymbol{x}_i-\boldsymbol{\mu}_m]^T, [\boldsymbol{x}_i-\boldsymbol{c}_m]^T, \boldsymbol{\sigma}_m^T, \log n_m]^T \quad (1)$$

여기서 $\boldsymbol{x}_i$는 점의 위치이고, $\boldsymbol{\mu}_m$, $\boldsymbol{c}_m$, $\boldsymbol{\sigma}_m$, n_m은 각각 복셀 내부 점들의 평균 위치, 복셀 중심, 축별 표준편차, 점의 개수이다. 이 특징은 VFE(Voxel Feature Encoding) [9]에 입력된다. VFE는 모든 점에 같은 연산을 적용한 뒤 최대값 풀링으로 통합하므로, 점의 개수와 순서에 관계없이 각 복셀을 64차원 특징 벡터로 변환한다.

3.2. 특징 맵 추출 백본

3차원 점군은 대부분의 복셀이 비어 있으므로, 점이 존재하는 복셀에서만 연산하는 희소 3차원 합성곱으로 백본을 구성한다. 또한 넓은 수용 영역을 확보하면서도 상자 예측에 필요한 해상도를 복원하기 위해 U-Net 구조를 사용하며, 모든 특징 맵은 높이 축을 포함한 3차원 구조를 유지한다. 인코더의 두 단계는 각각 희소 합성곱으로 해상도를 절반으로 줄이고 채널 수를 두 배로 늘린 뒤, 세 개의 submanifold 희소 합성곱 [11] 잔차 블록으로 수용 영역을 확장한다. 디코더는 역희소 합성곱으로 특징을 첫 번째 인코딩 단계에서 점이 존재하던 복셀 좌표에만 복원하여 빈 공간으로 특징이 퍼지지 않도록 한다. 복원된 특징은 첫 번째 단계의 특징과 결합되어 128채널의 3차원 특징 맵으로 출력된다.

3.3. 탐지 헤드

탐지 헤드는 각 복셀에서 다이버 존재 히트맵 값과 3차원 상자를 예측하며, 히트맵 값은 해당 복셀이 다이버의 중심 영역에 속할 가능성을 나타낸다. 3차원 상자의 중심은 다이버 중심이 점이 없는 빈 복셀에 위치할 수 있으므로 복셀 중심으로부터의 오프셋으로 예측한다. 크기는 로그 스케일로 예측하고, 회전은 roll, pitch, yaw를 연속적으로 표현할 수 있는 6D 회전 표현 [12]으로 예측하며, 이는 그람-슈미트 직교화를 통해 회전 행렬로 변환된다. 추론 시에는 히트맵 값이 임계값 이상이면서 인접 복셀들 사이에서 국소 최대인 예측만 남긴다.

3.4. 손실 함수

전체 손실 함수 L는 존재 손실 L_{cls}, 중심 위치 손실 L_{center}, 상자 크기 손실 L_{size}, 회전 손실 L_{rot}, IoU 손실 L_{IoU}, 꼭짓점 보조 손실 $L_{conrner}$의 가중합으로 구성된다.

$$L=\sum_k \lambda_k L_k,\ k\in\{cls, center, size, rot, IoU, corner\} \quad (2)$$

여기서 λ_k는 각 손실의 가중치이며, λ_{size}는 0.5, 나머지 가중치는 모두 1.0으로 설정하였다. 존재 손실은 각 복셀에서 다이버의 존재를 학습하고, 중심 위치, 크기, 회전 손실은 상자의 각 구성 요소를 학습하며, IoU 손실과 꼭짓점 보조 손실은 상자 전체가 실제 상자와 맞도록 학습한다.

존재 손실 L_{cls}의 정답은 다음과 같이 설정한다. 정답 상자의 중심을 기준으로 상자를 0.6배 축소한 영역 내부의 복셀을 양성(Pos)으로 두고, 나머지 복셀에는 다이버 중심으로부터의 거리에 따른 가우시안 값 h_j을 할당한다. 이때 양성 복셀은 전체 복셀에 비해 매우 적으므로, CenterNet [13] 방식의 focal loss로 배경 복셀의 영향을 줄여 학습한다.

$$h_j=\begin{cases}1, & \boldsymbol{c}_j\in P\\ \exp\left(-\dfrac{\|\boldsymbol{d}-\boldsymbol{c}_j\|^2}{2\sigma^2}\right), & otherwise\end{cases} \quad (3)$$

$$L_{cls}=-\frac{1}{N_{pos}}\sum_j\begin{cases}(1-\hat{p}_j)^{\alpha}\log\hat{p}_j, & h_j=1\\ (1-h_j)^{\beta}\hat{p}_j^{\alpha}\log(1-\hat{p}_j), & h_j<1\end{cases} \quad (4)$$

여기서 P와 N_{pos}는 양성 복셀의 집합과 수, d는 다이버 중심, c_j는 j번째 복셀의 중심, h_j와 $\hat{p}_j$는 j번째 복셀의 존재 정답과 예측이며, $\sigma=0.5m, \alpha=2, \beta=4$이다.

중심 위치 손실 L_{center}와 상자 크기 손실 L_{size}는 양성 복셀에 대한 L1 손실의 평균으로 계산한다. 이때 다이버 상자는 축마다 크기 차이가 있으므로, 작은 축의 오차가 충분히 반영되도록 크기는 로그 공간에서 비교한다.

$$L_{center}=\frac{1}{N_{pos}}\sum\|\hat{\boldsymbol{o}}_j-(\boldsymbol{d}-\boldsymbol{c}_j)\|_1 \quad (5)$$

$$L_{size}=\frac{1}{N_{pos}}\sum\|\hat{\boldsymbol{l}}_j-\log\boldsymbol{s}\|_1 \quad (6)$$

여기서 $\hat{\boldsymbol{o}}_j$와 $\hat{\boldsymbol{l}}_j$는 j번째 복셀에서 예측된 중심 오프셋과 로그 스케일 크기, $\boldsymbol{s}$는 실제 상자의 크기이다.

회전 손실 L_{rot}은 예측과 정답 상자 사이의 각도 차이로 계산한다. 오일러 각이나 쿼터니언과 같은 4차원 이하의 회전 표현은 불연속적이어서 기울기 기반 학습을 어렵게 한다 [12]. 따라서 예측된 6D 표현을 회전 행렬로 변환한 뒤, 정답 회전 행렬과의 각도 차이를 손실로 사용한다.

$$L_{rot}=\frac{1}{N_{pos}}\sum\arccos\left(\frac{tr\left(\hat{\boldsymbol{R}}_j^T\boldsymbol{R}\right)-1}{2}\right) \quad (7)$$

여기서 $\hat{R}_j$는 예측된 6D 표현으로부터 변환된 회전 행렬, R은 실제 회전 행렬이다.

IoU 손실 L_{IoU}는 상자 전체의 겹침 정도를 학습한다. 앞의 손실들은 중심 위치, 크기, 회전을 각각 학습하므로 겹침

정도를 직접 최적화하지 못한다. 그러나 회전된 3차원 상자의 정확한 IoU는 미분이 어렵기 때문에, 각 상자로부터 가우시안 분포를 구성하고, 두 분포 사이의 GWD(Gaussian Wasserstein Distance) [14]로 IoU를 근사한다.

$$L_{IoU} = \frac{1}{N_{pos}} \sum \left(1 - \frac{1}{\tau + W_j}\right) \tag{8}$$

여기서 W_j는 j번째 복셀의 GWD 값으로 두 분포가 유사할수록 0에 가까워지며, $\tau = 1$이다.

마지막으로 꼭짓점 보조 손실 L_{corner}은 가우시안 근사로는 반영되지 않는 상자 꼭짓점의 위치를 맞추도록 학습한다. 예측 상자와 실제 상자의 8개 꼭짓점을 각각 가우시안 히트맵으로 렌더링하고, 두 히트맵 사이의 평균 제곱 오차로 손실을 계산한다. 꼭짓점 좌표를 직접 비교하지 않고 히트맵으로 비교하므로, 꼭짓점의 대응 순서에 영향을 받지 않으며 오차가 큰 경우에도 학습이 불안정해지지 않는다.

$$H(\boldsymbol{c_j}; V) = \max_{\boldsymbol{v} \in V} \exp\left(-\frac{|\boldsymbol{c_j} - \boldsymbol{v}|^2}{2\sigma_c^2}\right) \tag{9}$$

$$L_{\text{corner}} = \frac{1}{\mathrm{N_{vox}}} \sum_{\mathrm{j}} \left(\mathrm{H}(\mathbf{c_j}; \hat{\mathrm{V}}) - \mathrm{H}(\mathbf{c_j}; \mathrm{V})\right)^2 \tag{10}$$

여기서 $\sigma_c = 0.5m$이고, $\hat{V}$와 V는 모든 양성 복셀에서 예측한 상자들의 꼭짓점 집합과 실제 상자들의 꼭짓점 집합이며, $\mathrm{N_{vox}}$는 점이 존재하는 전체 복셀의 수이다.

4. 실험 설계

제안한 알고리즘의 구조 자체의 성능을 평가하기 위해 데이터 증강 없이 기존 연구와 비교하였다. SonarVoxNet [3]은 동일한 데이터셋에서 다이버를 탐지하는 기존 3D 소나 기반 방법으로, 3차원 점군을 2차원 BEV 특징 맵으로 압축하여 처리한다. FCAF3D [4]는 특징의 3차원 구조를 유지하는 실내 3차원 객체 탐지 방법이지만, z축 방향 회전만을 갖는 상자를 예측한다. 다만 기존 방법과 제안한 알고리즘을 바로 비교하면 백본, 탐지 헤드, 손실 함수가 한꺼번에 달라져, 어떤 요소가 성능 향상에 기여했는지 알기 어렵다. 이에 제안한 알고리즘과 같은 백본을 사용하는 FCAF3D에서 z축 회전 예측 헤드만 3차원 회전을 예측하도록 교체한 모델을 기준 모델(Baseline)로 두었다. 그리고 기준 모델의 존재 예측을 CenterNet [13]의 가우시안 히트맵 기반 존재 예측(A)으로 교체하고, 꼭짓점 보조 손실(B)을 순차적으로 추가하며 각 구성 요소의 효과를 확인하였다. 또한 SonarVoxNet과 기준 모델에 A를 적용한 모델의 비교로는 3차원 특징 구조 유지의 효과를 확인한다. 마지막으로 SonarVoxNet과 제안한 알고리즘의 비교로 기존 다이버 탐지 방법 대비 전체 성능을 확인한다.

탐지 성능은 3차원 IoU 임계값 0.1, 0.35, 0.5에서의 AP(Average Precision)로 평가하였다. AP@0.1로는 다이버의 존재를 탐지하는 능력을, AP@0.35와 AP@0.5로는 상자를 얼마나 정확하게 예측하는지를 평가한다. 또한 다이버의 위치와 자세 추정 정확도를 확인하기 위해, 정답과 매칭된 예측 상자에 대해 중심 오차(ATE), 크기 오차(ASE), 3차원 회전 오차(AOE3D)를 측정하였다. 마지막으로 SonarVoxNet [3]에서 제안한 SDS(Sonar-Diver Detection Score)를 사용하여, 탐지 성능과 세 가지 오차를 하나의 통합 지표로 종합하였으며, 이때 탐지 성능은 원 논문과 동일하게 IoU 임계값 0.3, 0.35, 0.4에서의 평균 AP를 사용하였다.

실험에는 3D 소나 기반 다이버 데이터셋인 Diver3D [3]를 사용하였다. Diver3D는 학습, 검증, 시험 데이터로 나뉘어 제공되며, 각각 20,861, 8,037, 8,112 프레임으로 구성된다.

SonarVoxNet [3]은 원 논문에 보고된 결과를 사용하였으며, 나머지 모델은 다음과 같은 동일한 설정으로 학습하였다. 최적화에는 가중치 감쇠 0.01의 AdamW를 사용하였다. 학습률은 OneCycle 스케줄을 따라 전체 학습의 처음 1/10 동안 최대 학습률 0.006까지 증가한 뒤 감소한다. 학습에는 NVIDIA RTX 2070 GPU 한 장을 사용해 배치 크기 8로 20에폭 동안 수행하였다. 검증 데이터에서 AP@0.35가 가장 높은 모델을 선택하였으며, 선택한 모델의 시험 데이터 결과를 최종 성능으로 보고한다.

5. 실험 결과

Table 1은 기존 방법인 SonarVoxNet [3], FCAF3D [4]와 제안한 알고리즘(기준 모델+A+B)의 비교 실험 결과이다. 제안한 알고리즘은 모든 지표에서 가장 높은 성능을 보였으며, SonarVoxNet 대비 AP@0.35는 23.0%p, AP@0.5는 14.8%p 향상되었고, SDS는 0.678로 0.104 높았다. FCAF3D는 AP@0.35가 0.112, AP@0.5가 0.004로 매우 낮았으며, 이는 z축 회전만 예측하는 실내 객체 탐지 방법을 3차원 공간에서 다양한 자세로 움직이는 다이버 탐지에 그대로 적용하기 어려움을 의미한다.

Table 1. Comparison of the proposed algorithm with SonarVoxNet and FCAF3D on the Diver3D test set

Method	AP@0.1	AP@0.35	AP@0.5	SDS
SonarVoxNet [3]	-	0.515	0.233	0.574
FCAF3D [4]	0.212	0.112	0.004	0.350
Ours	0.858	0.745	0.381	0.678

Table 2는 기준 모델에 제안한 구성 요소를 순차적으로 추가한 결과이다. 먼저 가우시안 히트맵 기반 존재 예측(A)을 적용하자 AP@0.1이 42.0%p, AP@0.35가 31.1%p 향상되었다. 이는 다이버 중심 주변 복셀에 거리에 따른 연속적인 정답을 할당함으로써, 희소한 소나 점군에서도 다이버의 존재를 안정적으로 학습할 수 있음을 보여준다. 그리고 3차원 특징 구조 유지의 효과를 확인하기 위해, 특징 맵의 차원만 다른 SonarVoxNet과 기준 모델에 A를 적용한 모델을 비교하였다. 3차원 특징 맵을 사용한 모델은 SonarVoxNet 대비 AP@0.35가 13.7%p, AP@0.5가 8.5%p, SDS가 0.063 높아, 높이 방향의 정보를 유지하는 것이 다이버 탐지에 유리함을 확인하였다. 마지막으로 꼭짓점 보조 손실(B)을 추가하자 AP@0.35가 9.3%p, AP@0.5가 6.3%p 향상되고 중심 오차가 감소하였으며, SDS는 0.678로 가장 높았다. 이는 꼭짓점 손실이 상자의 꼭짓점 위치를 직접 맞추도록 하여 높은 IoU 임계값에서의 정확도를 높이는 데 도움을 준다고 볼 수 있다.

반면 제안한 알고리즘은 SonarVoxNet과 비교하여 중심 오차는 소폭 개선되었으나, 크기와 회전 오차는 더 크게 나타났다. 이는 오차 지표가 정답과 매칭된 예측에 대해서만 계산되기 때문으로 분석된다. 탐지 성능이 낮은 모델은 상대적으로 쉬운 경우에 대해서만 오차가 계산되는 반면, 제안한 알고리즘은 탐지가 어려운 다이버까지 탐지하므로 이들의 상자 오차가 함께 반영된다. Fig. 2는 시험 예시 데이터에 대한 각 방법의 탐지 결과를 나타낸다.

6. 결론

본 연구에서는 수중 로봇이 다이버를 인식하고 보조하기 위한 첫 단계로, 3D 소나 점군에서 다이버의 위치와 3차원 자세를 추정하는 다이버 탐지 알고리즘을 제안하였다. 기존 다이버 탐지 방법인 SonarVoxNet은 점군을 BEV 특징 맵으로 압축하여 높이 방향의 정보를 잃는 한계가 있었다. 이를 해결하기 위해 특징의 3차원 구조를 유지하는 희소 3차원 백본을 구성하였다. 또한 가우시안 히트맵 기반 존재 예측과 꼭짓점 보조 손실을 도입하여 다이버를 더 안정적이고 정확하게 탐지할 수 있도록 하였다. Diver3D 데이터셋에서 제안한

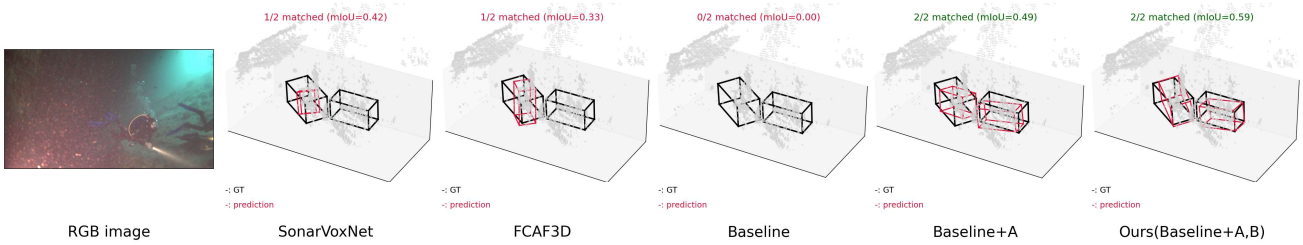


Figure 2. Qualitative detection results on the Diver3D test set (black: GT, red: prediction)

Table 2. Ablation study on the Diver3D test set. A: Gaussian heatmap-based presence prediction [13], B: corner auxilliary loss

Method	Feature	A [13]	B	AP			Average Error			SDS ↑
				0.1 ↑	0.35 ↑	0.5 ↑	ATE (m) ↓	ASE ↓	AOE3D(°) ↓	
SonarVoxNet [3]	BEV	✓		-	0.515	0.233	0.210	0.330	34.3	0.574
Baseline	3D			0.364	0.341	0.210	0.183	0.310	**29.0**	0.532
Baseline+A	3D	✓		0.784	0.652	0.318	0.199	0.334	52.1	0.637
Ours	3D	✓	✓	**0.858**	**0.745**	**0.381**	0.194	0.341	53.1	**0.678**

알고리즘은 AP@0.35 0.745, SDS 0.678로 SonarVoxNet 대비 각각 23.0%p, 0.104 향상되었다. 특히 3차원 특징 구조를 유지하는 것만으로 SonarVoxNet 대비 AP@0.35가 13.7%p 향상되었으며, 가우시안 히트맵 기반 존재 예측(A)은 탐지 성능을, 꼭짓점 보조 손실(B)은 상자 정확도를 높여 각각 성능 향상에 기여함을 확인하였다.

그러나 제안한 알고리즘은 LiDAR 점군을 위해 설계된 VFE로 복셀 특징을 추출한다. VFE는 각 복셀을 내부의 점만으로 독립적으로 인코딩하는데, 소나 데이터는 LiDAR보다 노이즈가 많고 희소하여 복셀마다 신뢰할 수 있는 점이 적다. 이 때문에 주변 복셀과의 맥락이나 소나 특유의 반사 특성을 충분히 반영하지 못한다. 또한 현재의 오차 지표는 정답과 매칭된 예측에 대해서만 계산되므로, 탐지가 어려운 다이버까지 탐지하는 모델일수록 오차가 크게 나타나는 경향이 있어 모델 간 자세 추정 정확도를 공정하게 비교하기 어렵다.

향후에는 소나의 노이즈와 반사 특성을 고려한 특징 추출 방법을 연구할 계획이다. 또한 탐지율의 영향을 배제하고 자세 추정 정확도를 평가할 수 있는 지표를 제안하고자 한다. 나아가 수중 로봇에 탑재할 수 있도록 실시간성을 검증하고, 다이버의 상태 인식과 작업 보조로 연구를 확장하고자 한다.

참 고 문 헌

[1] A. Birk, "A survey of underwater human-robot interaction (U-HRI)," Current Robotics Reports, vol. 3, no. 4, pp. 199 - 211, 2022, doi: 10.1007/s43154-022-00092-7.

[2] D. Zhao, T. Cai, P. Chen, W. Mao, Y. Hu, Y. Zhang, et al., "SonarPoint: Weak-heterogeneity awareness object detection network for 3D sonar point cloud," IEEE Trans. Circuits Syst. Video Technol., vol. 35, no. 10, pp. 9695 - 9707, 2025.

[3] E. Park, J. Lee, S. Kan, T. Dong, X. Lin, and J. Shin, "SonarVoxNet: Diver detection in 3D bounding box using 3D sonar," arXiv preprint arXiv:2610.01644, 2026.

[4] D. Rukhovich, A. Vorontsova, and A. Konushin, "FCAF3D: Fully convolutional anchor-free 3D object detection," in Proc. Eur. Conf. Comput. Vis. (ECCV), 2022, pp. 477 - 493.

[5] M. Aubard, A. Madureira, L. Teixeira, and J. Pinto, "Sonar-based deep learning in underwater robotics: Overview, robustness and challenges," IEEE J. Ocean. Eng., 2025.

[6] A. H. Lang, S. Vora, H. Caesar, L. Zhou, J. Yang, and O. Beijbom, "PointPillars: Fast encoders for object detection from point clouds," in Proc. IEEE/CVF Conf. Comput. Vis. Pattern Recognit. (CVPR), 2019, pp. 12697 - 12705.

[7] Y. Yan, Y. Mao, and B. Li, "SECOND: Sparsely embedded convolutional detection," Sensors, vol. 18, no. 10, p. 3337, 2018.

[8] T. Yin, X. Zhou, and P. Krähenbühl, "Center-based 3D object detection and tracking," in Proc. IEEE/CVF Conf. Comput. Vis. Pattern Recognit. (CVPR), 2021, pp. 11784 - 11793.

[9] Y. Zhou and O. Tuzel, "VoxelNet: End-to-end learning for point cloud based 3D object detection," in Proc. IEEE/CVF Conf. Comput. Vis. Pattern Recognit. (CVPR), 2018, pp. 4490 - 4499.

[10] J. Gwak, C. Choy, and S. Savarese, "Generative sparse detection networks for 3D single-shot object detection," in Proc. Eur. Conf. Comput. Vis. (ECCV), 2020, pp. 297 - 313.

[11] B. Graham, M. Engelcke, and L. van der Maaten, "3D semantic segmentation with submanifold sparse convolutional networks," in Proc. IEEE/CVF Conf. Comput. Vis. Pattern Recognit. (CVPR), 2018, pp. 9224 - 9232.

[12] Y. Zhou, C. Barnes, J. Lu, J. Yang, and H. Li, "On the continuity of rotation representations in neural networks," in Proc. IEEE/CVF Conf. Comput. Vis. Pattern Recognit. (CVPR), 2019, pp. 5745 - 5753.

[13] X. Zhou, D. Wang, and P. Krähenbühl, "Objects as points," arXiv preprint arXiv:1904.07850, 2019.

[14] X. Yang, J. Yan, Q. Ming, W. Wang, X. Zhang, and Q. Tian, "Rethinking rotated object detection with Gaussian Wasserstein distance loss," in Proc. Int. Conf. Mach. Learn. (ICML), 2021, pp. 11830 - 11841.