한국해양로봇기술연구회
Korea Marine Robot Technology Society

2026

한국해양로봇기술연구회

추계학술대회

학술대회 논문집

PROCEEDINGS

일시 2026년 11월 13일(금) 13:00-18:00

장소 부산항국제전시컨벤션센터(BPEX) 회의실 3·4
부산 동구 충장대로 206 부산항국제여객터미널 5층

주최·주관 한국해양로봇기술연구회

후원 (사)한국해양공학회, 대양전기공업(주),
오션테크(주), 비엠에스

BUSAN · BPEX

Underwater Robotics Solutions

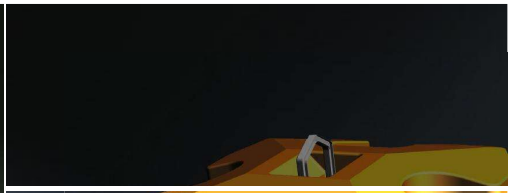

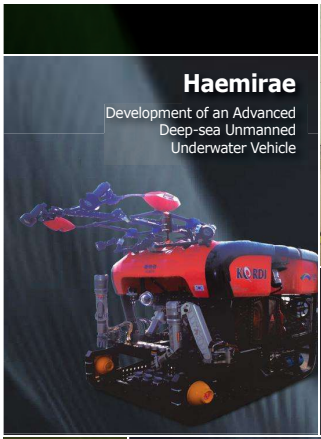

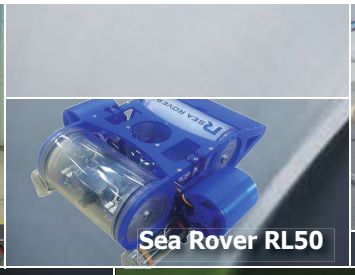

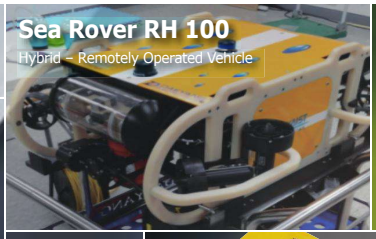

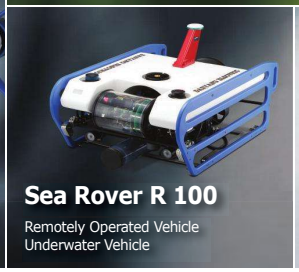

DAEYANG ELECTRIC

Daeyang is a leader in marine lightings, communication systems, power systems and nautical instruments. Based on over 49 years of experience in marine and shipbuilding industry, our superior products are acknowledged by various customers throughout the world.

Customer satisfaction is our first and only priority and we put endless effort in order to meet the highest standard. With heavy investment (about 10% of annual turnover) on research and development, our R&D center is one of the most famous research centers in the industry for its innovation and capability of product development.

We operate in various sites around Busan, Korea and have oversea liaison offices in Japan, North & South America, Europe, China, South Asia and Australia for immediate response to the customers' demands.

DAEYANG

www.daeyang.co.kr

Head Office / Marine Solution Division
245 Jangpyeong-ro, Saha-gu, Busan, Korea

Defense Solution Division
45-10 Noksansandan 261-ro 14beon-gil, Ganseo-gu, Busan, Korea

Sensor Solution Division
16 Venture-ro 100beon-gil, Yeonsu-Gu Incheon, Korea

Environment Solution Division
36, Magokjungang 14-ro, Ganseo-gu, Seoul, Korea

Tel.
Overseas +82-51-200-5282, 5285
Domestic +82-51-200-5213, 5219
Instrument +82-51-200-9720~23

OCEANTECH

PARANG 5000 (OCEANTECH USV)

- Unmanned Surface Vehicle
- Mission Control & Data Relay
- Acoustic Communication Hub

Exail R7 ROV

- Inspection & Intervention
- Sensor Deployment
- Leak Investigation

Exail GAPS (Under-Hull Mounted)

- USBL Positioning
- Acoustic Modem

Teledyne Gavia AUV

- Autonomous Survey
- Seabed Mapping
- Data Collection
- LBL-aided Navigation

Exail LBL Network System Long Baseline (LBL)

- High-Accuracy Tracking
- Asset Navigation & Survey Support

PARANG 5000 (OCEANTECH USV)
Unmanned Surface Vehicle

Teledyne Gavia AUV
Autonomous Underwater Vehicle

Exail R7 ROV
Work-Class ROV

Exail GAPS
Under-Hull Mounted

Exail LBL
Network System
Long Baseline (LBL)

OCEANTECH
Ocean Building, 57, Haengjusanseong-ro 144beon-gil, Deogyang-gu, Goyang-si, Gyeonggi-do, Republic of Korea, Zip.10440
Tel. 82 31 995 9000 | Fax.82 31 970 1459 E mail. sales@oceantech.co.kr | Homepage. www.oceantech.co.kr

SBG SYSTEMS | 해양 INS 센서

NORBIT Subsea | 수중 소나 시스템

Quanta Micro

초소형 고정밀 GNSS/INS

- 관성항법시스템(INS)
- 싱글 또는 듀얼 안테나 지원
- 방위각 정확도 0.06°
- Roll & Pitch 0.015° (RTK)
- 크기:50x37x23mm/ 무게:38g

Stellar-40

전술급 관성항법 시스템(INS)

- GNSS 차단 시 위치오차0.2%DT
- 스푸핑 실시간 탐지 및 대응
- 3중 진동 보호 설계
- Heading 0.05°(RTK)
- SAF2Nav 기반 고정밀 항법

Apogee-D

고정밀 INS/GNSS 시스템

- RTK수평 위치 정확도 (0.01m+0.5ppm)
- 듀얼 안테나 GNSS 탑재
- Roll & Pitch 0.008°
- Heading 0.02°

WBMS Basic

광대역 멀티빔 음향측심기

- 측량 범위 최대 210°
- 빔 수 256~512개
- 거리 분해능 10mm미만
- 작동 주파수 – 200~700kHz
- 최대 내압 수심6,000m (옵션)

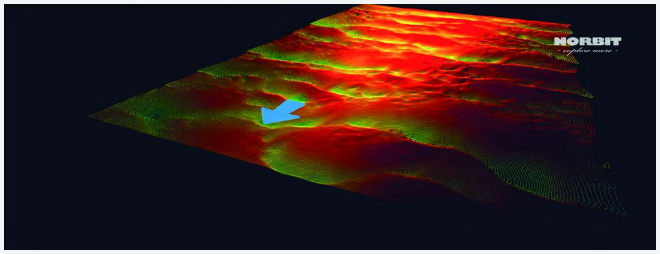

WBMS FLS

광대역 전방탐지 이미징 소나

- 수평 탐지 범위 최대 180°
- 탐지거리 최대 250m
- 거리 분해능 10mm미만
- 최대 내압 수심 6,000(옵션)
- 데이터 갱신 주기 60Hz

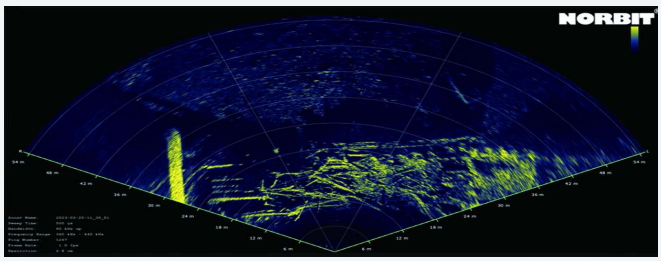

비엠에스
Blue Marine Solutions

Tel: 032-223-0770
E-mail: bmsolutions05@gmail.com
Web: https://bmsoltuions.biz
주소: 경기도 부천시 조마루로 385번길 92, 부천테크노밸리U1센터 420호

한국해양로봇기술연구회
Korea Marine Robot Technology Society

[2026년도 추계학술대회]

❍ 개 요

- **주최/주관:** 한국해양로봇기술연구회
- **일시:** 2026년 11월 13일(금), 13:00~18:00
- **장소:** 부산항국제전시컨벤션센터(BPEX) 회의실 3·4
  (부산 동구 충장대로 206 부산항국제여객터미널 5층)
- **후원:** (사)한국해양공학회, 대양전기공업(주), 오션테크(주), 비엠에스

❍ 학술대회 일정표

시간	순서	장소	비고
11:00~13:00	등록/접수	BPEX 회의실 3,4	
13:00~13:05	개회사(김진환 회장)		
13:05~13:55	[초청강연 1] “국제협력을 통한 무인함정 개발 현황 및 계획” (강연자: HD한국조선해양 김형택 소장)		좌장: 유선철 (POSTECH)
13:55~14:45	[초청강연 2] “바다에서 원자로까지, 그리고 다시 바다로” (강연자: 한국원자력연구원 주성문 박사)		좌장: 김진환 (KAIST)
14:45~15:05	기념촬영 및 휴식		학술세션 A 준비
15:05~15:45	[학술세션 A] 포스터 티저(Teaser)		좌장: 홍성훈 (계명대)
15:45~16:20	[학술세션 A] 포스터 발표		
16:20~16:30	휴식		학술세션 B 준비
16:30~17:10	[학술세션 B] 포스터 티저(Teaser)		좌장: 조성진 (한경국립대)
17:10~17:45	[학술세션 B] 포스터 발표		
17:45~18:00	행사 종료 안내 및 만찬장 이동		
18:00~	만찬	롯데캐슬 드메르 라메르	

❍ 포스터 발표 방법

- 공지된 발표 순서에 따라, 발표자별로 **5분 이내**의 구두 티저(teaser) 발표 진행
  (*티저 발표는 제한된 짧은 시간 안에 자신의 포스터에 대한 학회 참가자들의 관심을 끌고, 이후 포스터 세션에서 보다 심도 있는 토론으로 이어지도록 유도하는, 일종의 '광고' 역할을 하는 발표입니다. 연구 결과 동영상 등이 포함된 PPT 슬라이드 활용을 권장드립니다.)
- 티저 세션 종료 후, 준비된 포스터 패널 앞에서 자유롭게 소통 진행
  (*발표자는 각자 포스터를 사전에 준비해 오시기 바랍니다)
- 포스터 사이즈: 세로 방향 A0 사이즈 권장 (A0 사이즈에 맞는 포스터 부착용 패널 제공)
- 포스터 양식(디자인)은 자유롭게 구성 가능

❍ 만찬 장소: 롯데캐슬 드메르 라메르(B동 2층)

- 일정: 18:00~
- 주소: 부산 동구 충장대로 190 롯데캐슬 드메르 B동 2층 라메르
  (발표장 학술대회장 BPEX에서 도보 5분 거리)
- TEL: 051-469-8898

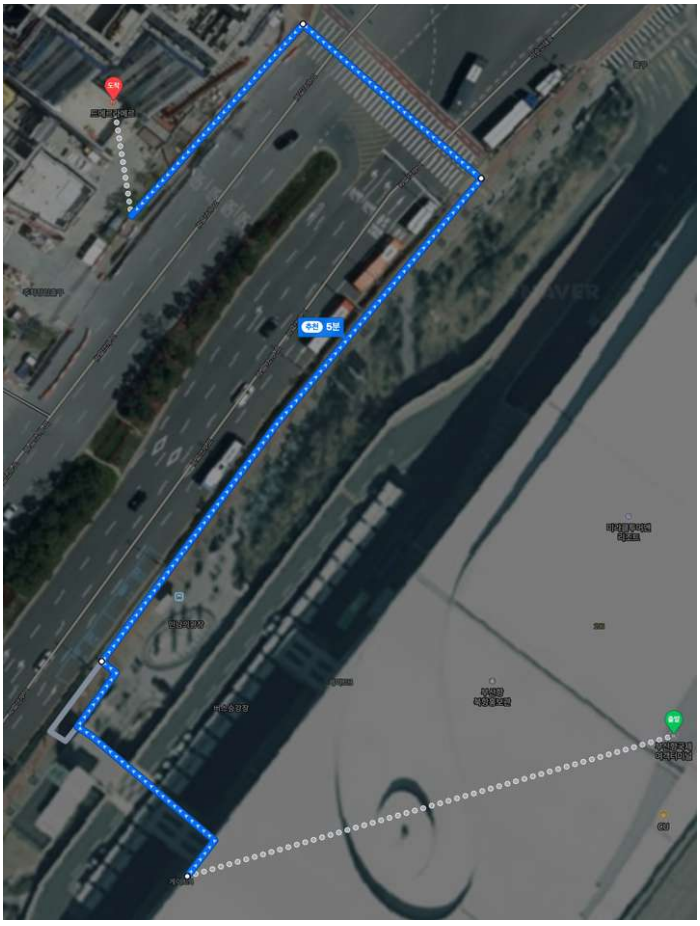

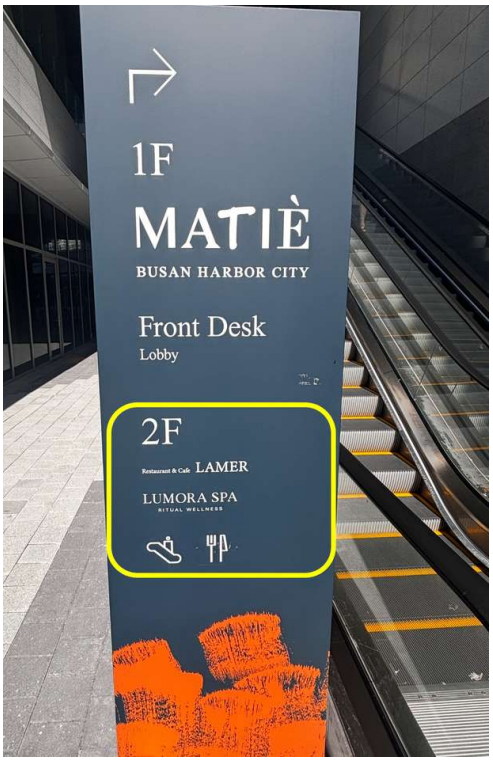

[학술세션 A] 포스터 티저: 15:05~15:45 (발표자별 5분 발표)			
No.	제목	저자	좌장
A-P1	해상 환경에서의 다중 센서 데이터 취득을 위한 ROS2 기반 통합 시스템 개발	이동제, 장혜수, 김한근, 구정모 (씨드로닉스(주))	홍성훈 (계명 대학교)
A-P2	자율운항선박 디지털 트윈 환경 구축을 위한 DINOv3 이미지 특징 기반 카메라-라이다 3D 공간정보 정합 기초 연구	조민기, 강민주, 주기범, 최진우, 김동함, 김동언, 박정홍(KRISO)	
A-P3	GPU 가속 레스터화와 음향 레이트레이싱을 기반한 가상 소나 데이터 렌더링	권희규, 심현민, 하재민, 조한길 (경북대학교)	
A-P4	가상 소나이미지를 활용한 AUV 위치추정 고도화 연구	하재민, 심현민, 조한길 (경북대학교)	
A-P5	해저면 근접 운용을 위한 제한된 화각의 3차원 멀티빔 음향측심기 기반 오도메트리 추정 기법	양동원, 홍성훈 (계명대학교), 윤석민(한화시스템(주))	
A-P6	3D 소나의 3차원 특징벡터 기반 수중 다이버 탐지 알고리즘	이지원, 박유진, 신재정 (서울대학교)	
A-P7	RL-Based Gain Optimization of Time-Delay Control for AUVs with a Pan-Tilt Sensor Pointing Mechanism	김동섭, 김승민, 유선철 (POSTECH)	
A-P8	Tilt-Aware FFT–ICP Scan Registration for Pose-Graph SLAM with a Downward-Tilted Forward-Looking Sonar	김승민, 박성민, 김민종, 유선철 (POSTECH)	

* 상기 일정은 상황에 따라 일부 조정될 수 있습니다.

[학술세션 B] 포스터 티저: 16:30~17:10 (발표자별 5분 발표)			
No.	제목	저자	좌장
B-P1	대양전기공업(주) 수중로봇 솔루션	정수남 (대양전기공업(주))	조성진 (한경 국립대)
B-P2	AUV 도킹 유도를 위한 딥러닝 기반 레이저 광원-끝점 검출	유수빈, 길상민, 권승곤, 손현중, 강진일 ((주)볼시스)	
B-P3	무인수상선 해상시험을 위한 무인기 자율 추종 및 공중 영상 관제 시스템	김성민(충남대학교), 이영준(KRISO), 김상수(UST-KRISO), 이현우, 강호준, 한종부, 김기훈 (KRISO)	
B-P4	임의 단일 물체의 자율 시각 커버리지를 위한 학습 기반 경로계획기	표승현, 박대길 (UST-KRISO)	
B-P5	Investigation of Effective Representation for Side-Scan Sonar SLAM Under Elevation Degeneracy	임진호, 홍성훈 (계명대학교)	
B-P6	포텐셜 유동 패널법 – CFD 도메인 보정 회귀모델을 이용한 BB2 세일 후류 압력장 기반 AUV 상대 위치 역추정	손영주, 남보우 (서울대학교), 변성훈(KRISO)	
B-P7	외란 관측기 기반 모델 예측 제어를 이용한 무인수상정의 강인 궤적 추종	박기용, 김진환 (KAIST)	
B-P8	피드백 기반 인식 정제를 통한 열악한 해상 환경에서의 강인한 카메라–레이다 융합	신영하, 김진환 (KAIST)	

* 상기 일정은 상황에 따라 일부 조정될 수 있습니다.

목차

CONTENTS

행사 안내

학술대회 개요·일정 및 발표 안내 5

특별강연

초청강연 1 국제협력을 통한 무인함정 개발 현황 및 계획 15

초청강연 2 바다에서 원자로까지, 그리고 다시 바다로 21

학술세션 A

A-P1 해상 환경에서의 다중 센서 데이터 취득을 위한 ROS2 기반 통합 시스템 개발 41

A-P2 자율운항선박 디지털 트윈 환경 구축을 위한 DINOv3 이미지 특징 기반 카메라-라이다 3D 공간정보 정합 기초 연구 47

A-P3 수중 로봇 연구를 위한 GPU 가속 소나 시뮬레이터 및 자동 데이터셋 생성 55

A-P4 가상 데이터 학습 기반 수중 로봇 위치 추정 61

A-P5 해저면 근접 운용을 위한 제한된 화각의 3차원 멀티빔 음향측심기 기반 오도메트리 추정 기법 65

A-P6 3D 소나의 3차원 특징벡터 기반 수중 다이버 탐지 알고리즘 71

A-P7 RL-Based Gain Optimization of Time-Delay Control for AUVs with a Pan-Tilt Sensor Pointing Mechanism 77

A-P8 Tilt-Aware FFT-ICP Scan Registration for Pose-Graph SLAM with a Downward-Tilted Forward-Looking Sonar 83

목차

CONTENTS

학술세션 B

B-P1	대양전기공업(주) 수중로봇 솔루션	93
B-P2	AUV 도킹 유도를 위한 딥러닝 기반 레이저 광원-끝점 검출	97
B-P3	무인수상선 해상시험을 위한 무인기 자율 추종 및 공중 영상 관제 기술	103
B-P4	임의 단일 물체의 자율 시각 커버리지를 위한 학습 기반 경로계획기	109
B-P5	Investigation of Effective State Representation for Side-Scan Sonar SLAM Under Elevation Degeneracy	117
B-P6	BB2 세일 후류 압력장 기반 AUV 상대 위치 추정 모델 개발	125
B-P7	외란 관측기 기반 모델 예측 제어를 이용한 무인수상정의 강인 궤적 추종	135
B-P8	피드백 기반 인식 정제를 통한 열악한 해상 환경에서의 강인한 카메라-레이다 융합	141

메모

MEMO 145

특별강연

초청강연 1 국제협력을 통한 무인함정 개발 현황 및 계획 15

초청강연 2 바다에서 원자로까지, 그리고 다시 바다로 21

한국해양로봇기술연구회
2026 추계학술대회

초청강연 1

국제협력을 통한 무인함정 개발 현황 및 계획

김형택

HD한국조선해양 함정연구소

본문 15쪽 특별강연

HD HYUNDAI

HD HYUNDAI · NAVAL R&D CENTER

국제협력을 통한 무인함정 개발 현황 및 계획

HD현대 함정연구소장
김형택 상무

2026. 11 · HD한국조선해양 함정연구소

01 / 26

HD HYUNDAI

CONTENTS

목차 - 발표순서

I 무인 함정 개발 배경 및 동향

II 한국(HD현대)-미국(Anduril) 협력 배경

III 무인수상함의 자율화/무인화 SW 개발 현황

02 / 26

HD HYUNDAI

PART I

I. 무인수상함 개발 배경 및 동향

03 / 26

HD HYUNDAI

무인 함정 개발 배경 및 동향

배경 – 무인함정 개발 필요성

전세계 시장/전장 상황의 변화 및 승조원 부족과 관련, 선택이 아닌 군과 기업의 생존의 문제

Effectiveness

실전에서 증명된 비대칭

3억원 USV ⇔ 900억원 초계함

Inevitability

병력은 줄지만 임무는 그대로

30년간 66% 감소 · 입영률 70.5%

Market

10년 31.3조원

연 10.6% 성장 · 미국이 절반

04 / 26

HD HYUNDAI

무인 함정 개발 배경 및 동향

무인함정 개발 동향(국내)

무인수상정은 본격적으로 해군 작전에 투입되지 않은 상황 (시제 검증 단계),로 전력화 사례가 없음

On the Testing Phase

전력화 사례 없음 · 시제 검증 진행

한화시스템 · 해령

LIG넥스원 · 해검

KRISO · 아라곤

HD HYUNDAI

무인 함정 개발 배경 및 동향

무인함정 개발 동향(해외)

소형 USV 의 경우 국내와 달리 전력화되어 실제 상용화 단계이며, 중 대형으로 확장 중

01

Fielded

소형 USV는 이미 실전 투입 중

02

Autonomy Up

항해 + "기관"

03

Scaling Up

중 · 대형으로 확장 중

HD HYUNDAI

PART II

II. 한국(HD현대)-미국(Anduril) 협력 배경

07 / 26

HD HYUNDAI

PART III

III. 무인수상함의 자율화/무인화 SW 개발 현황

12 / 26

한국해양로봇기술연구회
2026 추계학술대회

초청강연 2

바다에서 원자로까지, 그리고 다시 바다로

원자력로봇과 해양로봇 기술의 접점

주성문

한국원자력연구원 (KAERI)

2026.11.13, 해양로봇기술연구회 초청강연

바다에서 원자로까지, 그리고 다시 바다로

원자력로봇과 해양로봇 기술의 접점
- 함께 풀 수 있는 문제는 어떤 것들이 있나?

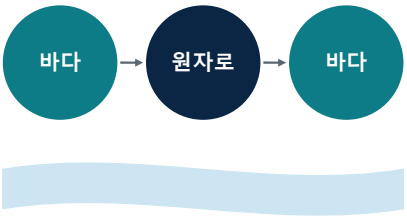

주성문
한국원자력연구원 (KAERI)

한국원자력연구원

- **1959년 2월, 원자력연구소(국립 연구소)**
- **1973년 2월, 한국원자력연구소(정부출연 연구소)**
  - 원자력연구소, 방사선의학연구소,방사선농학연구소 통합
- **2007년 3월,한국원자력연구원으로 명칭변경**
- **국내 유일의 원자력 종합 연구개발 기관**

직원 현황 2026년 3월 1일 기준

예산 2026년도 사업계획 및 예산(안) 기준

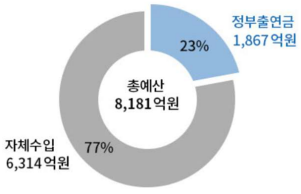

지역별 거점

2

원자력

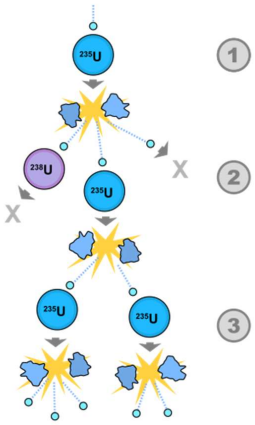
235U
238U
235U
235U
235U
X
X
1
2
3

120 gallons
Oil
17,000 ft³
Natural Gas
Natural gas is less energy dense compared to other fossil fuels, but creates far fewer emissions.
A uranium pellet packs around 17 million BTU (British Thermal Units) of energy.
1 inch tall
Uranium Pellet
Less than 10 pellets can power the average household for a year.
1 ton
Coal
Source: U.S. Department of Energy

3

원자력 발전

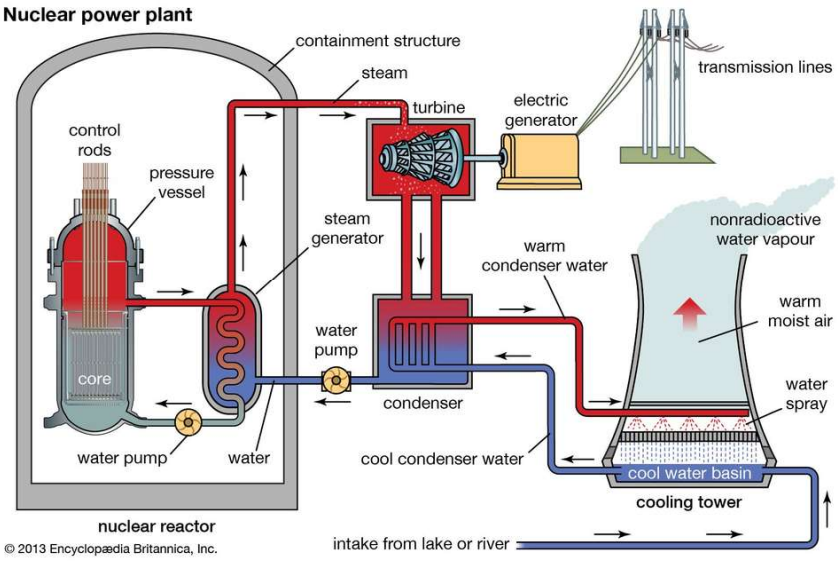
Nuclear power plant
containment structure
steam
turbine
electric generator
transmission lines
control rods
pressure vessel
steam generator
warm condenser water
nonradioactive water vapour
warm moist air
water pump
core
condenser
water spray
water pump
water
cool condenser water
cool water basin
cooling tower
nuclear reactor
intake from lake or river
© 2013 Encyclopædia Britannica, Inc.

4

원자력 주기(Cycle): 연료(Fuel), 시설(Facility)

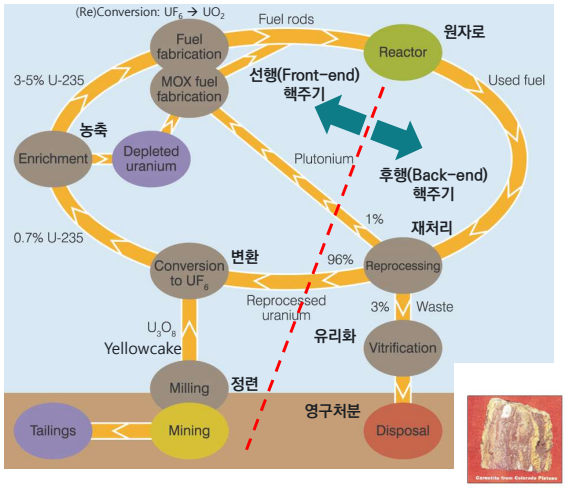

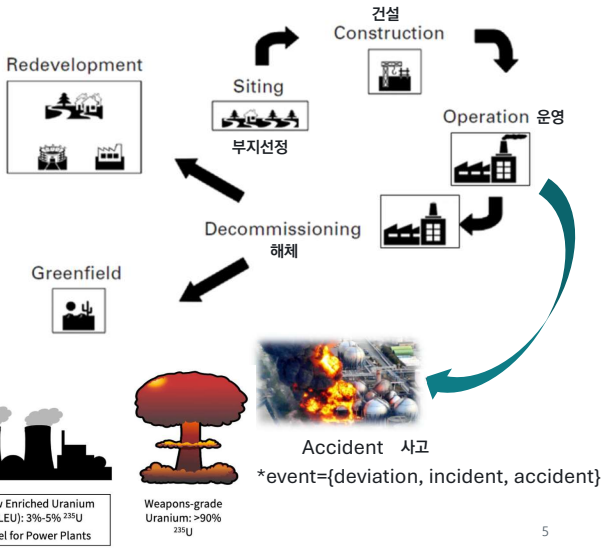

Natural Uranium:
0.7% ^{235}U
99.3% ^{238}U

Low Enriched Uranium (LEU): 3%-5% ^{235}U
Fuel for Power Plants

Weapons-grade Uranium: >90% ^{235}U

5

해양 × 원자력: 생각보다 가까운 두 단어

왜 원자력연구원 연구자가 해양로봇기술연구회에서 강연을 할까?

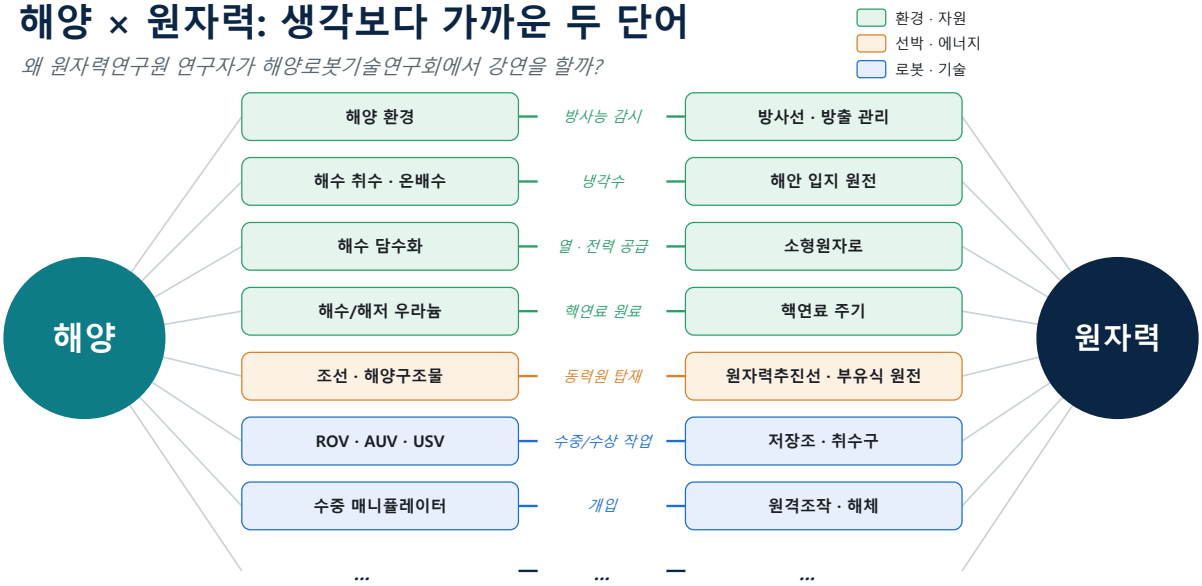

6

바다에서 원자로까지...

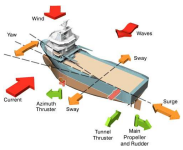

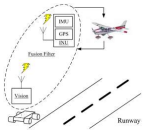

조선해양공학
부유체 동역학
Dynamic Positioning

기계공학
무인 자동차

항공공학
GNC, GPS-denied 환경
SLAM + 비선형 최적화

SHI
생산자동화 로봇
O&M 로봇

GIT.
DARPA
Robotic Challenge

KAERI
원자력 로봇

로봇 기술의 역사

왜 원자력연구원 연구자가 로봇기술을 연구할까?

문헌

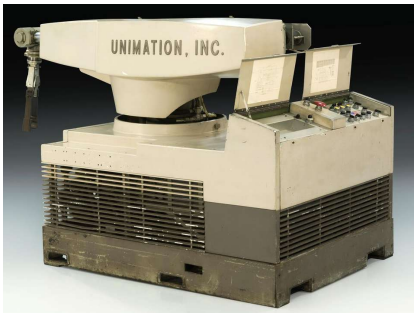

In 1961, the First Robot Arm Punched In The era of industrial robots began with **Unimate**, at a GM plant in Trenton

3,500 pound industrial robot, **Unimate**, pouring coffee for a woman at Biltmore Hotel in Los Angeles, Calif., 1967.

SRI researchers Nils Nilsson (right) and Sven Wahlstrom with **Shakey** the Robot in the late 1960s

원자력에서 발전한 master–slave 원격조작

문헌

왜 원자력연구원 연구자가 로봇기술을 연구할까?

Goertz demonstrating his mechanical slave-master manipulator device in 1949 at Argonne National Lab.

master–slave 원격조작 · ANL (Goertz), 1949
차폐창 너머에서 방사성 물질을 다루기 위해
손의 움직임과 도구의 움직임을 연동

힘 반영 (force reflection)	전기식 서보 (1954, Model E1) 로봇??	감독 제어 (supervisory control)

기술이 확산된 사례

우주	수중	의료

9

잠깐~

해양로봇의 역사?

문헌

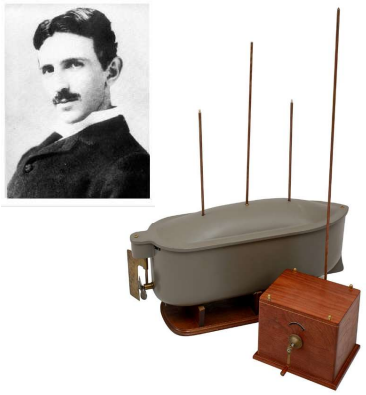

Tesla;s Remotely Controlled Boat (Telautomaton) @ Electrical Exhibition at Madison Square Garden, NY, 1898

telautomatics - the art of controlling the movements and operations of distant automatons

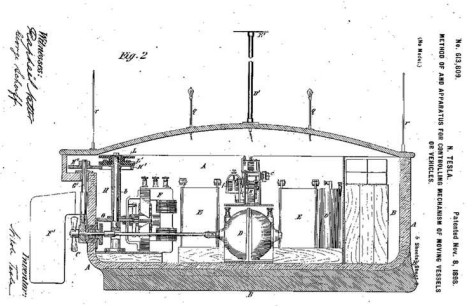

Method of and apparatus for controlling mechanism of moving vessels or vehicles (US Patent 613,809, N. Tesla, 1898)

10

KAERI 로봇 연구

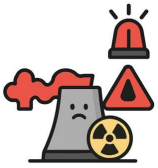

KAERI 로봇 연구

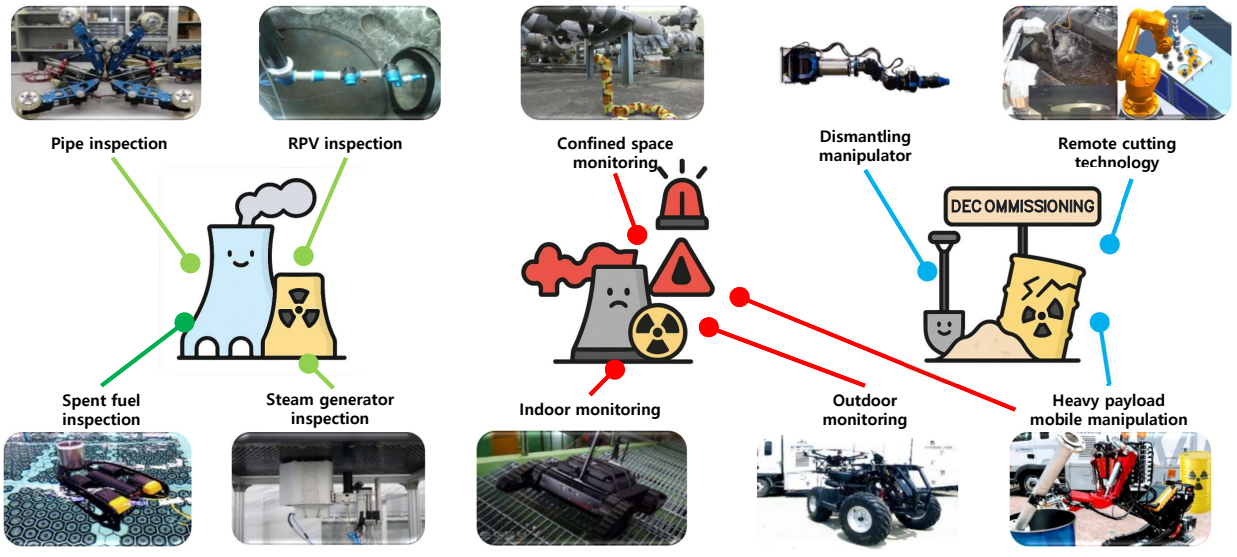

바다에서 → **원자로까지** → 다시 바다로

원자력 발전소 주변의 '물'

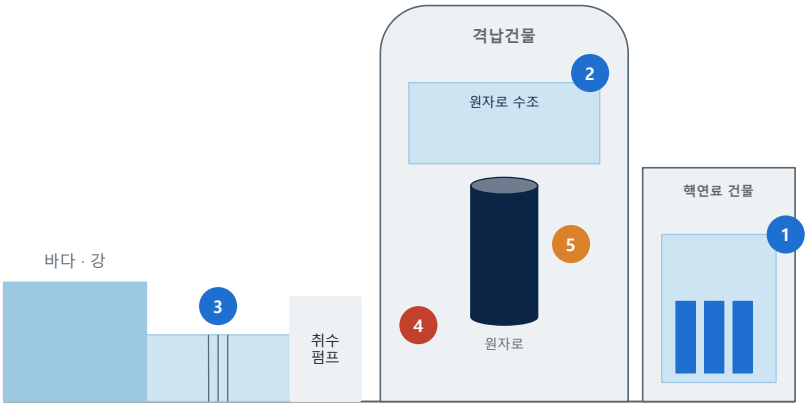

1. **사용후핵연료 저장조**
   IAEA 안전조치 · 점검
2. **원자로 수조 · 원자로 내부**
   정비 기간 수중 검사
3. **취수구 · 방수로**
   취수 구조물 · 트래시랙 점검
4. **사고 원자로 격납용기**
   침수 내부 조사 (후쿠시마)
5. **해체 현장**
   원자로 구조물 수중 절단

바다에서 → **원자로까지** → 다시 바다로

사용후 연료 저장조

문헌

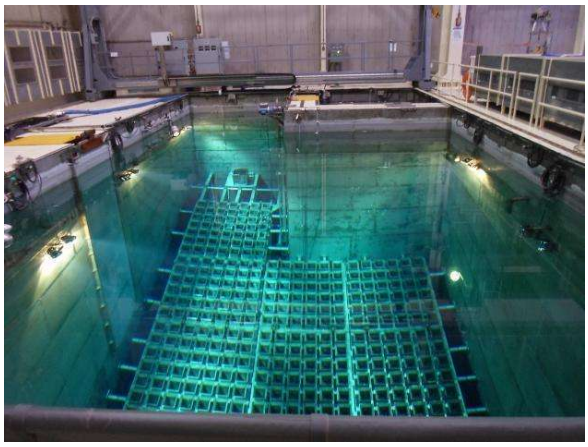

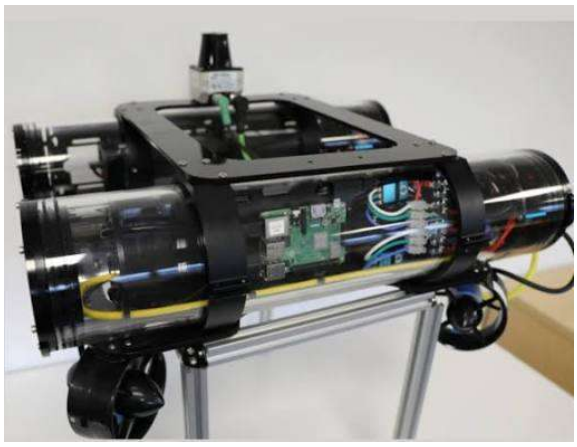

바다에서 → **원자로까지** → 다시 바다로

원자로 수조

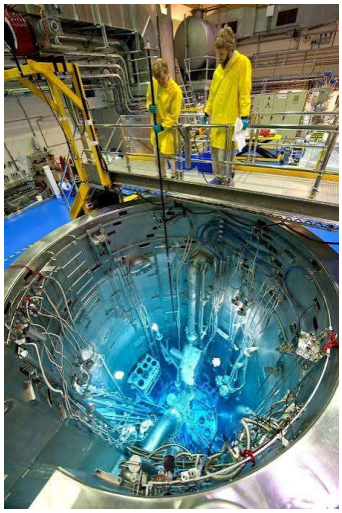

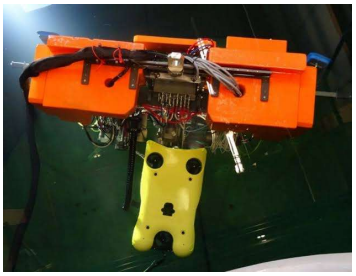

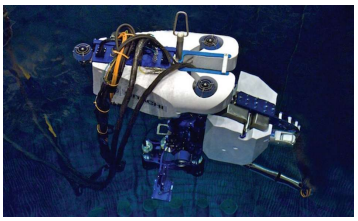

바다에서 → **원자로까지** → 다시 바다로

원자력 발전소 취수구

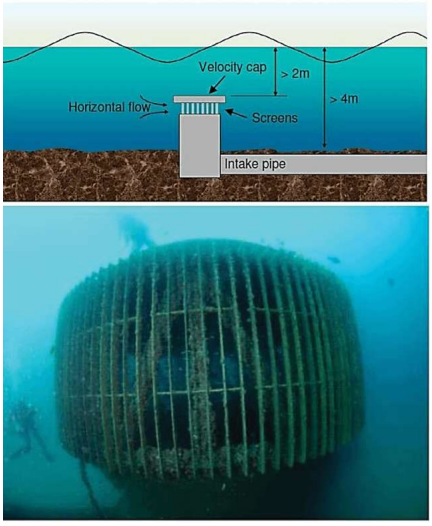

원자력 발전소 사고현장

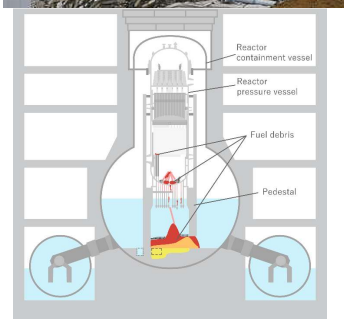

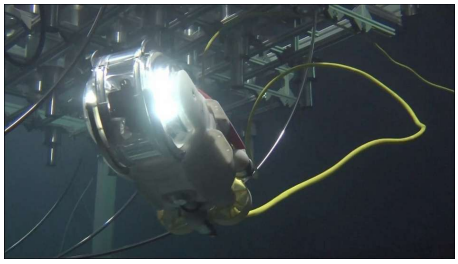

노후 원자력 시설

원자력 시설의 해체

원자력 시설의 해체

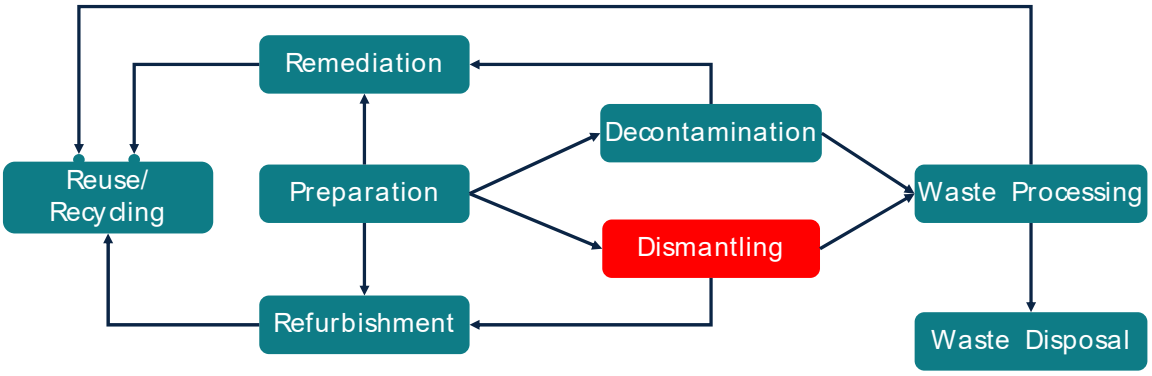

해체로봇 시스템

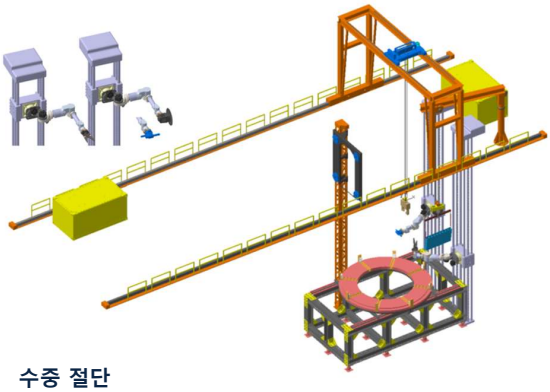

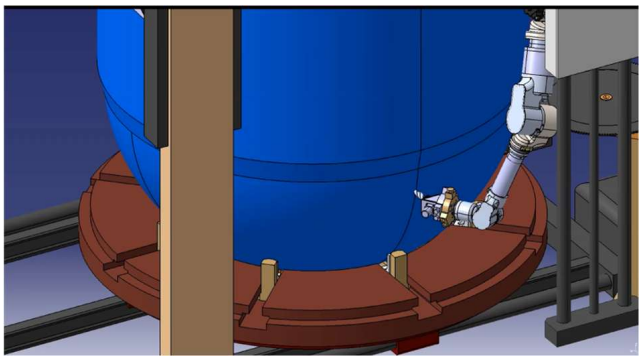

수중 절단

- 대상: 고방사화된 원자력 구조물 (예. 원자로, 1차계통)
- 장점: 물이 방사선을 차폐하고, 공기 중 입자 비산을 줄임
- 단점: 수중 오염 확산과 여과 관리가 함께 필요

해체로봇 시스템

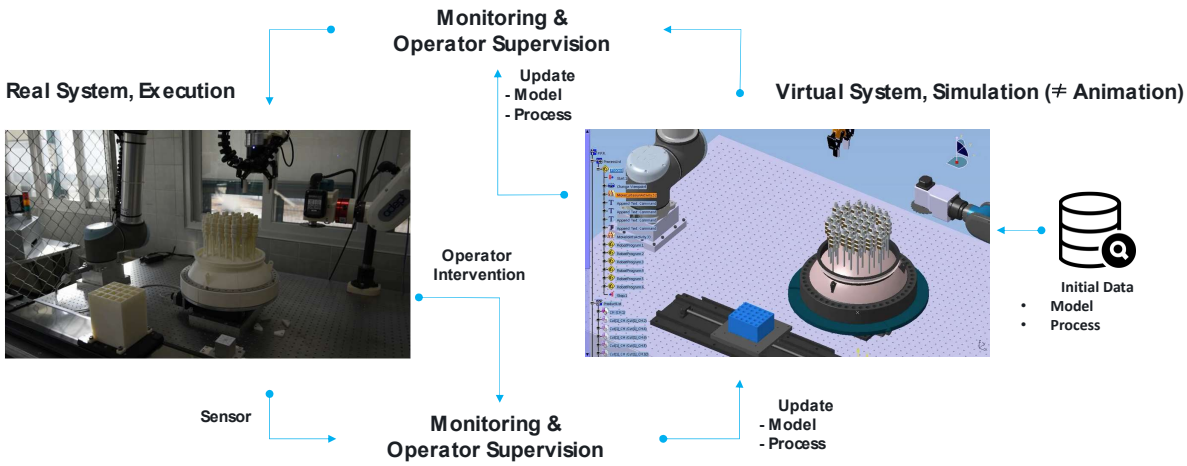

해체로봇 시스템

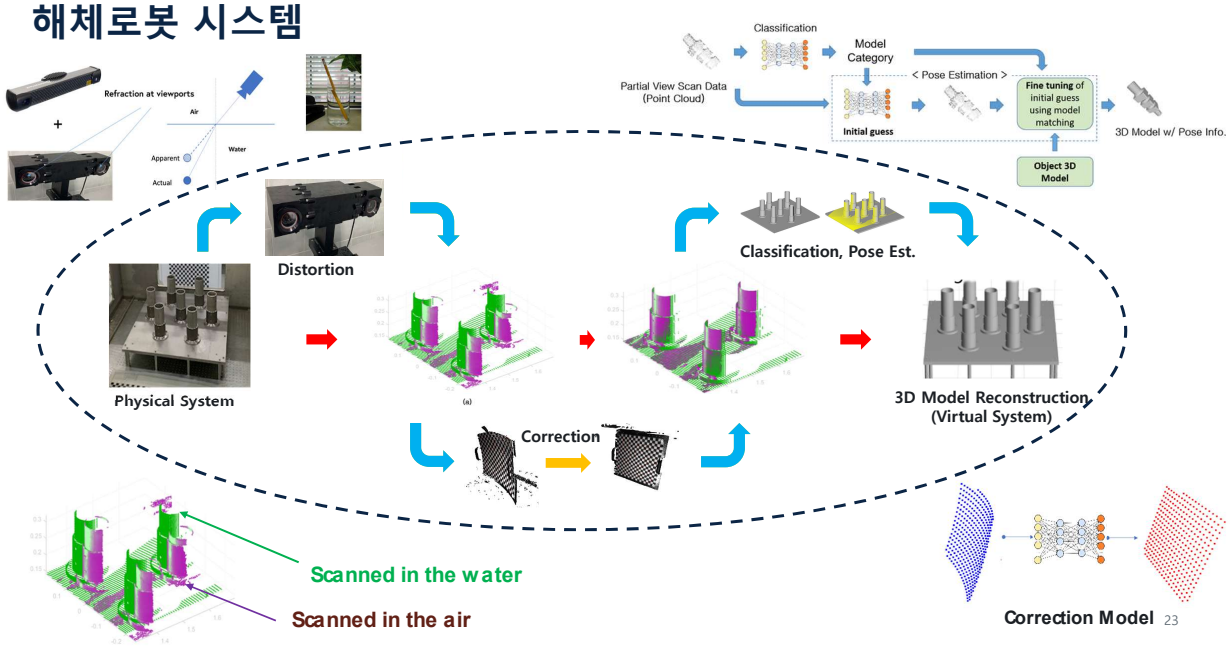

해체로봇 시스템

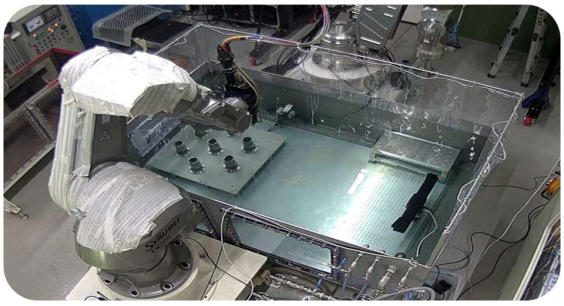

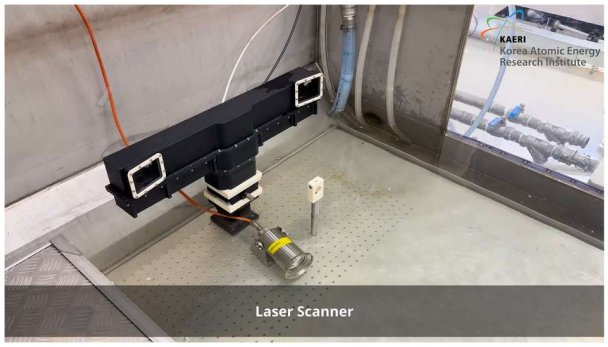

해체로봇 시스템

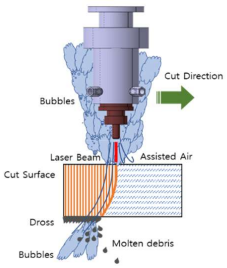

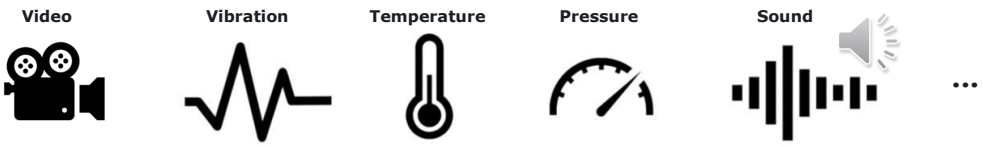

해체로봇 시스템

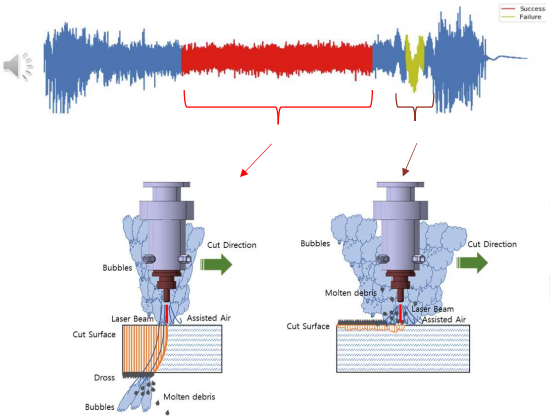

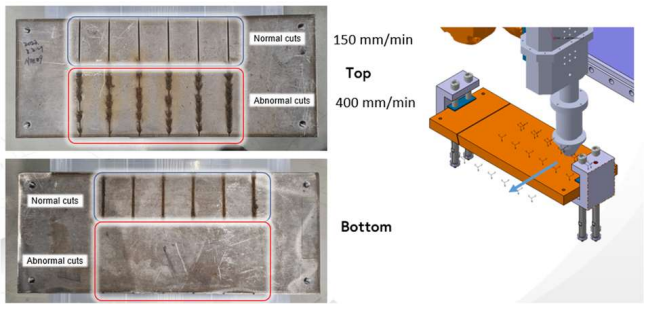

바다에서 → **원자로까지** → 다시 바다로

해체로봇 시스템

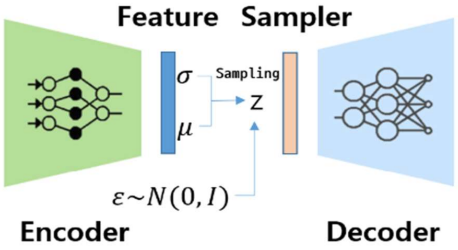

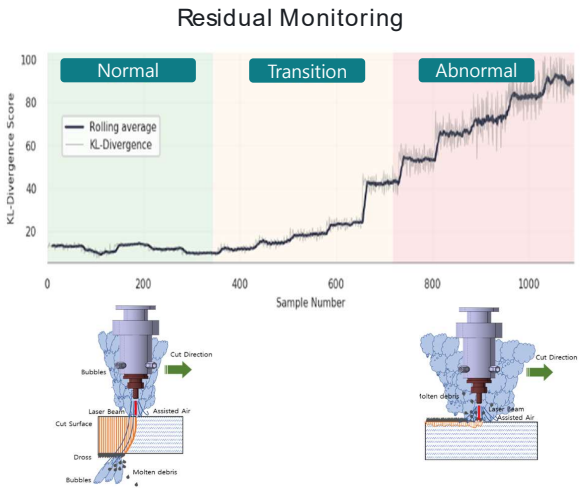

바다에서 → **원자로까지** → 다시 바다로

해체로봇 시스템

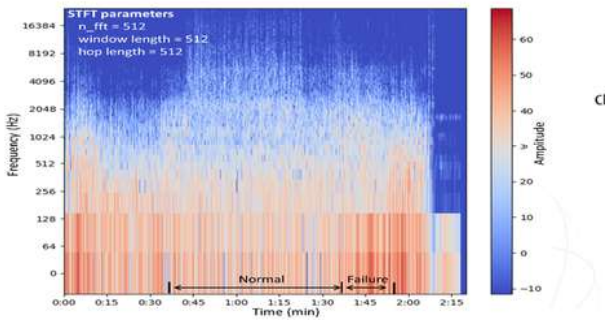

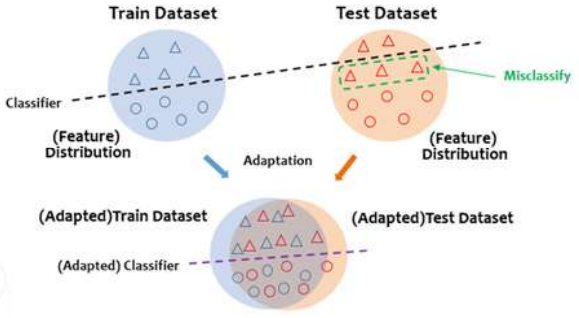

상태 인식의 불확실성 존재함 → 안전성을 보장할 수 있는 설계 필요

바다에서 → **원자로까지** → 다시 바다로

원자력 로봇의 운용 원칙

사람의 단계별 감독/책임하에 원격·자동화 기능을 임무에 맞게 구성

원격·자율화를 제약하는 요인들 ...

신뢰성	현장환경	작업절차	검증/규제	경제성
고장이 곧 작업 중단·오염 복구/회수 어려움	현장 데이터 수집 어려움 환경인식 어려움	도구 운용· 취급 노하우 필수	무엇을 어떻게 입증할 것인가	개발·시험 비용 대비 효과

바다에서 → 원자로까지 → **다시 바다로**

서로 다른 현장의 접점

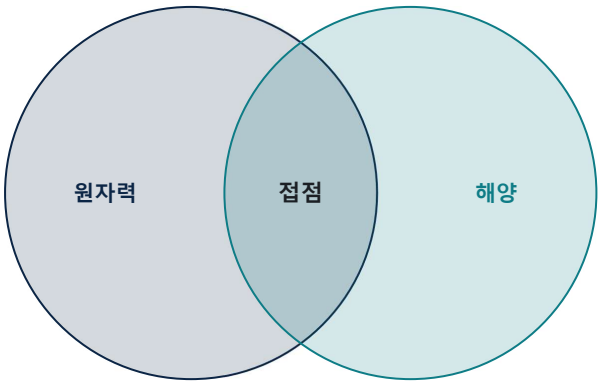

1. 사람의 접근 제약 - 접근
2. (제한된) 자율제어 ·원격(테더)제어 - 운용
3. 시야 · 통신 제약 – 관측/인식
4. 높은 실패/회수 비용 – 복구/경제성
5. 적은 실환경 시험 기회 – 접근/경제성

...

바다에서 → 원자로까지 → **다시 바다로**

마무리

원자력 시설에는 해양로봇 기술을 바로 적용할 수 있는 다양한 수중/수상 작업이 있다.

두 분야는 환경적 측면에서 일부 차이점이 있으나 공통 접점에서 함께 고민해서 해결할 수 있는 문제들이 많다.

학술세션 A

A-P1	해상 환경에서의 다중 센서 데이터 취득을 위한 ROS2 기반 통합 시스템 개발	41
A-P2	자율운항선박 디지털 트윈 환경 구축을 위한 DINOv3 이미지 특징 기반 카메라-라이다 3D 공간정보 정합 기초 연구	47
A-P3	수중 로봇 연구를 위한 GPU 가속 소나 시뮬레이터 및 자동 데이터셋 생성	55
A-P4	가상 데이터 학습 기반 수중 로봇 위치 추정	61
A-P5	해저면 근접 운용을 위한 제한된 화각의 3차원 멀티빔 음향측심기 기반 오도메트리 추정 기법	65
A-P6	3D 소나의 3차원 특징벡터 기반 수중 다이버 탐지 알고리즘	71
A-P7	RL-Based Gain Optimization of Time-Delay Control for AUVs with a Pan-Tilt Sensor Pointing Mechanism	77
A-P8	Tilt-Aware FFT-ICP Scan Registration for Pose-Graph SLAM with a Downward-Tilted Forward-Looking Sonar	83

한국해양로봇기술연구회
2026 추계학술대회

A-P1

해상 환경에서의 다중 센서 데이터 취득을 위한 ROS2 기반 통합 시스템 개발

Development of a ROS2-Based Integrated System for Multi-Sensor Data Acquisition in Maritime Environments

이동제 · 장혜수 · 김한근 · 구정모

씨드로닉스(주)

해상 환경에서의 다중 센서 데이터 취득을 위한 ROS2 기반 통합 시스템 개발

이동제 · 장혜수 · 김한근 · 구정모
씨드로닉스(주)

Development of a ROS 2-Based Integrated System for Multi-Sensor Data Acquisition in Maritime Environments

Dongje Lee, Hyesu Jang, Hanguen Kim, Jungmo Koo
Seadronix Corp.

Key Words: ROS2, Multi-sensor 다중 센서, Data acquisition 데이터 취득, Time synchronization 시간 동기화

Abstract: *Acquiring sensor data at sea is harder than on land. Unlike in road driving, there are few nearby structures or objects that can serve as features. Ships are constantly rocked by waves, making their attitude hard to determine. Most observed objects are distant, so even small attitude or timing errors cause large position errors. In such conditions, a single sensor type cannot easily perceive the surroundings, so data from multiple sensor types must be combined. In this case, time synchronization between the sensors is important. As the own ship and targets move and the hull sways, data acquired at different instants capture different scenes. Fusing time-misaligned data or using them for labeling and training causes position errors. However, maritime sensors differ in interface and data format by manufacturer, so their data are often recorded separately. This hinders time alignment across sensors and long-term unattended collection. To address these issues, we developed a multi-sensor data acquisition device. The device acquires data from heterogeneous maritime sensors in a single ROS 2 environment and records them together on a common time base. It was installed on two operating vessels to acquire data to acquire data in several sea areas, and the results are presented.*

1. 개요

최근 해상에서도 자율운항선박과 무인수상정(USV)을 중심으로 로보틱스와 인공지능 연구가 활발하다[1]. 주변 선박과 부유물의 인지, 충돌 회피, 자선의 위치 추정 등이 대표적인 과제이다. 이러한 연구에는 날씨, 조도, 해상 상태, 교통 상황 등 실제 해상의 다양한 환경을 반영한 양질의 데이터가 필요하다. 특히 학습 기반 인지 기술은 데이터의 질이 성능을 좌우한다. 학습 데이터에 없던 야간, 해무, 역광 등의 조건에서는 객체를 놓치거나 잘못 인식할 수 있다[2].

자율운항의 인지와 위치 추정에는 카메라, LiDAR, 레이더, GNSS/INS, AIS처럼 성격이 다른 센서가 함께 쓰인다. 카메라는 영상 분할과 객체 검출에 필요한 외관 정보를 제공하지만, 조명과 해무에 약하고 거리를 직접 재지 못한다. LiDAR와 레이더는 거리를 직접 측정하여 객체 거리 추정에서 카메라를 보완한다. LiDAR는 근거리에서 정밀한 3차원 점군을 얻고, 레이더는 원거리나 악천후에서도 표적을 탐지할 수 있다. 근거리 특징이 적고 수면이 단조로운 해상에서는 SLAM과 자세 추정에 레이더와 GNSS/INS를 함께 활용한다. 레이더는 해안선과 육상 구조물을 관측하여 부족한 특징을 메우고, GNSS/INS는 파랑에 흔들리는 자선의 위치와 자세를 제공한다. AIS는 주변 선박의 식별 정보와 위치를 알려 주므로, 인지 결과를 검증하거나 라벨링하는 데 쓸 수 있다. 공개된 해상 다중 센서 데이터셋[3], [4]도 있지만, 연구 목적과 운항 해역에 맞는 데이터는 직접 수집해야 하는 경우가 많다. 이들 데이터셋은 수집 해역과 센서 구성, 설치 위치가 정해져 있어 다른 선박에 그대로 적용하기 어렵다.

* 이동제 : 씨드로닉스(주) 02-552-1201, *dj.lee@seadronix.com*
* 장혜수 : 씨드로닉스(주) 02-552-1201, *hsjang@seadronix.com*
* 김한근 : 씨드로닉스(주) 02-552-1201, *hank05@seadronix.com*
* 구정모 : 씨드로닉스(주) 02-552-1201, *jungmo.koo@seadronix.com*

선박에서 다중 센서 데이터를 직접 취득할 때는 세 가지 어려움이 있다. 첫째, 센서마다 데이터를 전달받는 통신 방식과 데이터 형태가 달라 하나의 시스템에서 함께 다루기 어렵다. 예를 들어 카메라 영상은 스트림으로, LiDAR와 레이더 데이터는 UDP 패킷으로, AIS 데이터는 텍스트 문장으로 들어오므로 장비마다 수신 프로그램이 따로 필요하다. 둘째, 수집한 데이터를 센서 융합이나 인지·위치 추정 알고리즘에 적용하려면 센서 간 시각 정렬이 매우 중요하다. 자선과 표적의 운동, 선체의 요동 때문에 짧은 시간 차이도 융합 결과에서 위치 오차로 나타날 수 있다. 그러나 장비별 수집 프로그램을 따로 실행하면 사후에 파일을 병합할 때 시각이 어긋나기 쉽다. 프로그램마다 시계와 타임스탬프 기준이 일치하지 않을 수 있고, 센서마다 전송 지연도 다르기 때문이다. 셋째, 수집 장비는 전담 운용자 없이 장기간 가동된다. 운항 중에는 전원이 끊기거나 저장장치를 교체하는 일이 생길 수 있으며, 수집이 멈춘 것을 늦게 알면 그사이의 데이터를 잃는다. 따라서 전원이 복구되거나 저장장치가 늦게 연결된 뒤에도 수집이 자동으로 재개되어야 한다.

본 논문에서는 이러한 어려움을 해결하기 위해, 센서 구성이 다른 선박에도 범용으로 적용할 수 있는 ROS2 기반 통합 시스템을 소개한다. ROS2는 로봇 분야에서 널리 쓰이는 공개 소프트웨어 프레임워크로, 발행·구독 통신과 표준 메시지 형식, bag 기록 도구를 제공한다[5]. 발행·구독 통신에서는 센서 드라이버가 데이터를 토픽으로 발행하고, 다른 프로그램은 센서 종류와 관계없이 같은 방식으로 이를 구독한다. 따라서 선박마다 센서를 더하거나 빼더라도 기록 프로그램과 처리 모듈은 고칠 부분이 적다. 형태가 다른 영상, 점군, 위치, 관성 데이터도 표준 메시지 형식으로 통일해 다룰 수 있으며, 각 메시지 헤더에는 타임스탬프와 좌표계 정보가 담긴다. bag 기록 도구는 여러 토픽을 하나의 기록 세션에 함께 저장하므로, 센서별 파일을 사후에 병합하지 않아도 된다. 또한 각 프로그램(노드)은 중앙 마스터 없이 독립된 프로세스로 실행되어, 일부가 멈춰도 나머지

한국해양로봇기술연구회 2026년 추계학술대회 (2026. 11. 13(금) / 부산항국제전시컨벤션센터(부산))

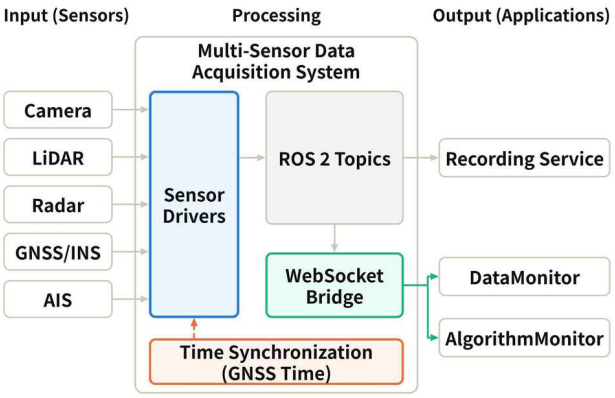

Fig.1 System Configuration

는 통신과 기록을 이어 갈 수 있다. 아울러 ROS2 토픽을 웹소켓 토픽으로 변환하는 브리지를 두었다. 이를 통해 ROS2가 설치되지 않은 뷰어 프로그램이나 다른 컴퓨터의 알고리즘도 센서 데이터를 실시간으로 받을 수 있다. 본 논문의 주요 내용은 다음과 같다.

* 센서마다 독립된 드라이버를 두고, 모든 드라이버가 같은 구조(데이터 획득부, ROS2 발행기, 파일 기록기)를 따르도록 설계하였다.

* 각 드라이버가 가능한 한 데이터 취득 시각을 타임스탬프로 기록하도록 하고, PC 시계를 GNSS 시각에 맞추는 보조 도구를 함께 두었다.

* 통합 실행 도구, 부팅 시 자동 기동, 연속 bag 기록을 갖추어 선박에서 무인으로 운용할 수 있게 하였다.

* ROS2 토픽을 웹소켓 토픽으로 변환하는 브리지를 두어, 별도로 개발한 뷰어 프로그램에서 센서 데이터를 실시간으로 확인하고 알고리즘의 입력으로 사용할 수 있게 하였다.

2. 시스템 설계

2.1 전체 시스템 구조

그림 1은 시스템의 전체 구조를 나타낸다. 카메라, LiDAR, 레이더, GNSS/INS, AIS처럼 종류가 다른 센서의 데이터도 모두 같은 방식으로 각 드라이버를 거쳐 ROS2 토픽으로 발행된다. 기록 서비스는 이 토픽을 구독하여 데이터를 저장한다. 또한 웹소켓 브리지는 ROS2 토픽을 웹소켓 토픽으로 변환하여 별도로 개발한 뷰어 프로그램에 실시간으로 전달한다. 뷰어 프로그램은 센서 데이터를 확인하는 DataMonitor와, 알고리즘을 실시간으로 적용하고 그 결과를 확인하는 AlgorithmMonitor로 이루어진다. 드라이버의 구조는 2.2절에서, 시각 동기화는 2.3절에서, 웹소켓 브리지는 2.4절에서 설명한다.

2.2 센서 드라이버

모든 드라이버는 그림 2와 같이 데이터 획득부 위에 발행기(publisher)와 파일 기록기(recorder)를 두는 공통 구조를 따른다. 데이터 획득부는 장비에서 받은 데이터를 영상, 점군 등의 내부 자료 구조로 변환하고, 발행기는 이를 ROS2 토픽으로 발행한다. 획득부가 데이터를 받는 방식은 센서마다 다르다. 카메라 중 IP 카메라는 RTSP로 받은 영상 스트림을 복호하여 이미지로 변환하고, GMSL2 카메라는 임베디드 캡처 장치를 거쳐 들어온 프레임을 이미지로 변환한다. LiDAR는 UDP로 받은 패킷을 한 회전 단위로 모아 점군으로 변환한다. 레이더는 안테나가 회전하면서 방위별 반사 강도(스포크)를 차례로 보내므로, 이를 안테나 한 회전 단위로 모아 직교 좌표의 영상으로 변환한다. 레이더는 장비마다 출력 형식이 달라, 공통 구조는 그대로 두고 장비별 전송

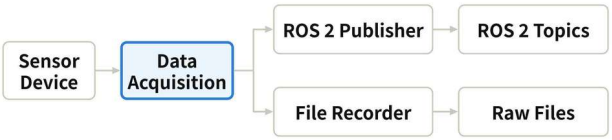

Fig.2 Common Structure of Sensor Drivers

Table 1 ROS2 Message Types by Sensor Data

데이터	센서	ROS2 메시지 타입
영상	카메라, 레이더	sensor_msgs/Image
압축 영상	카메라, 레이더	sensor_msgs/CompressedImage
점군	LiDAR	sensor_msgs/PointCloud2
위치	GNSS/INS	sensor_msgs/NavSatFix
자세	GNSS/INS	sensor_msgs/Imu
AIS 문장	AIS	nmea_msgs/Sentence

Table 2 Interfaces and Timestamp Sources by Sensor

센서	수신 방식	변환 데이터	타임스탬프 기준
IP 카메라	RTSP	영상	PC 수신 시각
GMSL2 카메라	UDP	영상	캡처 장치 시각
LiDAR	UDP	점군	PC 수신 시각
X-band 레이더	UDP	영상	스포크 수신 시각
W-band 레이더	TCP	영상	회전 끝 수신 시각
GNSS/INS	직렬(NMEA)	위치·자세	UTC 측위 시각
AIS	직렬(NMEA)	AIS 문장	PC 수신 시각

규격에 맞추어 데이터를 해석하는 부분만 장비별로 구현하였다. GNSS/INS는 직렬 통신으로 NMEA 문장을 받아 위치와 자세 데이터로 변환하고, AIS 역시 직렬 통신으로 NMEA[6] 문장을 받는다. 또한 ROS2를 사용할 수 없는 환경에 대비하여, 파일 기록기는 같은 획득부로 받은 원본 데이터를 ROS2 없이 파일로 저장한다. 이 기능은 장비 점검이나 단독 수집에도 활용할 수 있다. 각 센서의 드라이버는 토픽 이름과 장비 주소 같은 설정을 별도의 파라미터 파일로 관리한다. 따라서 다른 선박으로 옮겨 설치 환경이 바뀌어도 코드 수정 없이 파라미터 파일만 고쳐 대응할 수 있다.

센서 데이터는 표 1과 같이 ROS2 표준 메시지로 발행한다. 영상 데이터는 원본 영상과 함께 JPEG으로 압축한 영상(compressed)도 발행하여, 기록 용량과 전송량을 줄이고 사용 편의성을 높였다.

2.3 타임스탬프와 시각 동기화

각 센서의 타임스탬프에는 메시지 발행 시각이 아니라 데이터의 취득 시각을 기록하였다. 발행 시각에는 센서마다 다른 전송 지연과 처리 시간이 포함되어, 같은 순간에 측정한 데이터라도 서로 다른 시각으로 기록될 수 있기 때문이다. 장비가 취득 시각을 함께 제공하는 경우에는 그 값을 그대로 사용하였다. 취득 시각을 제공하지 않는 장비는 데이터를 수신한 시각 등을 바탕으로 역산하여 최대한 실제 취득 시각에 가깝게 맞추었다.

센서 간 데이터를 정렬하려면 모든 타임스탬프가 같은 시각 기준을 가져야 한다. 해상에서는 외부 시각 서버에 접속하기 어렵지만, GNSS 수신기는 위성 신호로부터 UTC 시각을 얻을 수 있다. 따라서 이 UTC 시각을 기준으로 동작하는 NTP[7] 서버를 구성하고, 수집 장치와 각 센서가 이 서버의 시각을 따르도록 하여 모든 센서의 시각을 동일하게 맞추었다. 이를 통해 서로 다른 센서에서 얻은 데이터를 하나의 시간축에서 비교하고 정렬할 수 있다.

센서별 수신 방식과 타임스탬프 기준은 표 2와 같다. 표 2의 타임스탬프 기준은 드라이버가 발행하는 메시지 헤더에 기록되는 시각의 출처이며, 센서마다 전송 방식과 시각 정보가 달라 드라이버별로 따로 정하였다.

한국해양로봇기술연구회 2026년 추계학술대회 (2026. 11. 13(금) / 부산항국제전시컨벤션센터(부산))

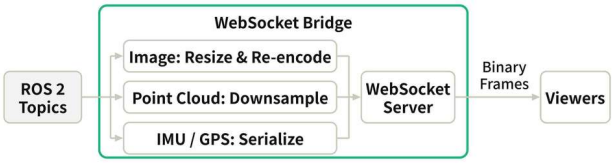

Fig.3 WebSocket Bridge Architecture

2.4 웹소켓 브리지

웹소켓 브리지는 ROS2 토픽을 웹소켓 토픽으로 변환하여 뷰어와 알고리즘에 실시간으로 전달한다. 웹소켓[8]은 웹 브라우저와 여러 프로그래밍 언어에서 널리 지원하는 양방향 통신 방식이므로, ROS2가 설치되지 않은 컴퓨터에서도 센서 데이터를 바로 받아 쓸 수 있다. 브리지는 토픽을 읽기만 하므로 데이터 기록에 영향을 주지 않으며, 각 토픽을 하나의 웹소켓 채널에 대응시킨다. 그림 3과 같이 브리지는 구독한 ROS2 토픽을 영상, 점군, IMU·GPS 등 데이터 종류별로 가공한 뒤 웹소켓 서버를 거쳐 뷰어에 전달한다. 영상은 크기를 줄여 다시 압축하고 점군은 점 수를 줄이는 등 데이터를 전송에 알맞게 변환하되, 원래의 타임스탬프는 그대로 담아 보낸다. 이때 영상은 JPEG을 복호하는 단계에서 1/2, 1/4 같은 축소 배율을 바로 적용하고, SIMD(single instruction, multiple data) 명령어로 가속되는 복호·압축 연산을 사용하여 적은 연산량으로 시각화용 영상을 만든다. 원본 폭이 기준 이하인 영상은 다시 압축하지 않고 그대로 전달한다. 뷰어는 필요한 채널만 골라 받으며, 처리가 느린 뷰어에는 최신 데이터만 보내 다른 뷰어에 영향을 주지 않는다.

3. 실험 결과

3.1 실험 환경

개발한 장치를 실선에 설치하여 실험을 진행하였다. 실험 선박은 싱가포르에서 운항하는 요트와 한국 인천에서 운항하는 예인선으로, 선종과 운항 해역이 서로 다른 두 선박에 같은 시스템을 적용하였다. 싱가포르에서는 센토사섬(Sentosa)주변 해역을, 인천에서는 인천대교 주변 해역을 운항하였다. 그림 4와 그림 5는 각 선박의 장치 설치 모습과 운항 구역을 나타내며, 각 선박에 설치한 센서는 표 3과 같다. 표 3과 같이 두 선박은 카메라와 LiDAR의 모델과 수량, 레이더 구성이 서로 다르며, W-band 레이더는 요트에만

Table 3 Sensor Configuration by Vessel

종류	싱가포르	인천
Camera	한화비전 XNO-9083R 2대, NAVISS(GMSL2 카메라) 2대	한화비전 XNO-9083R 2대, NAVISS(GMSL2 카메라) 4대
LiDAR	Ouster OS1 Gen1 1대	RoboSense RS-Helios 2대
X-band Radar	Simrad Halo 4 1대	선박 레이더 + DSPNOR Scan Streamer II 1대
W-band Radar	Navtech MAS10 1대	미설치
GNSS	Hemisphere V500 1대, Xsens MTi-7 1대	선박 GNSS 1대, Xsens MTi-7 1대
AIS	삼영이엔씨 SI-60RX 1대	선박 AIS 1대

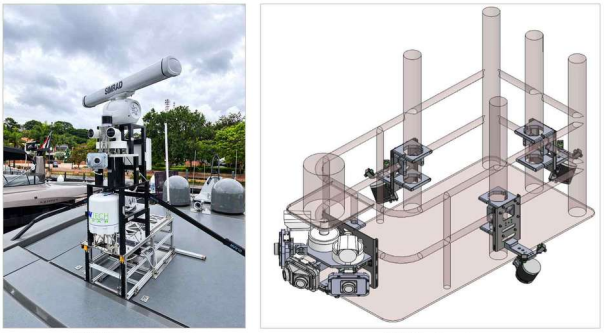

(a) Singapore (b) Incheon

Fig.4 Sensor Installation and Design Drawing

(a) Singapore (b) Incheon

Fig.5 Operating Areas

설치하였다. 요트에는 레이더, GNSS, AIS를 별도 장비로 설치하였고, 예인선에서는 선박에 이미 설치된 항해 장비를 연동하였다. 이처럼 센서 구성이 달라도 두 선박 모두 실행할 드라이버와 설정 파일만 바꾸어 같은 시스템을 적용하였다. 실험 기간 동안 요트는 주간, 일몰, 야간 시나리오에 따라 운항하였고, 예인선은 정박과 약 6~9 kt 항해를 포함한 일상 운항 중에 데이터를 수집하였다.

3.2 데이터 취득 및 실시간 적용 결과

각 선박에서는 설치한 센서의 데이터를 같은 시각 기준으로 하나의 기록 세션에 함께 저장하였으며, 선박별 기록 결과는 표 4와 같다. 이와 동시에 웹소켓 브리지를 통해 별도의 모니터 PC로 데이터를 실시간 전달하였다. 두 선박 모두 시간당 약 230 GB의 데이터가 기록되어, 장시간 수집에는 대용량 저장 장치가 필요함을 확인하였다. 인천의 예인선에서는 현재도 수집을 이어가고 있다.

그림 6은 DataMonitor 화면이다. DataMonitor는 카메라 영상과 LiDAR 점군, 레이더 영상, 지도 위의 자선 위치와 AIS 선박 정보를 한 화면에 실시간으로 표시한다. 화면 아래의 표에는 토픽별 수신 주기와 기대 주기, 대역폭, 마지막 수신 후 경과 시간, 최근 타임스탬프, 누적 메시지 수가 표시되므로, 특정 센서의 연결이 끊기거나 수신 주기가 떨어지면 바로 알 수 있다. 또한 IMU의 자세(롤·피치·요) 정보도 함께 표시되며, 그림 6의 AIS 화면에는 수신한 주변 선박 319척이 지도 위에 나타나 있다. 그림 6의 상태 표를 보면 IP 카메라 영상은 30 Hz, GMSL2 카메라 영상은 15 Hz, LiDAR와 X-band 레이더는 약 10 Hz, IMU는 100 Hz로 수신되어 설정한 주기와 거의 같았다.

그림 7은 AlgorithmMonitor에서 카메라 및 레이더 데이터에 객체 검출·추적과 영역 분할 알고리즘을 실시간으로 적용한 결과이다. 왼쪽은 두 카메라 영상에서 검출한 선박을 경계 상자와 추적 번호로 표시하고 해수면 영역을 분할

한국해양로봇기술연구회 2026년 추계학술대회 (2026. 11. 13(금) / 부산항국제전시컨벤션센터(부산))

Table 4 Data Acquisition Results by Vessel

항목	싱가포르	인천
수집 기간	2026.6.26 ~ 7.1	2026.8.19 ~ 계속 수집 중
총 기록 시간	약 8시간	약 130시간 이상
총 데이터량	약 1.9 TB	약 10.5 TB
시간당 데이터량	약 235 GB/h	약 232 GB/h

Fig.6 Data Monitor

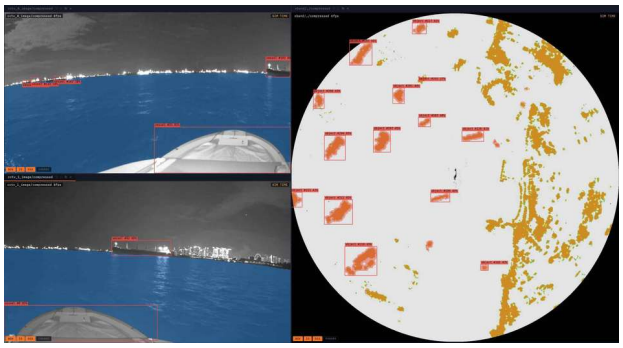

Fig.7 Algorithm Monitor

하여 색으로 나타낸 결과이며, 오른쪽은 X-band 레이더 영상에서 검출한 물체를 같은 방식으로 표시한 결과이다. 알고리즘은 수집 장치와 분리된 PC에서 실행되므로, 수집 장치의 처리 부하를 늘리지 않고 여러 알고리즘을 시험할 수 있다.

이를 통해 개발한 장치가 데이터를 기록하면서, 별도의 PC에서도 웹소켓으로 받은 센서 데이터를 알고리즘의 실시간 입력으로 사용할 수 있음을 확인하였다. 즉, 하나의 시스템으로 데이터 기록과 상태 감시, 알고리즘 검증을 동시에 수행할 수 있다.

3.3 고찰

두 선박에 시스템을 적용하면서, 새로 설치한 장비뿐 아니라 선박에 이미 설치된 항해 장비도 같은 구조로 연동할 수 있음을 확인하였다. 예인선에서는 선박 레이더 신호를 DSPNOR Scan Streamer II로 디지털화하여 받았고, 선박의 GNSS와 AIS 데이터도 그대로 기록하였다. 다만 시스템을 연속적으로 사용하기 위해서는 선박의 이동 순간을 판단하는 등의 적절한 관리 방법이 필요하다.

4. 결론

본 논문에서는 해상 환경에서 다중 센서 데이터를 취득하기 위한 ROS2 기반 통합 시스템을 개발하였다. 통신 방식과 데이터 형태가 서로 다른 카메라, LiDAR, 레이더, GNSS/INS, AIS 데이터를 같은 구조의 드라이버로 수신하여 ROS2 토픽으로 발행하였다. 각 데이터에는 취득 시각을 타임스탬프로 기록하고, GNSS의 UTC 시각을 기준으로 모든 센서의 시각을 맞추어 같은 시각 기준으로 함께 저장하였다. 또한 ROS2 없이 원본 데이터를 저장하는 파일 기록 기능과, ROS2 토픽을 웹소켓 토픽으로 변환하여 뷰어와 알고리즘에 실시간으로 전달하는 브리지를 구현하였다. 개발한 시스템을 운항 해역과 센서 구성이 서로 다른 싱가포르의 요트와 인천의 예인선에 적용하여 데이터를 취득하였으며, 취득과 동시에 별도의 PC에서 센서 데이터를 실시간으로 확인하고 객체 인지 알고리즘을 적용할 수 있음을 확인하였다. 두 선박에서 각각 약 8시간과 130시간 이상의 데이터를 기록하였으며, 각 센서의 데이터는 설정한 주기와 거의 같은 주기로 수신되었다. 제안한 구조는 센서를 추가하거나 다른 선박으로 옮길 때 드라이버와 설정 파일만 바꾸면 되므로, 다양한 선박에 같은 수집 체계를 적용하는 데 유리하다.

향후에는 더 다양한 해역과 기상 조건에서 데이터를 축적하여, 해상 인지와 위치 추정 알고리즘의 학습과 검증에 활용할 수 있는 데이터셋으로 정리할 예정이다. 또한 PC 수신 시각을 사용하는 센서의 전송 지연을 측정하여 보정함으로써 센서 간 시각 정렬의 정확도를 높일 계획이다.

참 고 문 헌

[1] S. Thombre et al., “Sensors and AI techniques for situational awareness in autonomous ships: A review,” IEEE Transactions on Intelligent Transportation Systems, vol. 23, no. 1, pp. 64–83, 2022. doi:10.1109/TITS.2020.3023957

[2] L. Žust, J. Perš, and M. Kristan, “LaRS: A diverse panoptic maritime obstacle detection dataset and benchmark,” in Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV), pp. 20247–20257, 2023. doi:10.1109/ICCV51070.2023.01857

[3] D. Chung, J. Kim, C. Lee, and J. Kim, “Pohang canal dataset: A multimodal maritime dataset for autonomous navigation in restricted waters,” The International Journal of Robotics Research, vol. 42, no. 12, pp. 1104–1114, 2023. doi:10.1177/02783649231191145

[4] H. Jang, W. Yang, H. Kim, D. Lee, Y. Kim, J. Park, M. Jeon, J. Koh, Y. Kang, M. Jung, S. Jung, and A. Kim, “MOANA: Multi-radar dataset for maritime odometry and autonomous navigation application,” The International Journal of Robotics Research, vol. 45, no. 2, pp. 193–203, 2026. doi:10.1177/02783649251354897

[5] S. Macenski, T. Foote, B. Gerkey, C. Lalancette, and W. Woodall, “Robot Operating System 2: Design, architecture, and uses in the wild,” Science Robotics, vol. 7, no. 66, eabm6074, 2022. doi:10.1126/scirobotics.abm6074

[6] IEC 61162-1:2024, Maritime navigation and radiocommunication equipment and systems – Digital interfaces – Part 1: Single talker and multiple listeners, Ed. 6.0, 2024. https://webstore.iec.ch/en/publication/72729

[7] D. Mills, J. Martin, Ed., J. Burbank, and W. Kasch, “Network Time Protocol version 4: Protocol and algorithms specification,” Internet Engineering Task Force, RFC 5905, 2010. doi:10.17487/RFC5905

[8] I. Fette and A. Melnikov, “The WebSocket protocol,” Internet Engineering Task Force, RFC 6455, 2011. doi:10.17487/RFC6455

한국해양로봇기술연구회
2026 추계학술대회

A-P2

자율운항선박 디지털 트윈 환경 구축을 위한 DINOv3 이미지 특징 기반 카메라-라이다 3D 공간정보 정합 기초 연구

Preliminary Study on Camera-LiDAR 3D Spatial Data Registration Using DINOv3 Image Features for Autonomous Ship Digital Twins

조민기 · 강민주 · 주기범 · 최진우 · 김동함 · 김동언 · 박정홍

선박해양플랜트연구소 (KRISO) / 과학기술연합대학원대학교 (UST)

한국해양로봇기술연구회
Korea Marine Robot Technology Society

KRISO UST

자율운항선박 디지털 트윈 환경 구축을 위한 DINOv3 이미지 특징 기반 카메라-라이다 3D 공간정보 정합 기초 연구

: Preliminary Study on Camera-LiDAR 3D Spatial Data Registration Using DINOv3 Image Features for Autonomous Ship Digital Twins

2026.11.13

조민기, 강민주, 주기범, 최진우, 김동함, 김동언, 박정홍*
선박해양플랜트연구소, **KRISO**
선박해양공학전공, **UST**

ORIS LAB

01 디지털 트윈을 위한 실해역 공간정보

KRISO UST

- **자율 이·접안 및 경로 계획 검증용 디지털 트윈 공간정보 활용의 필요성**
  - 자율운항 핵심 기술 검증: 정밀한 실해역 공간정보 기반 디지털 트윈 필요

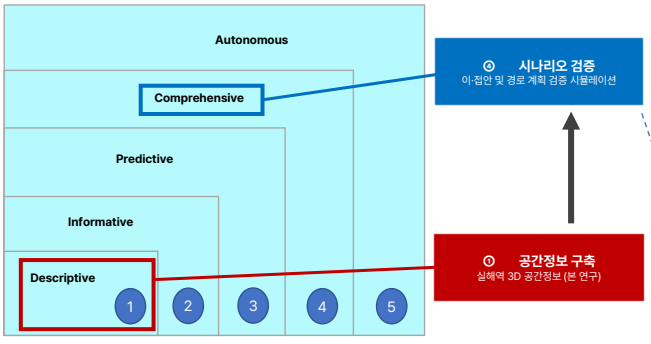

Five levels of digital twin development [Tomczak et al., 2025]

검증 시뮬레이션 현황

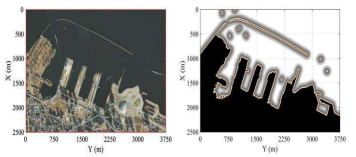

위성영상 기반 2D 격자 지도 자동 접안 시뮬레이션 환경

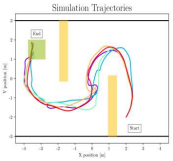

수조 배치 2D 자동 접안 시뮬레이션 환경

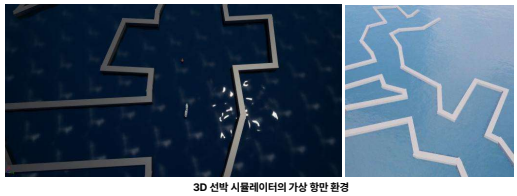

3D 선박 시뮬레이터의 가상 항만 환경

→ 2D 단순화·가상 항만 환경 중심

Reference
[1] Bitar, G., Martinsen, A. B., Lekkas, A. M., & Breivik, M. (2020). Trajectory planning and control for automatic docking of ASVs with full-scale experiments. IFAC-PapersOnLine, 53(2), 14488–14494.
[2] de Kruif, B. J., van Daalen, E. F. G., Cozijn, H., & Ijzerdoorn, G. (2024). Quay-to-quay mission with autonomous docking: A model-scale experimental validation. Journal of Marine Engineering & Technology, 23(5), 345–356.
[3] Tomczak, A., Stąpień, G., Kogut, T., Jedynak, Ł., Zaniewicz, G., Łącka, M., & Bodus-Olkowska, I. (2025). Development of a digital twin of the harbour waters and surrounding infrastructure based on spatial data acquired with multimodal and multi-sensor mapping systems. Applied Sciences, 15(1), 315.
[4] Lexau, S. J. N., Breivik, M., & Lekkas, A. M. (2023). Automated docking for marine surface vessels—A survey. IEEE Access, 11, 132324–132367.
[5] Han, S., et al. (2025). Hybrid trajectory planning and tracking for automatic berthing: A grid-search and optimal control integration approach. Ocean Engineering.
[6] Lesy, B., Herremans, S., Kerstens, R., Stocket, J., Daems, W., Marcelis, S., & Anwar, A. (2026). ASVSim (AirSim for Surface Vehicles): A high-fidelity simulation framework for autonomous surface vehicle research. IEEE Access.
[7] Dietrich, E., Gezer, E. C., Zhong, B., Arcak, M., Zamani, M., Skjetne, R., & Sørensen, A. J. (2025). Symbolic control for autonomous docking of marine surface vessels. IEEE CDC.
[8] Nguyen, C., Tran, M., Nguyen, T.-T., Fernando, N., Wang, L., & Nguyen, H. (2025). Simulation framework for addressing challenges in path planning evaluation for an autonomous surface vehicle. Journal of Marine Science and Application, 24(4), 816–828.

ORIS LAB

02 방어진항 데이터와 세션 간 지도 정합

- **실해역 형상을 반영한 디지털 트윈 공간정보 구축**
  - 서로 다른 좌표계와 관측 영역을 단일 좌표계로 통합
  - 울산 방어진항에서 자율운항선박 테스트베드 해양누리호를 이용하여 취득

Session 1

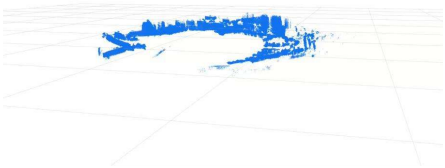

2026년 6월 10일
항만 내측 중심 관측
데이터 취득 시간: 약 18분

Session 2

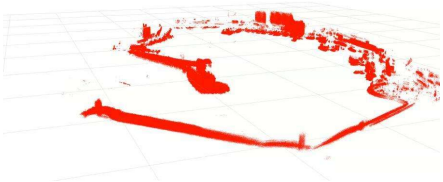

2026년 6월 10일
방파제 외측까지 관측
데이터 취득 시간: 약 22분

ORIS LAB

03 반복 안벽 구조에서의 오정합

- **항만은 비슷한 안벽이 반복 → 라이다 기하 특징(FPFH)만으로는 세션 간 동일 안벽을 식별하기 어려움**

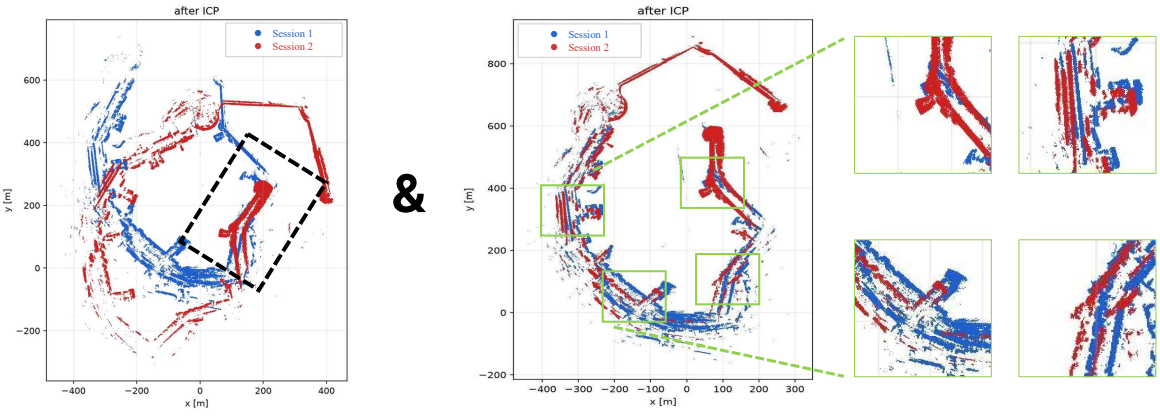

형태가 유사한 다른 안벽 구역으로 전역 오정합

확대 시 안벽이 이중으로 어긋나는 국소 오정합

ORIS LAB

04 카메라-라이다 기반 지도 정합 프레임워크

5

- 카메라-라이다 특징 결합과 서브맵 선정을 통한 세션 간 지도 정합

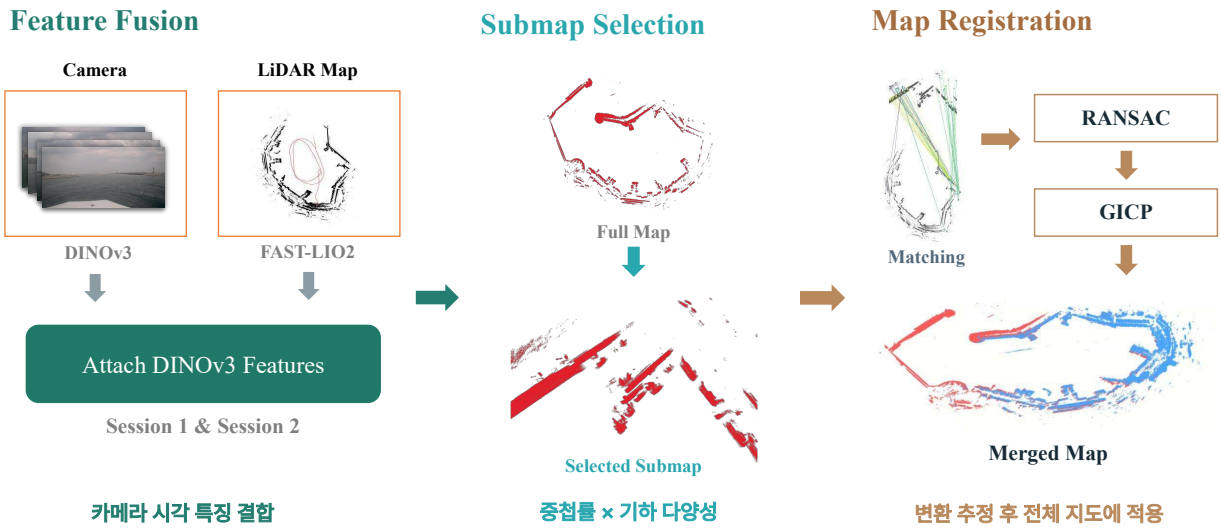

05 DINOv3 기반 카메라-라이다 특징 결합

6

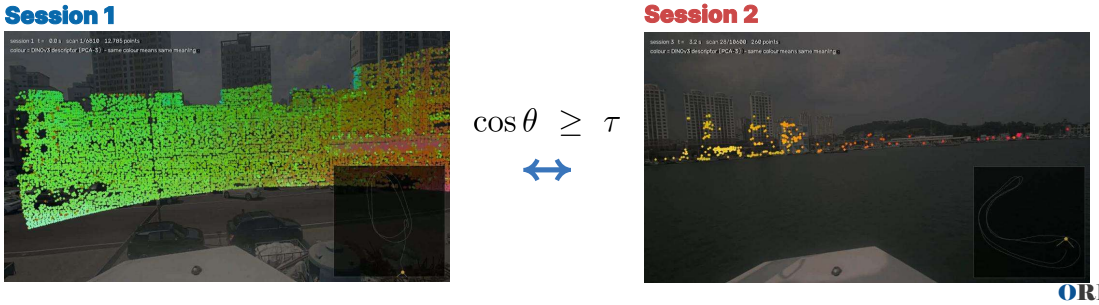

ORIS LAB

06 정합에 유리한 서브맵 선정

- **지도 전체를 다 비교해야 할까? — 정합에 유리한 영역만 먼저 고른다**
- **중첩률 × 기하 다양성으로 서브맵 자동 선정** $c^* = \arg\max_c \widetilde{D}(c)\,\widetilde{O}(c)$

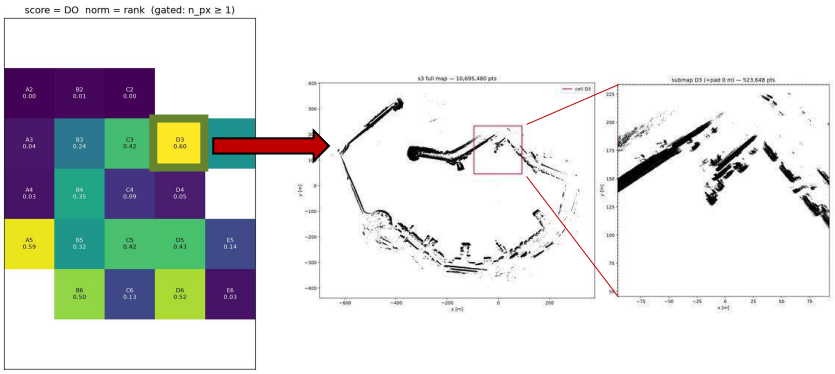

1. 중첩률

두 세션에 공통으로
관측된 영역

2. 기하 다양성

서로 다른 방향의
안벽과 모서리

선정된 서브맵에서 추정한 정합 변환을 전체 지도에 적용

ORIS LAB

07 디스크립터별 정합 결과 비교

- **같은 파이프라인에서 디스크립터만 바꾸면?**
- **기하 디스크립터(FPFH · GCL)는 비슷한 다른 안벽으로, DINOv3 이미지 특징은 같은 안벽으로 정합**

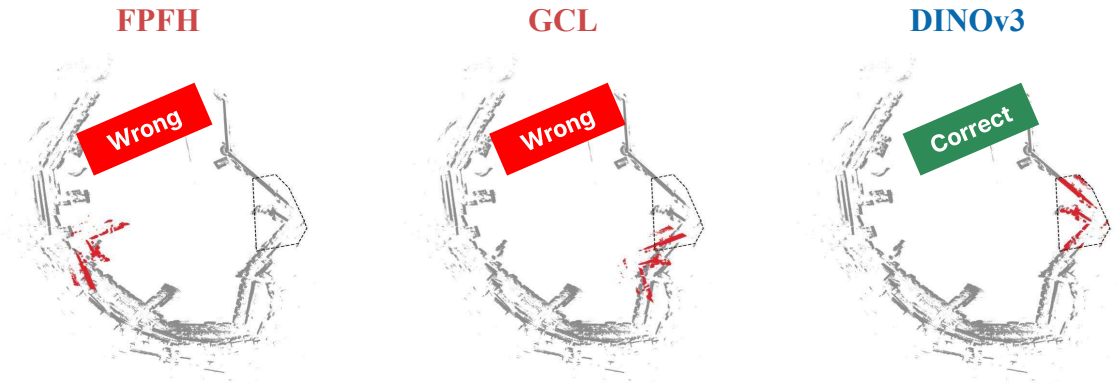

이미지 특징의 정합 유효성 검증

ORIS LAB

08 전체 지도 통합 및 정합 효율

- **부분 정합으로 전체 세션 지도를 통합 → 한 세션에서 부족했던 관측 영역을 다른 세션으로 보완**

안벽 관측 보완 ①

전체 세션 지도 정렬 결과

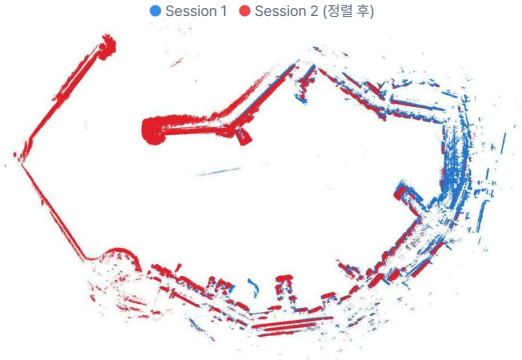

안벽 관측 보완 ②

추가 관측 예시 ③

단일 세션 정합 후

추가 관측 예시 ④

단일 세션 정합 후

GNSS 초기값 없이

1,940 s → 39.3 s

기준 방법 대비 약 2%

기준: GNSS 초기 정렬 + 전체 지도 GICP

ORIS LAB

09 결론 및 향후 계획

- **이 연구는**

라이다 형상만으로 구분되지 않는 항만 안벽을 카메라 DINOv3 특징으로 구분해

GNSS 초기값 없이 세션 간 지도를 정합하고, 서브맵 선별로 32분 → 39초로 단축

- **기여**
  - 반복 안벽 구분 — 카메라 시각 특징을 라이다 점에 부여
  - 연산 효율 — 중첩률 × 기하 다양성으로 정합에 유리한 서브맵 자동 선정
  - 프레임워크 제안 — 카메라·라이다 기반 항만 지도 정합 및 실해역 검증

- **향후 계획**
  - 정합 정확도 개선 및 추가 세션·타 항만 검증
  - 지도 규모·세션 수 증가에 따른 연산 시간·메모리 평가
  - DINOv3 사전 지도 기반 선박 위치·자세 추정 및 실시간성 검토

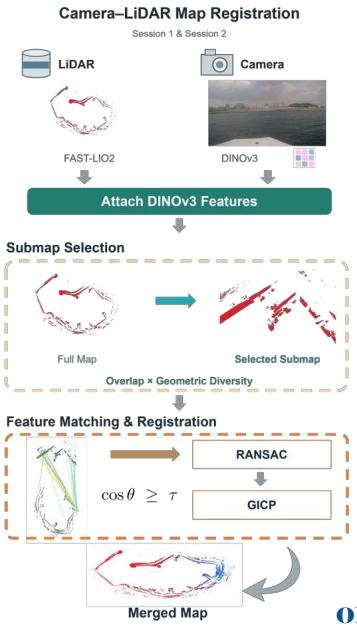

ORIS LAB

Thank You

Korea Research Institute of Ships & Ocean Engineering (KRISO)
University of Science and Technology (UST)

한국해양로봇기술연구회
2026 추계학술대회

A-P3

수중 로봇 연구를 위한 GPU 가속 소나 시뮬레이터 및 자동 데이터셋 생성

GPU-Accelerated Sonar Simulator and Automatic Dataset Generation for Underwater Robot Research

권희규 · 심현민 · 하재민 · 조한길

경북대학교

본문 55쪽 학술세션 A

수중 로봇 연구를 위한 GPU 가속 소나 시뮬레이터 및 자동 데이터셋 생성

권희규[1] · 심현민[2] · 하재민[2] · 조한길[2†]
[1]경북대학교, 로봇 및 스마트시스템 공학과
[2]경북대학교, 스마트 모빌리티 공학과

GPU-Accelerated Sonar Simulator and Automatic Dataset Generation for Underwater Robot Research

Heekyu Kweon[1], Hyeonmin Sim[2], Jaemin Ha[2] and Hangil Joe[2†]
[1]*Department of Robot and Smart System Engineering, Kyungpook National University*
[2]*Department of Smart Mobility Engineering, Kyungpook National University*

Key Words : Sonar simulation 소나 시뮬레이션, Forward-looking sonar 전방주사소나, Acoustic ray tracing, Synthetic training data 합성 학습 데이터, Sim-to-real transfer

Abstract : *Learning-based perception for underwater robots requires large sets of annotated sonar images, but real acoustic data are expensive to acquire and label. This paper presents a GPU-accelerated forward-looking sonar simulator developed as the sonar module of FURo-Sim (Field and Underwater Robotics Simulator) on Unreal Engine 5. A single rasterization pass forms the primary returns, recursive acoustic ray tracing adds multipath returns, and transmission loss, a beam pattern measured in a water tank, speckle, and crosstalk complete the image. Segmentation masks, 2-D bounding boxes, labeled 3-D point clouds, and 3-D bounding boxes are exported with every frame without manual labeling. Water-tank ablations against a high- and a low-resolution sonar showed that the modeled acoustic components and secondary reflections moved the synthetic images closer to the real ones. In our previous work, a detector trained only on synthetic images with these annotations reached an mAP_{50} of 0.813 on real sea data.*

1. 개요

수중에서는 빛이 탁도에 따라 빠르게 감쇠하므로 수중 로봇의 인지 능력은 소나에 크게 의존한다[1]. 전방주사소나(forward-looking sonar, FLS) 영상은 해상도가 낮고 스페클과 다중경로 반사가 섞여 있으며 시점에 따라 표적의 모양이 크게 달라진다. 이 때문에 학습 기반 인식 모델이 널리 연구되고 있으나[2], 실제 소나 데이터는 수집 비용이 크고 픽셀 단위 레이블을 사람이 직접 그려야 한다.

시뮬레이터는 이 문제의 대안이 될 수 있지만, 실제 소나의 영상 형성 과정을 재현하면서 정답 레이블을 자동으로 생성해야 한다. 기존 시뮬레이터 중 HoloOcean[3]은 다중경로를 한 번의 추가 반사로만 다루고, OceanSim[4]은 1차 반사만 추적하며, ACSim[5]은 재귀적 ray tracing을 오프라인으로 수행한다.

본 논문에서는 Unreal Engine 5(UE5) 기반 해양 로봇 시뮬레이터 FURo-Sim(Field and Underwater Robotics Simulator)의 소나 모듈로, 재귀적 다중경로와 실시간 동작을 함께 갖춘 GPU 가속 FLS 시뮬레이터를 소개한다(그림 1). 고해상도 소나 DIDSON 300m과 저해상도 소나 Oculus M750d(이하 DIDSON, Oculus)의 수조 영상으로 음향 요소와 반사 차수에 따른 시뮬레이션 영상을 검증하고, 시뮬레이터의 자동 주석을 활용한 Sim-to-Real 적용 사례를 소개한다.

* 권희규 : 경북대학교 로봇 및 스마트시스템 공학과, *heekyu8421@knu.ac.kr*
* 심현민, 하재민 : 경북대학교 스마트 모빌리티 공학과
† 조한길(교신저자) : 경북대학교 스마트 모빌리티 공학과 053-950-4569, *hgjoe@knu.ac.kr*

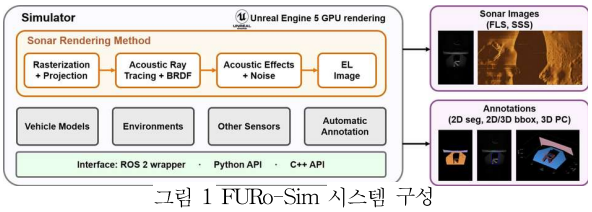

그림 1 FURo-Sim 시스템 구성

2. 소나 시뮬레이션 방법

소나 영상은 그림 1과 같이 만들어진다. UE5의 렌더링 과정에서 1차 반사를 계산하고, 별도의 acoustic ray tracing 모듈이 다중경로 성분을 더한 뒤, 센서 효과 모델을 거쳐 최종 영상이 된다.

2.1 GPU 래스터화 기반 1차 반사

각 영상 셀에 대응하는 첫 반사면을 ray로 찾는 대신, 소나 위치에서 장면을 한 번 렌더링한다. 이때 커스텀 픽셀 셰이더로 G-buffer에 각 표면점의 거리, 법선, 의미 레이블을 저장한다. 표면점의 에코 세기는 재질의 반사율과 거칠기에 따라 Lambert 확산 성분과 Phong 정반사 성분의 합으로 계산하며[6], 표면점은 거리와 방위각에 따라 소나 영상 셀로 투영된다. 또한 이 G-buffer와 장면의 객체 정보로부터 분할 마스크, 2차원 경계 상자, 레이블이 부여된 3차원 점군, 3차원 경계 상자를 매 프레임 함께 출력한다. 2차원 경계 상자는 표적의 하이라이트만 감싸는 것과 음향 그림자까지 포함하는 것을 모두 출력한다.

2.2 Acoustic Ray Tracing 기반 다중경로

물체와 바닥 사이의 2차 이상 반사는 래스터화만으로 표현할 수

한국해양로봇기술연구회 2026년 추계학술대회 (2026. 11. 13(금) / 부산항국제전시컨벤션센터(BPEX))

없으므로, 각 1차 반사점에서 시작하는 재귀적 acoustic ray tracing을 추가하였다. ray가 표면과 만날 때마다 반사 에너지를 계산하고, 다음 진행 방향은 정반사 방향 또는 이를 가우시안 분포의 각도만큼 흩뜨린 확산 표본으로 정한다. 이 과정을 사용자가 지정한 최대 반사 차수 k까지 반복한다.

각 반사점의 에코는 입사 경로를 되돌아가는 후방산란과 소나로 곧바로 돌아가는 정반사로 나누어 계산하고, 왕복 경로 길이의 절반에 해당하는 거리 셀에 기록한다. 따라서 다중경로 에코가 실제 영상과 같은 거리에 나타난다.

2.3 센서 효과 모델

음파는 구면 확산과 흡수에 의해 감쇠하며, 전달 손실(transmission loss, TL)은 식 (1)과 같다[7].

$$\mathrm{TL}(r) = 20\log_{10} r + \alpha r \tag{1}$$

여기서 r은 단방향 거리(m), α는 흡수 계수(dB/m)이다. α는 주파수와 수질에 따라 크게 달라지므로 사용자가 직접 설정한다.

빔 패턴은 두 소나에 대해 직접 측정하였다. 각 소나를 알려진 높이와 기울기로 설치하여 평평한 수조 바닥을 촬영하고, 바닥 반사에서 확산 반사 항과 전달 손실을 나누어 제거한 뒤 남은 세기를 수평·수직 각도에 대한 분포로 재투영하였다. 측정 결과는 식 (2)와 같이 수평 성분과 수직 성분의 곱으로 표현하고, 각 성분을 가우시안 main lobe에 필요한 경우 대칭 side lobe 한 쌍을 더한 형태로 근사하였다. side lobe는 Oculus의 수평 성분에만 필요하였다.

$$g(\theta,\phi) = g_h(\theta) \cdot g_v(\phi) \tag{2}$$

여기서 θ와 ϕ는 각각 수평각과 수직각이다.

잡음은 두 소나의 원영상에서 공통으로 관찰되는 스페클과 크로스토크를 다루었다. 스페클은 각 셀에서 반사 차수별 에코 중 하나를 기여도에 비례하는 확률로 선택하고, 여기에 평균이 1인 감마 분포 난수를 곱하여 만든다. 곱셈 잡음만으로는 신호가 없는 셀이 0으로 남으므로 Rayleigh 분포 잡음을 더하였다. 크로스토크는 강한 반사가 같은 거리의 인접 빔으로 새어 나가는 현상으로, 빔 사이 거리에 따라 지수적으로 감소하도록 모델링하였다. 새어 나가는 빔은 각 소나의 송신 방식을 따라 DIDSON은 네 번째 빔마다, Oculus는 바로 옆 빔으로 두었다.

3. 수조 실험 검증

3.1 실험 환경

실제 영상은 2.96 × 1.19 × 1.50 m 크기의 실내 수조에서 취득하였다. 두 소나를 높이 1.15 m에 각각 25°(DIDSON)와 20°(Oculus) 기울여 설치하고, 벽돌(0.19 × 0.15 × 0.39 m) 세 개를 화살촉 모양으로 놓은 표적을 촬영하였다. 수조와 표적은 실측 치수로 CAD 장면을 구성하였고, 표적의 음향 재질 변수는 실제 반사에 맞추어 조정하였다. 영상 유사도는 화소 수준의 PSNR과 구조 수준의 MS-SSIM[8], LPIPS[9]로 평가하였다.

3.2 음향 요소와 반사 차수의 영향

표 1의 위쪽은 기하 정보만 사용한 Base 구성에 전달 손실(TL), 빔 패턴(BP), 스페클(SN), 크로스토크(CT)를 차례로 더한 결과이며, 이때 acoustic ray tracing은 최대 반사 차수 k = 3과 확산 표본(D)을 사용하였다. 그림 2는 각 단계의 영상이다. 전체 모델은 두 소나 모두에서 가장 좋은 LPIPS를 보였다. DIDSON에서는 전달 손실과 빔 패턴이 개선의 대부분을 차지하였고, Oculus에서는 잡음 모델을 더하기 전까지 지표가 거의 변하지 않았다. 개선 폭은 DIDSON에서 더 컸는데, 좁은 시야각에서 표적이 영상의 많은 부분을 차지하여 Base 영상과 실제 영상의 차이가 컸기 때문이다.

표의 아래쪽은 전체 모델에서 최대 반사 차수를 바꾸고, 2차와 3차에서는 확산 표본의 사용 여부를 비교한 결과이다. k = 3+D는 +CT와 같은 구성이다. 2차 반사를 더할 때 두 소나 모두 개선 폭이 가장 컸고, 3차 반사와 확산 표본에 따른 변화는 측정 잡음 수준이었다. 따라서 이 장면의 다중경로는 2차 반사가 지배적이다.

표 1 음향 요소와 최대 반사 차수에 따른 영상 유사도(화살촉 표적, D는 확산 표본 사용. PSNR과 MS-SSIM은 높을수록, LPIPS는 낮을수록 실제 영상에 가까움)

구성	DIDSON (고해상도)			Oculus (저해상도)		
	PSNR	MS-SSIM	LPIPS	PSNR	MS-SSIM	LPIPS
Base	25.53	0.774	0.099	29.10	0.714	0.226
+TL	26.58	0.796	0.082	29.09	0.690	0.222
+BP	28.16	0.867	0.069	29.07	0.684	0.222
+SN	28.67	0.873	0.067	30.67	0.815	0.187
+CT	28.65	0.879	0.059	30.66	0.813	0.185
k = 1	27.64	0.820	0.103	30.35	0.797	0.209
k = 2	28.66	0.872	0.067	30.65	0.813	0.185
k = 2+D	28.47	0.867	0.068	30.65	0.813	0.185
k = 3	28.66	0.872	0.068	30.66	0.813	0.184
k = 3+D	28.65	0.879	0.059	30.66	0.813	0.185

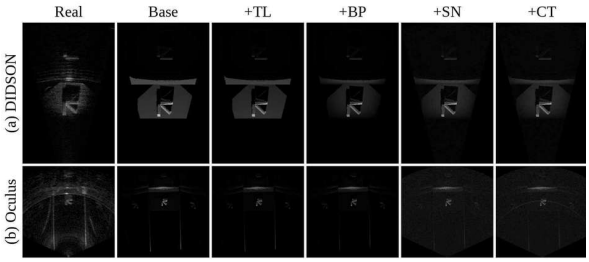

그림 2 화살촉 표적의 실제 영상(Real)과 음향 요소를 차례로 더한 시뮬레이션 영상: (a) DIDSON, (b) Oculus

4. Sim-to-real 적용

시뮬레이터가 출력하는 주석은 이전 연구[10]에서 Sim-to-Real 과제에 활용되었다. 해당 연구에서는 시뮬레이션 FLS 영상과 자동으로 생성된 하이라이트 및 음향 그림자 주석만으로 YOLO11 탐지기를 학습하고, 탐지 결과를 AUV 포즈 그래프 최적화의 랜드마크 관측으로 사용하였다. 실제 연안 해역 데이터에서 합성 데이터만으로 학습한 탐지기는 mAP_{50} 0.813을 보였고, 전체 시스템은 추측 항법(dead reckoning)의 위치 추정 오차를 15.4% 줄였다.

5. 결론

본 논문에서는 GPU 래스터화와 재귀적 acoustic ray tracing, 실측 빔 패턴, 스페클과 크로스토크 잡음 모델을 결합하고 네 종류의 주석을 함께 출력하는 실시간 FLS 시뮬레이터를 소개하였다. 수조 실험에서 각 음향 요소와 2차 반사는 시뮬레이션 영상을 실제 영상에 가깝게 하였으며, 시뮬레이터의 자동 주석은 합성 데이터만으로 학습한 탐지기를 실해역에 적용하는 데 활용되었다. 향후 다양한 표적과 해역으로 검증을 넓힐 계획이다.

Acknowledgement

이 논문은 2025년도 정부(과학기술정보통신부)의 재원으로 정보통신기획평가원의 지원을 받아 수행된 연구 결과임 (No.RS-2025-02217613). 또한, 이 논문은 2026년도 해양수산부 재원으로 해양수산과학기술진흥원의 지원을 받아 수행된 연구임 (RS-2026-25540332, 해양수산융합형전문인력양성사업 강원·경북씨 그랜트).

참 고 문 헌

[1] J. S. Jaffe, “Computer Modeling and the Design of Optimal Underwater Imaging Systems,” *IEEE Journal of Oceanic*

Engineering, vol. 15, no. 2, pp. 101–111, 1990.

[2] Y. Steiniger, D. Kraus, and T. Meisen, "Survey on Deep Learning Based Computer Vision for Sonar Imagery," *Engineering Applications of Artificial Intelligence*, vol. 114, Art. no. 105157, 2022.

[3] E. Potokar et al., "HoloOcean: A Full-Featured Marine Robotics Simulator for Perception and Autonomy," *IEEE Journal of Oceanic Engineering*, vol. 49, no. 4, pp. 1322–1336, 2024.

[4] J. Song, H. Ma, O. Bagoren, A. V. Sethuraman, Y. Zhang, and K. A. Skinner, "OceanSim: A GPU-Accelerated Underwater Robot Perception Simulation Framework," in *2025 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS)*, 2025, pp. 1526–1533.

[5] Y. Wang, Y. Ji, H. Tsuchiya, J. Ota, H. Asama, and A. Yamashita, "ACSim: A Novel Acoustic Camera Simulator With Recursive Ray Tracing, Artifact Modeling, and Ground Truthing," *IEEE Transactions on Robotics*, vol. 41, pp. 2970–2989, 2025.

[6] M. D. Aykin and S. S. Negahdaripour, "Modeling 2-D Lens-Based Forward-Scan Sonar Imagery for Targets With Diffuse Reflectance," *IEEE Journal of Oceanic Engineering*, vol. 41, no. 3, pp. 569–582, 2016.

[7] R. J. Urick, *Principles of Underwater Sound*, 3rd ed.. New York, NY, USA: McGraw-Hill, 1983.

[8] Z. Wang, E. P. Simoncelli, and A. C. Bovik, "Multiscale Structural Similarity for Image Quality Assessment," in *The Thirty-Seventh Asilomar Conference on Signals, Systems & Computers, 2003*, 2003, pp. 1398–1402.

[9] R. Zhang, P. Isola, A. A. Efros, E. Shechtman, and O. Wang, "The Unreasonable Effectiveness of Deep Features as a Perceptual Metric," in *2018 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 2018, pp. 586–595.

[10] J. Ha, H. Kweon, H. Sim, S.-C. Yu, and H. Joe, "AUV Pose Correction via Underwater Object Recognition Using Synthetic Data," *Intelligent Service Robotics*, vol. 19, no. 4, Art. no. 61, 2026.

한국해양로봇기술연구회
2026 추계학술대회

A-P4

가상 데이터 학습 기반 수중 로봇 위치 추정

Underwater Robot Localization Based on Learning from Synthetic Data

하재민 · 조한길

경북대학교 수중 및 필드로봇 연구실

가상 데이터 학습 기반 수중 로봇 위치 추정

하재민 · 조한길
경북대학교, 수중 및 필드로봇 연구실

Underwater Robot Localization Based on Learning from Synthetic Data

Jae-Min Ha, Hangil Joe
Field and Underwater Robotics Lab., Kyungpook National University

Key Words : Forward-looking sonar, Bounding box, Semantic segmentation, Synthetic data, Underwater robot

Abstract : *This paper describes path correction of underwater robots using forward-looking sonar images. Two approaches are considered: object detection with class-labeled bounding boxes, and semantic segmentation that separates objects from the seabed. Sonar images and labels are generated in a simulator, so that training data can be obtained without manual annotation. The detection-based approach was applied to a sea experiment and reduced the position error of dead reckoning, and the segmentation-based approach was verified in simulation, reducing the position error on all four routes. The segmentation-based approach is planned to be validated in sea experiments.*

1. 서 론

수중 로봇은 GPS 신호를 받을 수 없으므로 DVL과 IMU를 이용한 추측항법으로 위치를 추정한다. 추측항법은 속도와 방위의 작은 오차가 적분되어 운용 시간에 따라 위치 오차가 누적되며, USBL과 같은 음향 위치 측정 장비는 별도의 설치가 필요하고 갱신 주기가 길며 측정 잡음이 크다. 따라서 로봇이 주변 환경을 관측하여 누적된 위치 오차를 스스로 보정하는 방법이 필요하다. 탁한 수중에서는 광학 카메라의 관측 거리가 짧으므로, 탁도와 관계없이 수 m 이상의 영상을 얻는 전방 주사 소나(FLS)가 주변 관측에 널리 사용된다. 그러나 소나 영상은 스펙클 잡음이 많고 해상도가 낮으며, 같은 물체라도 관측 시점에 따라 반사 강도와 음향 그림자의 모양이 달라지므로 소나 영상의 물체 인식에는 학습 기반 방법이 사용된다. 학습 기반 방법은 많은 양의 라벨된 영상이 필요하지만, 실해역 소나 영상은 수집 비용이 크고 물체의 경계가 뚜렷하지 않아 수작업으로 라벨을 붙이기 어렵다. AirSim 기반 소나 시뮬레이터[1]를 이용하면 물체의 종류와 배치, 로봇의 자세를 바꾸어 가며 가상 영상을 생성하고, 렌더링 정보로부터 라벨을 자동으로 만들 수 있다.

본 논문은 가상 소나 영상으로 학습한 물체 인식 기반 방법과 의미론적 분할 기반 방법을 소개하고, 각각 실해역과 시뮬레이션에서 수중 로봇의 위치 보정에 적용한 결과를 제시한다.

2. 선행 연구

FLS를 이용한 위치 보정 연구로는 프레임 사이의 영상을 정합하여 로봇의 이동량을 구하는 방법[2]과, 영상의 특징을 이용하여 프레임 사이의 제약을 구하는 방법[3]이 있다. 소나 영상의 물체 인식에는 물체를 사각형으로 검출하는 방법과 화소 단위로 분할하는 방법이 사용된다. El-Mihoub 등[4]은 YOLOv8로 FLS 영상의 물체를 Fig. 1과 같이 바운딩 박스로 검출하였으며, Singh와 Valdenegro-Toro[5]는 수조에서 취득한 FLS 영상에 화소 단위 라벨을 부여한 데이터셋을 구축하였다(Fig. 2)

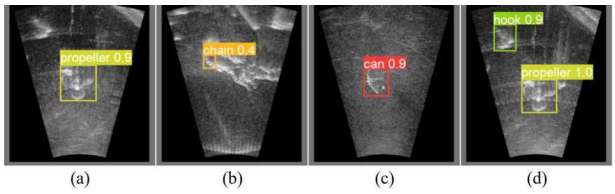

Fig. 1. Object detection results on FLS images [4]

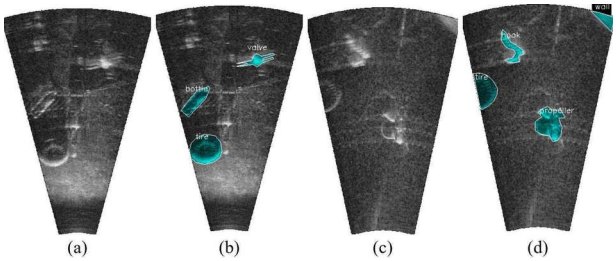

Fig. 2. FLS images ((a), (c)) and pixel-wise segmentation labels ((b), (d)) [5]

3. 제안 방법

3.1 물체 인식 기반 방법

물체 인식 기반 방법은 소나 영상에서 물체를 클래스별로 구별하여 바운딩 박스로 표현하는 방법이다. 서로 다른 프레임에서 같은 클래스의 물체를 대응시켜 로봇의 상대 위치를 구하고, 이를 추측항법과 함께 포즈 그래프에 반영하여 위치 보정에 활용한다. 검출기로는 YOLO11[6]를 가상 영상 718장으로만 학습하여 사용하며, [7]에서는 이 검출기를 실해역 영상에 적용하여 Fig. 3과 같이 물체를 검출하였다.

* 하재민 : 경북대학교 053-950-4569, *spiamin99@knu.ac.kr*
* 조한길 : 경북대학교 053-950-4569, *hgjoe@knu.ac.kr*

한국해양로봇기술연구회 2026년 추계학술대회 (2026. 11. 13(금) / 부산항국제전시컨벤션센터)

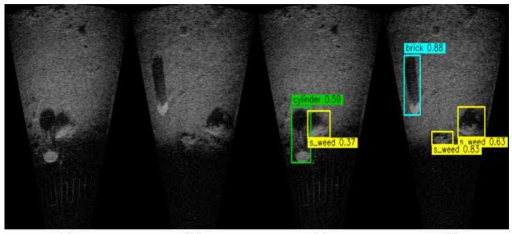

Fig. 3. Real FLS images ((a), (b)) and object detection results ((c), (d)) [7]

3.2 의미론적 분할 기반 방법

의미론적 분할 기반 방법은 소나 영상에서 물체와 해저면을 화소 단위로 분할하는 방법이다. 분할 결과로부터 프레임 사이의 상대 변위를 구하고, 이를 포즈 그래프에 반영하여 위치 보정에 활용한다. 분할 모델로는 UNet++[8]를 가상 영상 2,004장으로만 학습하여 사용하며, Fig. 4는 시뮬레이션 소나 영상 두 장과 학습한 UNet++의 분할 결과 예시이다.

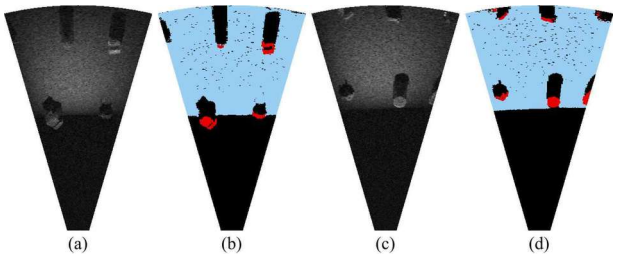

Fig. 4. Simulated sonar images ((a), (c)) and UNet++ segmentation results ((b), (d); light blue: seabed, red: object)

4. 실험 결과

물체 인식 기반 방법은 실해역에서 검증하였다. 연안 해역의 약 10 m × 7 m 구간에 벽돌, 원통, 수초가 있는 환경에서 AUV가 FLS, DVL, IMU, USBL 자료를 함께 취득하였으며, 이상값을 제거한 USBL 위치를 참값으로 사용하였다. 위치 오차(RMSE)는 추측항법 0.716 m에서 0.604 m로 약 15 % 감소하였으며, Fig. 5는 [7]에서 보정한 경로이다.

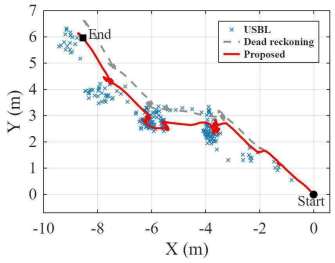

Fig. 5. Corrected path of the detection-based method in a sea experiment [7]

의미론적 분할 기반 방법은 시뮬레이션에서 검증하였다. 평평한 해저면에 물체 16개를 배치하고 선수각을 고정한 채 세 줄을 왕복하는 경로 4개를 생성하여 경로마다 영상 85장을 취득하였으며, 경로마다 임의의 위치에서 시작하고 DVL의 배율 오차, 장착 방위 오차와 잡음을 무작위로 주었다. 참값 위치를 기준으로 한 위치 오차(RMSE)는 Table 1과 같이 평균 약 63 % 감소하였으며, Fig. 6은 각 경로의 결과이다.

Table 1. Position error (RMSE) in simulation

Route	1	2	3	4	Mean
DR (m)	0.392	0.353	0.284	0.184	0.303
Seg. (m)	0.067	0.134	0.153	0.073	0.107
Reduction	83 %	62 %	46 %	60 %	63 %

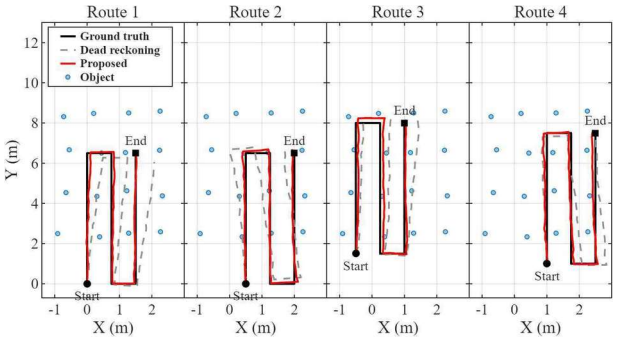

Fig. 6. Corrected paths (random start and DVL errors)

5. 결 론

본 논문에서는 가상 소나 영상으로 학습한 물체 인식 기반 방법과 의미론적 분할 기반 방법을 이용한 수중 로봇 위치 추정 방법을 제안한다. 물체 인식 기반 방법은 실해역 데이터로 검증하였고, 의미론적 분할 기반 방법은 시뮬레이션을 통해 검증하였다. 향후 의미론적 분할 기반 방법을 실해역에서 검증할 계획이다.

Acknowledgement

이 논문은 2025년도 정부(과학기술정보통신부)의 재원으로 정보통신기획평가원의 지원을 받아 수행된 연구 결과임 (No.RS-2025-02217613). 또한, 이 논문은 2026년도 해양수산부 재원으로 해양수산과학기술진흥원의 지원을 받아 수행된 연구임 (RS-2026-25540332, 해양수산융합형전문인력양성사업 강원·경북 씨그랜트).

참 고 문 헌

[1] S. Shah, D. Dey, C. Lovett, A. Kapoor, "AirSim: High-fidelity visual and physical simulation for autonomous vehicles", Field and Service Robotics, pp. 621-635, 2018.

[2] N. Hurtós, D. Ribas, X. Cufí, Y. Petillot, J. Salvi, "Fourier-based registration for robust forward-looking sonar mosaicing in low-visibility underwater environments", Journal of Field Robotics, Vol. 32, No. 1, pp. 123-151, 2015.

[3] E. Westman, M. Kaess, "Degeneracy-aware imaging sonar simultaneous localization and mapping", IEEE Journal of Oceanic Engineering, Vol. 45, No. 4, pp. 1280-1294, 2020.

[4] T. A. El-Mihoub, A. El Gadi, L. Nolle, F. Stahl, "On object detection and explainability with sonar imagery", Proc. IEEE MI-STA, pp. 779-786, 2024.

[5] D. Singh, M. Valdenegro-Toro, "The marine debris dataset for forward-looking sonar semantic segmentation", Proc. IEEE/CVF ICCV Workshops, pp. 3734-3742, 2021.

[6] G. Jocher, J. Qiu, "Ultralytics YOLO11", Version 11.0.0, 2024. https://github.com/ultralytics/ultralytics

[7] J. Ha, H. Kweon, H. Sim, S.-C. Yu, H. Joe, "AUV pose correction via underwater object recognition using synthetic data", Intelligent Service Robotics, Vol. 19, No. 4, 61, 2026.

[8] Z. Zhou, M. M. R. Siddiquee, N. Tajbakhsh, J. Liang, "UNet++: A nested U-Net architecture for medical image segmentation", Proc. DLMIA, pp. 3-11, 2018.

한국해양로봇기술연구회
2026 추계학술대회

A-P5

해저면 근접 운용을 위한 제한된 화각의 3차원 멀티빔 음향측심기 기반 오도메트리 추정 기법

Odometry Estimation Using a Limited-FOV 3D Multibeam Sonar for Near-Bottom Operations

양동원 · 홍성훈 · 윤석민

계명대학교 / 한화시스템

해저면 근접 운용을 위한 제한된 화각의 3차원 멀티빔 음향측심기 기반 오도메트리 추정 기법

양동원[1] · 홍성훈[1] · 윤석민[2]
[1]계명대학교, 인식기반 지능로봇 연구실
[2]한화시스템, Smart Vessel 사업센터

Odometry Estimation Using a Limited-FOV 3D Multibeam Sonar for Near-Bottom Operations

Dongwon Yang[1], Seonghun Hong[1], Sukmin Yoon[2]
[1]*Robotic Intelligence & Perception Lab., Keimyung University, Daegu, Korea*
[2]*Smart Vessel Business Center, Hanwha Systems Co., Ltd, Seoul, Korea*

Key Words : Multibeam echosounder 멀티빔 음향측심기, Underwater odometry 수중 오도메트리, Near-bottom operation 해저면 근접 운용, Limited field of view 제한된 화각, Point cloud registration 점군 정합

Abstract : *High-resolution 3D multibeam echosounders provide dense 3D point clouds from a single ping, offering a viable sensing modality for underwater odometry estimation. However, during near-bottom operations, their limited field of view results in low scan overlap, while most acoustic returns originate from locally planar seafloor regions. These characteristics pose significant challenges to direct point cloud registration. This study proposes a 6-DOF odometry estimation method that exploits the complementary geometric information provided by the local seafloor and non-planar terrain without relying on auxiliary navigation sensors. The proposed method first estimates vertical translation, roll, and pitch from the geometric relationship between consecutive seafloor planes obtained through a two-stage estimation process. The remaining horizontal translation and yaw are then estimated by registering non-planar terrain features against a 2D truncated distance field map. Experimental results using data collected in a real sea environment demonstrate that the proposed method improves overall odometry estimation performance compared with the state-of-the-art point cloud registration methods and produces more consistent 3D maps.*

1. 서론

무인수중운동체(UUV)의 항법과 지도 작성을 위해서는 6자유도 운동을 정확하게 추정해야 한다. 수중에서는 GPS를 사용할 수 없고, 카메라나 라이다(LiDAR) 같은 광학 센서도 빛의 감쇠와 산란으로 성능이 제한되므로 음향 센서가 주로 사용된다. 특히 고해상도 3차원 멀티빔 음향측심기(MBES)는 단일 핑으로 조밀한 3차원 점군을 획득할 수 있어 수중 오도메트리(odometry) 추정에 활용할 수 있다. 그러나 3차원 MBES는 라이다에 비해 화각이 제한적이며, 이 특성은 UUV가 해저면 가까이에서 운용되는 임무에서 두드러진다. 해저면에 가까워질수록 연속 스캔 간 중첩 영역이 줄고, 반사점의 대부분이 평탄한 해저면에 분포하며, 음향 잡음과 이상치도 더해지므로 점 대응관계에 의존하는 일반적인 점군 정합 기법으로는 안정적인 운동 추정이 어렵다. 기존 MBES 기반 위치 추정 방법은 추측항법 등 보조 항법 정보로 누적한 부분 수심 지도 간 정합에 의존한다.

본 연구에서는 보조 항법 센서 없이 제한된 화각의 3차원 MBES 계측치만으로 해저면 근접 운용 중인 UUV의 6자유도 오도메트리를 추정하는 기법을 제안한다. 제안 기법은 국소 해저면과 비평면 지형이 제공하는 상보적인 기하학적 정보로 운동 추정 문제를 분리한다. 2단계 해저면 평면 추정으로 해저면에 수직한 병진 운동과 roll, pitch를, 비평면 지형 특징을 누적한 2차원 절단 거리장(TDF) 과의 스캔-대-지도(scan-to-map) 정합으로 평면 내 병진 운동과 yaw를 추정한다.

* 양동원 : 계명대학교 053-580-5354, *y.dongwon@kmu.kr*
* 홍성훈 : 계명대학교 053-580-5354, *sh.hong@kmu.ac.kr*

2. 제안된 3차원 MBES 기반 오도메트리 추정 기법

UUV의 상태벡터 $\mathbf{x}$를 식 (1)과 같이 정의하고, 수직 운동 성분 $(z,\ \phi,\ \theta)$와 수평 운동 성분 $(x,\ y,\ \psi)$를 서로 다른 기하학적 정보로부터 독립적으로 추정한다.

$$\mathbf{x}=[x\ \ y\ \ z\ \ \phi\ \ \theta\ \ \psi]^{\top} \tag{1}$$

2.1 해저면 평면 기반 수직 운동 추정

스캔 k의 점군 P_k에서 각 점의 반경 내 이웃으로 공분산 행렬을 계산하고, 최소 고유값의 고유벡터를 점의 법선으로 정의한다. 해저면은 수평에 가까우므로 법선의 수직 성분이 큰 상위 n개의 점들로 해저면 후보점을 선정한다.

선정된 후보점들의 법선으로부터 스캔 단위 해저면 법선을 추정하기 위해 다음과 같은 법선 산포 행렬을 구성한다.

$$\mathbf{C}=\frac{1}{n}\sum_{i=1}^{n}\mathbf{n}_i^{c}\left(\mathbf{n}_i^{c}\right)^{\top} \tag{2}$$

$\mathbf{C}$의 최대 고유값의 고유벡터를 초기 해저면 법선 $\mathbf{N}_k^{c}$로, 후보점 평균 위치 $\bar{\mathbf{p}}_k^{c}$와의 내적을 평면 오프셋 d_k^{c}로 정의한다. 초기 평면의 신뢰성은 $\mathbf{C}$의 고유값 $\lambda_1 \geq \lambda_2 \geq \lambda_3$로 정의한 법선 집중도 L과 산포도 S로 평가한다.

한국해양로봇기술연구회 2026년 추계학술대회 (2026. 11. 13(금) / 부산항국제전시컨벤션센터(부산))

표 1. TCM 및 압력계 계측값에 대한 수직 운동 성분 추정값의 RMSE

Table 1. RMSE of the estimated vertical motion components with respect to the TCM and pressure sensor measurements.

Methods	Z (m)	Roll (°)	Pitch (°)
KISS-ICP	3.43	7.86	12.84
GenZ-ICP	4.51	9.73	16.58
Proposed	0.06	0.98	1.32

$$L=\frac{\lambda_1-\lambda_2}{\lambda_1},\quad S=\frac{\lambda_3}{\lambda_1} \tag{3}$$

$L>\tau_L$과 $S<\tau_S$를 모두 만족하면 초기 평면을 채택하고, 하나라도 만족하지 못하면 이전 스캔의 초기 평면을 유지한다. 이후 초기 평면과의 수직 거리가 τ_r 미만인 점을 다시 선정하고, 그 공분산 행렬과 평균 위치로 해저면 법선 $\mathbf{N}_k^{\mathrm{f}}$와 오프셋 d_k^{f}를 정밀하게 재추정한다. 연속된 두 스캔에서 동일한 국소 해저면이 관측된다고 가정하면, 스캔 k에서 $k-1$로의 상대변환 $\Delta\mathbf{T}_k=(\Delta\mathbf{R}_k,\ \Delta\mathbf{t}_k)$에 대해 다음 관계가 성립한다.

$$\mathbf{N}_{k-1}^{\mathrm{f}}=\Delta\mathbf{R}_k\mathbf{N}_k^{\mathrm{f}},\quad d_{k-1}^{\mathrm{f}}=d_k^{\mathrm{f}}+\left(\mathbf{N}_{k-1}^{\mathrm{f}}\right)^{\top}\Delta\mathbf{t}_k \tag{4}$$

$\Delta\mathbf{R}_k$는 두 법선을 일치시키는 최소 회전으로 계산하여 $(\phi,\ \theta)$를 얻고, 오프셋 관계에서 결정되는 법선 방향 변위 $\left(\mathbf{N}_{k-1}^{\mathrm{f}}\right)^{\top}\Delta\mathbf{t}_k=d_{k-1}^{\mathrm{f}}-d_k^{\mathrm{f}}$를 수평에 가까운 해저면 가정하에 z에 대응시킨다. $(x,\ y,\ \psi)$는 해저면 평면 정보만으로 추정할 수 없다.

2.2 비평면 지형 특징 기반 수평 운동 추정

재추정한 해저면 평면과의 수직 거리가 임계값 τ_{f}보다 큰 점을 지형 특징점 집합 F_k로 추출한다.

$$F_k=\left\{\mathbf{p}_i\in P_k\ \middle|\ \left|\left(\mathbf{N}_k^{\mathrm{f}}\right)^{\top}\mathbf{p}_i-d_k^{\mathrm{f}}\right|>\tau_{\mathrm{f}}\right\} \tag{5}$$

지형 특징점은 수평면에 해상도 δ의 균일 격자로 정의한 2차원 TDF 지도에 누적한다. 각 격자에는 가장 가까운 점유 격자까지의 유클리드 거리를 τ_{d}로 절단하여 저장하고, 임의 위치의 TDF 값은 쌍선형 보간으로, 기울기는 중앙 차분으로 계산한다. TDF는 점 대응관계 없이 특징점 분포를 연속적인 거리장으로 표현하므로 잡음과 불균일한 점 분포의 영향을 줄인다. 수직 운동 성분을 고정한 상태에서 수평 운동 파라미터 $\boldsymbol{\eta}=[x\ y\ \psi]^{\top}$는 변환된 특징점 위치 $\mathbf{u}_i(\boldsymbol{\eta})$에서의 TDF 값 $D(\cdot)$의 제곱합을 최소화하도록 추정한다.

$$\hat{\boldsymbol{\eta}}=\underset{\boldsymbol{\eta}}{\operatorname{argmin}}\sum_i D(\mathbf{u}_i(\boldsymbol{\eta}))^2 \tag{6}$$

식 (6)은 Gauss-Newton 방법으로 반복 최소화하며, TDF 지도는 위치 또는 자세 변화가 임계값을 넘을 때 생성하는 키프레임(keyframe) 단위로 갱신한다.

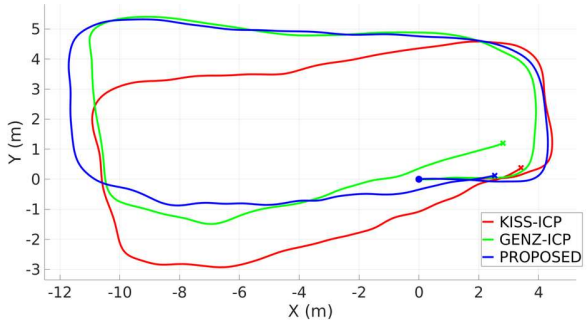

그림 1. KISS-ICP, GenZ-ICP, 제안 기법으로 추정한 수평면 궤적 비교.

Fig 1. Comparison of horizontal trajectories estimated by KISS-ICP, GenZ-ICP, and the proposed method.

3. 실험 결과

제안된 기법의 성능을 검증하기 위해 포항 청진항 인근 해역에서 데이터셋 획득 실험을 수행하였다. 3차원 MBES(Coda Octopus, Echoscope C500)를 UUV 플랫폼에 장착하고, roll과 pitch 기준값 계측용 TCM(PNI Sensor, FieldForce TCM)과 수심 기준값 계측용 압력계(WIKA, P-30)를 함께 장착하였다. UUV는 해저면에 근접한 상태로 주변 지형을 따라 한 차례 순환하여 초기 위치 부근으로 복귀하는 경로로 운용하였다. 비교 방법으로는 점군을 직접적으로 정합하는 KISS-ICP[1]와 GenZ-ICP[2]를 선정하였다. 표 1은 압력계 수심과 TCM 자세각을 기준값으로 한 $(z,\ \phi,\ \theta)$ 추정값의 RMSE이며, 제안 기법이 모든 성분에서 가장 낮은 오차를 보였다. TCM 헤딩은 신뢰성이 낮고 수평 위치 기준값도 없으므로 $(x,\ y,\ \psi)$는 초기 위치로 복귀하는 경로 특성을 이용하여 그림 1의 수평 궤적과 그림 2의 누적 지도 일관성으로 정성적으로 평가하였다. 비교 방법과 달리 제안 기법은 누적된 해저면이 평탄하게 유지되고 재방문 영역의 비평면 지형도 동일한 위치에 정합되었다.

4. 결론

본 연구에서는 해저면 근접 운용을 위한 제한된 화각의 3차원 MBES 기반 6자유도 오도메트리 추정 기법을 제안하였다. 제안 기법은 외부 항법 정보 없이 국소 해저면과 비평면 지형의 상보적인 기하학적 정보로 6자유도 운동을 추정한다. 실해역 데이터를 이용한 평가에서 제안 기법은 기존 점군 정합 기반 방법에 비해 roll, pitch 및 수직 위치를 안정적으로 추정하였고, 재방문 영역에서도 일관된 궤적과 3차원 지도를 나타내어 유효성을 확인하였다.

참 고 문 헌

[1] I. Vizzo, et. al, “KISS-ICP: In Defense of Point-to-Point ICP – Simple, Accurate, and Robust Registration If Done the Right Way”, *IEEE Robotics and Automation Letters*, Vol. 8, No. 2, 2023. 2, pp. 1029-1036.

[2] D. Lee, H. Lim, S. Han, “GenZ-ICP: Generalizable and Degeneracy-Robust LiDAR Odometry Using an Adaptive Weighting”, *IEEE Robotics and Automation Letters*, Vol. 10, No. 1, 2025. 1, pp. 152-159.

한국해양로봇기술연구회 2026년 추계학술대회 (2026. 11. 13(금) / 부산항국제전시컨벤션센터(부산))

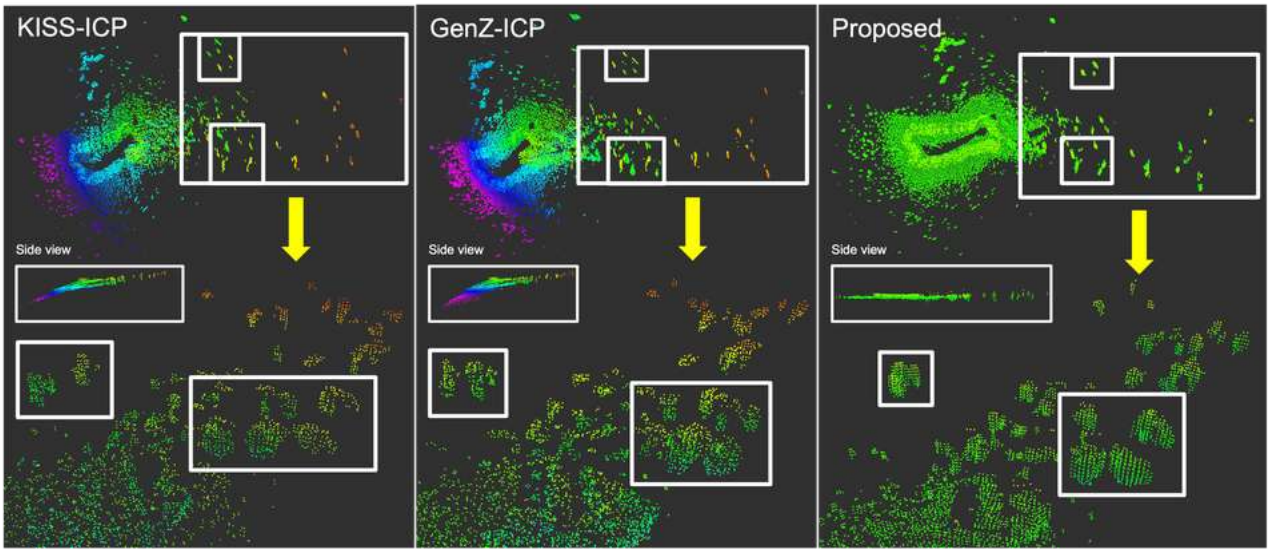

그림 2. KISS-ICP, GenZ-ICP, 제안 기법으로 얻은 3차원 지도 작성 결과의 정성적 비교. 확대 영역은 비평면 지형 특징의 정합을, 측면도는 추정된 해저면의 일관성을 나타낸다.

Fig 2. Qualitative comparison of 3D mapping results obtained using KISS-ICP, GenZ-ICP, and the proposed method. The enlarged regions show the alignment of non-planar terrain features, while the side views show the consistency of the estimated seafloor.

한국해양로봇기술연구회
2026 추계학술대회

A-P6

3D 소나의 3차원 특징벡터 기반 수중 다이버 탐지 알고리즘

A 3D Feature Vector-based Underwater Diver Detection Algorithm using 3D SONAR

이지원 · 박유진 · 신재정

서울대학교 조선해양공학과 능동인식 및 로봇지능 연구실

3D 소나의 3차원 특징벡터 기반 수중 다이버 탐지 알고리즘

이지원 · 박유진 · 신재정
서울대학교 조선해양공학과 능동인식 및 로봇지능 연구실

A 3D Feature Vector-based Underwater Diver Detection Algorithm using 3D SONAR

Jiwon Lee, Eugene Park, Jaejeong Shin
Active Perception and Robot Intelligence Lab, Seoul National University

Key Words : AUV 무인잠수정, 3D object detection 3차원 객체 탐지, 3D SONAR 3차원 소나

Abstract : There still exist complicated underwater operations that require divers, who are exposed to unpredictable hazards and heavy physical and mental workloads. To improve diver safety and operational efficiency, autonomous underwater robots should recognize divers to assist their jobs. As a first step, this study addresses diver detection, defined as estimating the diver's position and full 3D orientation. A 3D SONAR (Sound Navigation And Ranging) is chosen as a sensing modality in this study because it provides 3D information without projection and is robust to light attenuation and turbidity. Existing 3D SONAR-based methods compress point clouds into 2D bird's-eye-view features, losing elevation information. We therefore adopt a sparse 3D backbone that preserves the 3D structure of features and design a detection head that predicts the full 3D orientation of the diver, together with Gaussian heatmap-based presence prediction and a corner auxiliary loss. On the publicly available Diver3D dataset, the proposed method achieves an AP@0.35 of 0.745 and an SDS of 0.678, outperforming the existing 3D SONAR-based diver detection method by 23.0 percentage points and 0.104, respectively.

1. 개요

수중 작업은 해양 구조물 점검, 해양 플랜트 건설, 수색 및 구조 등 다양한 분야에서 이루어지며, 그 대부분은 여전히 다이버가 수행하고 있다. 이러한 작업은 시야 제한, 조류, 감압 등 예측하기 어려운 위험 요소가 많고, 다이버에게 큰 정신적·육체적 부담을 준다. 따라서 다이버의 안전과 작업 효율을 높이기 위해서는 다이버의 상태를 인식하고 작업을 보조할 수 있는 수중 자율로봇 기술이 필요하나, 이 기술은 아직 충분히 연구되지 않았다 [1]. 이에 본 연구에서는 그 첫 단계로서, 로봇이 주변 다이버의 위치와 3차원 자세를 추정하는 다이버 탐지 방법을 다룬다.

수중 환경에서는 빛이 흡수와 산란으로 인해 크게 감쇠되므로, 주변 환경을 인식하기 위해 음파를 이용하는 소나가 주로 사용된다. 최근 Water Linked 사의 Sonar 3D-15와 같이 비교적 저렴한 3D 소나가 개발되면서, 탁도가 높거나 빛이 없어 시야가 제한된 환경에서도 3차원 점군을 이용해 물체를 탐지하는 연구가 주목받고 있다 [2], [3]. 그러나 기존의 3D 소나 기반 객체 탐지 연구는 3차원 점군을 2차원 BEV(Bird's Eye View) 특징 맵으로 압축하여 처리하기 때문에 높이 방향의 정보가 손실되며, 이로 인해 다이버를 안정적으로 탐지하는 데 한계가 있다. 이에 본 연구에서는 FCAF3D [4]와 같은 실내 3차원 객체 탐지 방식을 참고하여 특징의 3차원 구조를 유지하는 희소(sparse) 3차원 백본을 구성하고, 이 3차원 특징에 맞는 탐지 헤드를 설계하여 3D 소나 기반 다이버 탐지 알고리즘의 성능을 향상시키고자 한다.

* 이지원 : 서울대학교 조선해양공학과
010-4157-3634, *smilejion@snu.ac.kr*
* 박유진 : 서울대학교 조선해양공학과
010-8238-1315, peg0525@*snu.ac.kr*
* 신재정 : 서울대학교 조선해양공학과
010-9935-9494, janeshin@*snu.ac.kr*

2. 3차원 객체 탐지 관련 연구

3D 소나가 상용화되기 이전, 소나 기반 수중 객체 탐지 연구는 주로 2차원 영상을 생성하는 FLS(Forward-Looking Sonar)를 이용하여 이루어졌으며, 합성곱 신경망(CNN) 기반의 다양한 탐지 방법이 제안되었다 [5]. 그러나 FLS는 거리와 방위각으로 이루어진 2차원 영상만을 제공하며, 고도각 방향의 정보는 하나의 픽셀로 투영되어 사라진다. 최근에는 고도각 정보까지 획득할 수 있는 3D 소나가 상용화되면서, 3차원 점군을 이용한 객체 탐지 연구가 이루어지고 있다. SonarPoint [2]는 3D 소나를 이용하여 여러 종류의 수중 객체를 탐지하였으며, SonarVoxNet [3]은 3D 소나 기반 다이버 탐지에 초점을 맞추었다. 그러나 두 연구 모두 3차원 점군을 2차원 BEV 특징 맵으로 압축하여 처리하므로, 센서가 제공하는 높이 방향의 정보를 충분히 활용하지 못한다.

이러한 한계를 해결하기 위해 본 연구에서는 3D 소나의 점군이 3D LiDAR의 점군과 동일한 형식을 가진다는 점에서, LiDAR 기반 3차원 객체 탐지 방법을 검토하였다. 지상 자율주행을 위한 LiDAR 기반 객체 탐지 연구 [6] - [9]는 차량과 보행자가 대부분 지면 위에 위치하여 높이 방향의 정보가 탐지에 미치는 영향이 적으므로, 앞서 언급한 3D 소나 기반 연구와 같이 3차원 특징을 BEV 특징 맵으로 압축하여 처리한다. 반면 실내 3차원 객체 탐지 연구는 다양한 높이에 놓인 물체를 구분해야 하므로 특징을 3차원 구조로 유지한다. GSDN [10]은 희소 3차원 합성곱을 이용하여 3차원 특징을 유지한 채 객체를 탐지하였으며, FCAF3D [4]는 이를 사전에 정의된 상자(anchor) 없이 각 위치에서 객체의 중심과 크기를 직접 예측하는 anchor-free 방식으로 확장하여, 다양한 크기와 형태의 객체를 탐지하였다. 수중의 다이버는 지면에 고정되지 않고 3차원

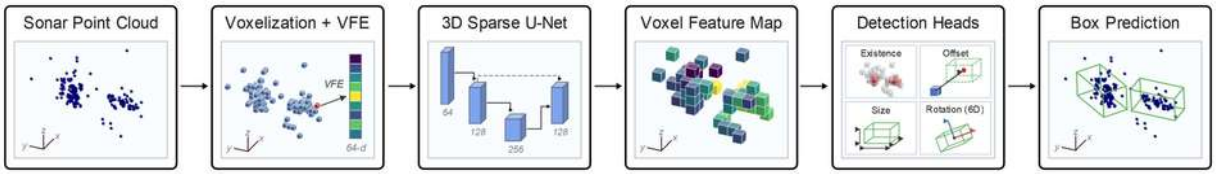

Figure 1. Overall architecture of the proposed diver detection algorithm

공간에서 다양한 자세로 움직이므로, 실내 객체 탐지와 같이 높이 방향의 정보가 탐지에 중요하다. 본 연구에서는 특징의 3차원 구조를 유지하는 백본 구조를 기반으로 다이버 탐지 알고리즘을 구성한다.

3. 수중 다이버 탐지 알고리즘

제안하는 알고리즘의 구조는 Fig. 1과 같으며, 복셀화, 희소 3차원 백본, 탐지 헤드로 구성된다.

3.1. 복셀화

3D 소나로부터 획득된 점군 $P=\{\boldsymbol{p}_i\}_{i=1,\dots,N}$ 의 각 점 $p_i=[x_i,y_i,z_i,r_i]^T$는 3차원 위치와 반사 세기로 구성된다. 탐지 범위는 전방 X ∈ [0, 12] m, 좌우 Y ∈ [-5, 5] m, 상하 Z ∈ [-2.5, 2.5] m로 설정하고, 이 공간을 한 변이 0.2 m인 정육면체 복셀로 나누어 60×50×25 격자를 구성한다. 점의 위치만으로는 복셀 내부의 국소 형상을 표현하기 어려우므로, 점이 존재하는 M개의 복셀 중 m번째 복셀에 속한 점 p_i에 복셀의 통계 정보를 더해 다음과 같은 특징 f_i를 구성한다.

$$f_i=[\boldsymbol{p}_i^T,\ [\boldsymbol{x}_i-\boldsymbol{\mu}_m]^T,\ [\boldsymbol{x}_i-\boldsymbol{c}_m]^T,\ \boldsymbol{\sigma}_m^T,\ \log n_m]^T \quad (1)$$

여기서 $\boldsymbol{x}_i$는 점의 위치이고, $\boldsymbol{\mu}_m$, $\boldsymbol{c}_m$, $\boldsymbol{\sigma}_m$, n_m은 각각 복셀 내부 점들의 평균 위치, 복셀 중심, 축별 표준편차, 점의 개수이다. 이 특징은 VFE(Voxel Feature Encoding) [9]에 입력된다. VFE는 모든 점에 같은 연산을 적용한 뒤 최대값 풀링으로 통합하므로, 점의 개수와 순서에 관계없이 각 복셀을 64차원 특징 벡터로 변환한다.

3.2. 특징 맵 추출 백본

3차원 점군은 대부분의 복셀이 비어 있으므로, 점이 존재하는 복셀에서만 연산하는 희소 3차원 합성곱으로 백본을 구성한다. 또한 넓은 수용 영역을 확보하면서도 상자 예측에 필요한 해상도를 복원하기 위해 U-Net 구조를 사용하며, 모든 특징 맵은 높이 축을 포함한 3차원 구조를 유지한다. 인코더의 두 단계는 각각 희소 합성곱으로 해상도를 절반으로 줄이고 채널 수를 두 배로 늘린 뒤, 세 개의 submanifold 희소 합성곱 [11] 잔차 블록으로 수용 영역을 확장한다. 디코더는 역희소 합성곱으로 특징을 첫 번째 인코딩 단계에서 점이 존재하던 복셀 좌표에만 복원하여 빈 공간으로 특징이 퍼지지 않도록 한다. 복원된 특징은 첫 번째 단계의 특징과 결합되어 128채널의 3차원 특징 맵으로 출력된다.

3.3. 탐지 헤드

탐지 헤드는 각 복셀에서 다이버 존재 히트맵 값과 3차원 상자를 예측하며, 히트맵 값은 해당 복셀이 다이버의 중심 영역에 속할 가능성을 나타낸다. 3차원 상자의 중심은 다이버 중심이 점이 없는 빈 복셀에 위치할 수 있으므로 복셀 중심으로부터의 오프셋으로 예측한다. 크기는 로그 스케일로 예측하고, 회전은 roll, pitch, yaw를 연속적으로 표현할 수 있는 6D 회전 표현 [12]으로 예측하며, 이는 그람-슈미트 직교화를 통해 회전 행렬로 변환된다. 추론 시에는 히트맵 값이 임계값 이상이면서 인접 복셀들 사이에서 국소 최대인 예측만 남긴다.

3.4. 손실 함수

전체 손실 함수 L는 존재 손실 L_{cls}, 중심 위치 손실 L_{center}, 상자 크기 손실 L_{size}, 회전 손실 L_{rot}, IoU 손실 L_{IoU}, 꼭짓점 보조 손실 $L_{conrner}$의 가중합으로 구성된다.

$$L=\sum_k \lambda_k L_k,\ k\in\{cls, center, size, rot, IoU, corner\} \quad (2)$$

여기서 λ_k는 각 손실의 가중치이며, λ_{size}는 0.5, 나머지 가중치는 모두 1.0으로 설정하였다. 존재 손실은 각 복셀에서 다이버의 존재를 학습하고, 중심 위치, 크기, 회전 손실은 상자의 각 구성 요소를 학습하며, IoU 손실과 꼭짓점 보조 손실은 상자 전체가 실제 상자와 맞도록 학습한다.

존재 손실 L_{cls}의 정답은 다음과 같이 설정한다. 정답 상자의 중심을 기준으로 상자를 0.6배 축소한 영역 내부의 복셀을 양성(Pos)으로 두고, 나머지 복셀에는 다이버 중심으로부터의 거리에 따른 가우시안 값 h_j을 할당한다. 이때 양성 복셀은 전체 복셀에 비해 매우 적으므로, CenterNet [13] 방식의 focal loss로 배경 복셀의 영향을 줄여 학습한다.

$$h_j=\begin{cases}1, & \boldsymbol{c}_j\in P\\ \exp\left(-\dfrac{\|\boldsymbol{d}-\boldsymbol{c}_j\|^2}{2\sigma^2}\right), & otherwise\end{cases} \quad (3)$$

$$L_{cls}=-\frac{1}{N_{pos}}\sum_j\begin{cases}(1-\hat{p}_j)^{\alpha}\log\hat{p}_j, & h_j=1\\ (1-h_j)^{\beta}\hat{p}_j^{\alpha}\log(1-\hat{p}_j), & h_j<1\end{cases} \quad (4)$$

여기서 P와 N_{pos}는 양성 복셀의 집합과 수, d는 다이버 중심, c_j는 j번째 복셀의 중심, h_j와 $\hat{p}_j$는 j번째 복셀의 존재 정답과 예측이며, $\sigma=0.5m, \alpha=2, \beta=4$이다.

중심 위치 손실 L_{center}와 상자 크기 손실 L_{size}는 양성 복셀에 대한 L1 손실의 평균으로 계산한다. 이때 다이버 상자는 축마다 크기 차이가 있으므로, 작은 축의 오차가 충분히 반영되도록 크기는 로그 공간에서 비교한다.

$$L_{center}=\frac{1}{N_{pos}}\sum\|\hat{\boldsymbol{o}}_j-(\boldsymbol{d}-\boldsymbol{c}_j)\|_1 \quad (5)$$

$$L_{size}=\frac{1}{N_{pos}}\sum\|\hat{\boldsymbol{l}}_j-\log\boldsymbol{s}\|_1 \quad (6)$$

여기서 $\hat{\boldsymbol{o}}_j$와 $\hat{\boldsymbol{l}}_j$는 j번째 복셀에서 예측된 중심 오프셋과 로그 스케일 크기, $\boldsymbol{s}$는 실제 상자의 크기이다.

회전 손실 L_{rot}은 예측과 정답 상자 사이의 각도 차이로 계산한다. 오일러 각이나 쿼터니언과 같은 4차원 이하의 회전 표현은 불연속적이어서 기울기 기반 학습을 어렵게 한다 [12]. 따라서 예측된 6D 표현을 회전 행렬로 변환한 뒤, 정답 회전 행렬과의 각도 차이를 손실로 사용한다.

$$L_{rot}=\frac{1}{N_{pos}}\sum\arccos\left(\frac{tr\left(\hat{\boldsymbol{R}}_j^T\boldsymbol{R}\right)-1}{2}\right) \quad (7)$$

여기서 $\hat{R}_j$는 예측된 6D 표현으로부터 변환된 회전 행렬, R은 실제 회전 행렬이다.

IoU 손실 L_{IoU}는 상자 전체의 겹침 정도를 학습한다. 앞의 손실들은 중심 위치, 크기, 회전을 각각 학습하므로 겹침

정도를 직접 최적화하지 못한다. 그러나 회전된 3차원 상자의 정확한 IoU는 미분이 어렵기 때문에, 각 상자로부터 가우시안 분포를 구성하고, 두 분포 사이의 GWD(Gaussian Wasserstein Distance) [14]로 IoU를 근사한다.

$$L_{IoU} = \frac{1}{N_{pos}} \sum \left(1 - \frac{1}{\tau + W_j}\right) \tag{8}$$

여기서 W_j는 j번째 복셀의 GWD 값으로 두 분포가 유사할수록 0에 가까워지며, $\tau = 1$이다.

마지막으로 꼭짓점 보조 손실 L_{corner}은 가우시안 근사로는 반영되지 않는 상자 꼭짓점의 위치를 맞추도록 학습한다. 예측 상자와 실제 상자의 8개 꼭짓점을 각각 가우시안 히트맵으로 렌더링하고, 두 히트맵 사이의 평균 제곱 오차로 손실을 계산한다. 꼭짓점 좌표를 직접 비교하지 않고 히트맵으로 비교하므로, 꼭짓점의 대응 순서에 영향을 받지 않으며 오차가 큰 경우에도 학습이 불안정해지지 않는다.

$$H(\boldsymbol{c_j}; V) = \max_{\boldsymbol{v} \in V} \exp\left(-\frac{|\boldsymbol{c_j} - \boldsymbol{v}|^2}{2\sigma_c^2}\right) \tag{9}$$

$$L_{\text{corner}} = \frac{1}{\mathrm{N_{vox}}} \sum_{\mathrm{j}} \left(\mathrm{H}(\mathbf{c_j}; \hat{\mathrm{V}}) - \mathrm{H}(\mathbf{c_j}; \mathrm{V})\right)^2 \tag{10}$$

여기서 $\sigma_c = 0.5m$이고, $\hat{V}$와 V는 모든 양성 복셀에서 예측한 상자들의 꼭짓점 집합과 실제 상자들의 꼭짓점 집합이며, $\mathrm{N_{vox}}$는 점이 존재하는 전체 복셀의 수이다.

4. 실험 설계

제안한 알고리즘의 구조 자체의 성능을 평가하기 위해 데이터 증강 없이 기존 연구와 비교하였다. SonarVoxNet [3]은 동일한 데이터셋에서 다이버를 탐지하는 기존 3D 소나 기반 방법으로, 3차원 점군을 2차원 BEV 특징 맵으로 압축하여 처리한다. FCAF3D [4]는 특징의 3차원 구조를 유지하는 실내 3차원 객체 탐지 방법이지만, z축 방향 회전만을 갖는 상자를 예측한다. 다만 기존 방법과 제안한 알고리즘을 바로 비교하면 백본, 탐지 헤드, 손실 함수가 한꺼번에 달라져, 어떤 요소가 성능 향상에 기여했는지 알기 어렵다. 이에 제안한 알고리즘과 같은 백본을 사용하는 FCAF3D에서 z축 회전 예측 헤드만 3차원 회전을 예측하도록 교체한 모델을 기준 모델(Baseline)로 두었다. 그리고 기준 모델의 존재 예측을 CenterNet [13]의 가우시안 히트맵 기반 존재 예측(A)으로 교체하고, 꼭짓점 보조 손실(B)을 순차적으로 추가하며 각 구성 요소의 효과를 확인하였다. 또한 SonarVoxNet과 기준 모델에 A를 적용한 모델의 비교로는 3차원 특징 구조 유지의 효과를 확인한다. 마지막으로 SonarVoxNet과 제안한 알고리즘의 비교로 기존 다이버 탐지 방법 대비 전체 성능을 확인한다.

탐지 성능은 3차원 IoU 임계값 0.1, 0.35, 0.5에서의 AP(Average Precision)로 평가하였다. AP@0.1로는 다이버의 존재를 탐지하는 능력을, AP@0.35와 AP@0.5로는 상자를 얼마나 정확하게 예측하는지를 평가한다. 또한 다이버의 위치와 자세 추정 정확도를 확인하기 위해, 정답과 매칭된 예측 상자에 대해 중심 오차(ATE), 크기 오차(ASE), 3차원 회전 오차(AOE3D)를 측정하였다. 마지막으로 SonarVoxNet [3]에서 제안한 SDS(Sonar-Diver Detection Score)를 사용하여, 탐지 성능과 세 가지 오차를 하나의 통합 지표로 종합하였으며, 이때 탐지 성능은 원 논문과 동일하게 IoU 임계값 0.3, 0.35, 0.4에서의 평균 AP를 사용하였다.

실험에는 3D 소나 기반 다이버 데이터셋인 Diver3D [3]를 사용하였다. Diver3D는 학습, 검증, 시험 데이터로 나뉘어 제공되며, 각각 20,861, 8,037, 8,112 프레임으로 구성된다.

SonarVoxNet [3]은 원 논문에 보고된 결과를 사용하였으며, 나머지 모델은 다음과 같은 동일한 설정으로 학습하였다. 최적화에는 가중치 감쇠 0.01의 AdamW를 사용하였다. 학습률은 OneCycle 스케줄을 따라 전체 학습의 처음 1/10 동안 최대 학습률 0.006까지 증가한 뒤 감소한다. 학습에는 NVIDIA RTX 2070 GPU 한 장을 사용해 배치 크기 8로 20에폭 동안 수행하였다. 검증 데이터에서 AP@0.35가 가장 높은 모델을 선택하였으며, 선택한 모델의 시험 데이터 결과를 최종 성능으로 보고한다.

5. 실험 결과

Table 1은 기존 방법인 SonarVoxNet [3], FCAF3D [4]와 제안한 알고리즘(기준 모델+A+B)의 비교 실험 결과이다. 제안한 알고리즘은 모든 지표에서 가장 높은 성능을 보였으며, SonarVoxNet 대비 AP@0.35는 23.0%p, AP@0.5는 14.8%p 향상되었고, SDS는 0.678로 0.104 높았다. FCAF3D는 AP@0.35가 0.112, AP@0.5가 0.004로 매우 낮았으며, 이는 z축 회전만 예측하는 실내 객체 탐지 방법을 3차원 공간에서 다양한 자세로 움직이는 다이버 탐지에 그대로 적용하기 어려움을 의미한다.

Table 1. Comparison of the proposed algorithm with SonarVoxNet and FCAF3D on the Diver3D test set

Method	AP@0.1	AP@0.35	AP@0.5	SDS
SonarVoxNet [3]	-	0.515	0.233	0.574
FCAF3D [4]	0.212	0.112	0.004	0.350
Ours	0.858	0.745	0.381	0.678

Table 2는 기준 모델에 제안한 구성 요소를 순차적으로 추가한 결과이다. 먼저 가우시안 히트맵 기반 존재 예측(A)을 적용하자 AP@0.1이 42.0%p, AP@0.35가 31.1%p 향상되었다. 이는 다이버 중심 주변 복셀에 거리에 따른 연속적인 정답을 할당함으로써, 희소한 소나 점군에서도 다이버의 존재를 안정적으로 학습할 수 있음을 보여준다. 그리고 3차원 특징 구조 유지의 효과를 확인하기 위해, 특징 맵의 차원만 다른 SonarVoxNet과 기준 모델에 A를 적용한 모델을 비교하였다. 3차원 특징 맵을 사용한 모델은 SonarVoxNet 대비 AP@0.35가 13.7%p, AP@0.5가 8.5%p, SDS가 0.063 높아, 높이 방향의 정보를 유지하는 것이 다이버 탐지에 유리함을 확인하였다. 마지막으로 꼭짓점 보조 손실(B)을 추가하자 AP@0.35가 9.3%p, AP@0.5가 6.3%p 향상되고 중심 오차가 감소하였으며, SDS는 0.678로 가장 높았다. 이는 꼭짓점 손실이 상자의 꼭짓점 위치를 직접 맞추도록 하여 높은 IoU 임계값에서의 정확도를 높이는 데 도움을 준다고 볼 수 있다.

반면 제안한 알고리즘은 SonarVoxNet과 비교하여 중심 오차는 소폭 개선되었으나, 크기와 회전 오차는 더 크게 나타났다. 이는 오차 지표가 정답과 매칭된 예측에 대해서만 계산되기 때문으로 분석된다. 탐지 성능이 낮은 모델은 상대적으로 쉬운 경우에 대해서만 오차가 계산되는 반면, 제안한 알고리즘은 탐지가 어려운 다이버까지 탐지하므로 이들의 상자 오차가 함께 반영된다. Fig. 2는 시험 예시 데이터에 대한 각 방법의 탐지 결과를 나타낸다.

6. 결론

본 연구에서는 수중 로봇이 다이버를 인식하고 보조하기 위한 첫 단계로, 3D 소나 점군에서 다이버의 위치와 3차원 자세를 추정하는 다이버 탐지 알고리즘을 제안하였다. 기존 다이버 탐지 방법인 SonarVoxNet은 점군을 BEV 특징 맵으로 압축하여 높이 방향의 정보를 잃는 한계가 있었다. 이를 해결하기 위해 특징의 3차원 구조를 유지하는 희소 3차원 백본을 구성하였다. 또한 가우시안 히트맵 기반 존재 예측과 꼭짓점 보조 손실을 도입하여 다이버를 더 안정적이고 정확하게 탐지할 수 있도록 하였다. Diver3D 데이터셋에서 제안한

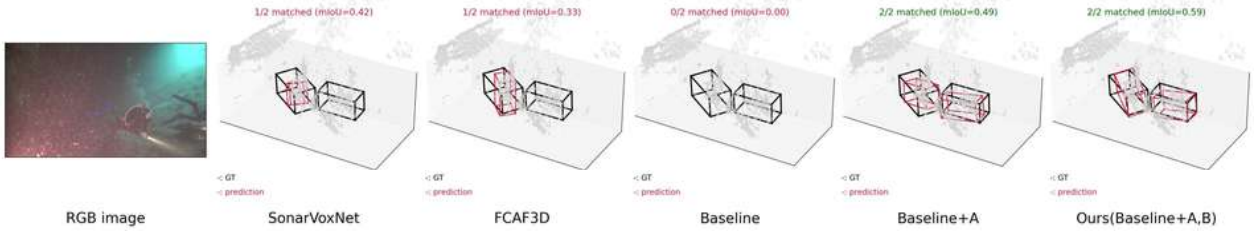

Figure 2. Qualitative detection results on the Diver3D test set (black: GT, red: prediction)

Table 2. Ablation study on the Diver3D test set. A: Gaussian heatmap-based presence prediction [13], B: corner auxilliary loss

Method	Feature	A [13]	B	AP			Average Error			SDS ↑
				0.1 ↑	0.35 ↑	0.5 ↑	ATE (m) ↓	ASE ↓	AOE3D(°) ↓	
SonarVoxNet [3]	BEV	✓		-	0.515	0.233	0.210	0.330	34.3	0.574
Baseline	3D			0.364	0.341	0.210	0.183	0.310	**29.0**	0.532
Baseline+A	3D	✓		0.784	0.652	0.318	0.199	0.334	52.1	0.637
Ours	3D	✓	✓	**0.858**	**0.745**	**0.381**	0.194	0.341	53.1	**0.678**

알고리즘은 AP@0.35 0.745, SDS 0.678로 SonarVoxNet 대비 각각 23.0%p, 0.104 향상되었다. 특히 3차원 특징 구조를 유지하는 것만으로 SonarVoxNet 대비 AP@0.35가 13.7%p 향상되었으며, 가우시안 히트맵 기반 존재 예측(A)은 탐지 성능을, 꼭짓점 보조 손실(B)은 상자 정확도를 높여 각각 성능 향상에 기여함을 확인하였다.

그러나 제안한 알고리즘은 LiDAR 점군을 위해 설계된 VFE로 복셀 특징을 추출한다. VFE는 각 복셀을 내부의 점만으로 독립적으로 인코딩하는데, 소나 데이터는 LiDAR보다 노이즈가 많고 희소하여 복셀마다 신뢰할 수 있는 점이 적다. 이 때문에 주변 복셀과의 맥락이나 소나 특유의 반사 특성을 충분히 반영하지 못한다. 또한 현재의 오차 지표는 정답과 매칭된 예측에 대해서만 계산되므로, 탐지가 어려운 다이버까지 탐지하는 모델일수록 오차가 크게 나타나는 경향이 있어 모델 간 자세 추정 정확도를 공정하게 비교하기 어렵다.

향후에는 소나의 노이즈와 반사 특성을 고려한 특징 추출 방법을 연구할 계획이다. 또한 탐지율의 영향을 배제하고 자세 추정 정확도를 평가할 수 있는 지표를 제안하고자 한다. 나아가 수중 로봇에 탑재할 수 있도록 실시간성을 검증하고, 다이버의 상태 인식과 작업 보조로 연구를 확장하고자 한다.

참 고 문 헌

[1] A. Birk, "A survey of underwater human-robot interaction (U-HRI)," Current Robotics Reports, vol. 3, no. 4, pp. 199 - 211, 2022, doi: 10.1007/s43154-022-00092-7.

[2] D. Zhao, T. Cai, P. Chen, W. Mao, Y. Hu, Y. Zhang, et al., "SonarPoint: Weak-heterogeneity awareness object detection network for 3D sonar point cloud," IEEE Trans. Circuits Syst. Video Technol., vol. 35, no. 10, pp. 9695 - 9707, 2025.

[3] E. Park, J. Lee, S. Kan, T. Dong, X. Lin, and J. Shin, "SonarVoxNet: Diver detection in 3D bounding box using 3D sonar," arXiv preprint arXiv:2610.01644, 2026.

[4] D. Rukhovich, A. Vorontsova, and A. Konushin, "FCAF3D: Fully convolutional anchor-free 3D object detection," in Proc. Eur. Conf. Comput. Vis. (ECCV), 2022, pp. 477 - 493.

[5] M. Aubard, A. Madureira, L. Teixeira, and J. Pinto, "Sonar-based deep learning in underwater robotics: Overview, robustness and challenges," IEEE J. Ocean. Eng., 2025.

[6] A. H. Lang, S. Vora, H. Caesar, L. Zhou, J. Yang, and O. Beijbom, "PointPillars: Fast encoders for object detection from point clouds," in Proc. IEEE/CVF Conf. Comput. Vis. Pattern Recognit. (CVPR), 2019, pp. 12697 - 12705.

[7] Y. Yan, Y. Mao, and B. Li, "SECOND: Sparsely embedded convolutional detection," Sensors, vol. 18, no. 10, p. 3337, 2018.

[8] T. Yin, X. Zhou, and P. Krähenbühl, "Center-based 3D object detection and tracking," in Proc. IEEE/CVF Conf. Comput. Vis. Pattern Recognit. (CVPR), 2021, pp. 11784 - 11793.

[9] Y. Zhou and O. Tuzel, "VoxelNet: End-to-end learning for point cloud based 3D object detection," in Proc. IEEE/CVF Conf. Comput. Vis. Pattern Recognit. (CVPR), 2018, pp. 4490 - 4499.

[10] J. Gwak, C. Choy, and S. Savarese, "Generative sparse detection networks for 3D single-shot object detection," in Proc. Eur. Conf. Comput. Vis. (ECCV), 2020, pp. 297 - 313.

[11] B. Graham, M. Engelcke, and L. van der Maaten, "3D semantic segmentation with submanifold sparse convolutional networks," in Proc. IEEE/CVF Conf. Comput. Vis. Pattern Recognit. (CVPR), 2018, pp. 9224 - 9232.

[12] Y. Zhou, C. Barnes, J. Lu, J. Yang, and H. Li, "On the continuity of rotation representations in neural networks," in Proc. IEEE/CVF Conf. Comput. Vis. Pattern Recognit. (CVPR), 2019, pp. 5745 - 5753.

[13] X. Zhou, D. Wang, and P. Krähenbühl, "Objects as points," arXiv preprint arXiv:1904.07850, 2019.

[14] X. Yang, J. Yan, Q. Ming, W. Wang, X. Zhang, and Q. Tian, "Rethinking rotated object detection with Gaussian Wasserstein distance loss," in Proc. Int. Conf. Mach. Learn. (ICML), 2021, pp. 11830 - 11841.

한국해양로봇기술연구회
2026 추계학술대회

A-P7

RL-Based Gain Optimization of Time-Delay Control for AUVs with a Pan-Tilt Sensor Pointing Mechanism

김동섭 · 김승민 · 유선철

포항공과대학교 (POSTECH)

RL-Based Gain Optimization of Time-Delay Control for AUVs with a Pan-Tilt Sensor Pointing Mechanism

Dongsub Kim*, Seungmin Kim*, Son-cheol Yu**
*Department of Convergence IT Engineering, Pohang University of Science and Technology (POSTECH)
**Department of Electrical Engineering, Pohang University of Science and Technology (POSTECH)

Key Words : autonomous underwater vehicle, pan-tilt mechanism, reaction disturbance, reinforcement learning, time-delay control, gain optimization

Abstract : Autonomous underwater vehicles (AUVs) equipped with a two-axis pan-tilt mechanism (PTM) for sensor pointing are subjected to reaction forces and moments generated by PTM motion, which can degrade vehicle pose stabilization and sensor-pointing performance. This paper uses reinforcement learning (RL) to optimize the six feedback gains of a Time-Delay Control (TDC) baseline and the intensity of an active vibration damper, training the policy with a staged curriculum in simulation. Compared with the best grid-searched fixed gains, the learned policy reduces position RMSE by 20.5% and vibration energy by 35.7%, with a slight improvement in attitude RMSE. It also outperforms an oracle rule-based switcher. Analysis of the learned gains shows, however, that the policy converges to a near-constant operating point rather than scheduling gains according to the disturbance regime. Therefore, the performance improvement results from identifying a better operating point rather than from online adaptation.

1. Introduction

Autonomous underwater vehicles (AUVs) are increasingly equipped with actively steered sensor pointing mechanisms, such as camera or sonar mounts, that retarget independently of the vehicle body (Fig. 1). Every retargeting motion produces an inertial reaction wrench on the body that falls in the same low-frequency band as the attitude and position loops, degrading pose-holding accuracy and sensor-pointing stability. Because the reaction is strong while the two-axis pan-tilt mechanism (PTM) scans and nearly absent while it is parked, a single set of fixed gains is necessarily a compromise between the two regimes.

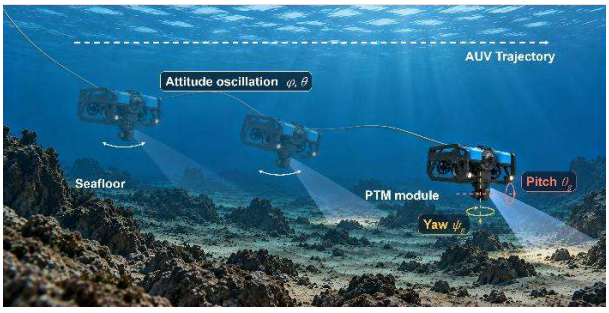

Fig. 1 Concept of an AUV equipped with a two-axis pan-tilt sensor pointing mechanism. Its rotation generates reaction forces and moments that disturb the vehicle's position and attitude.

Time-Delay Control (TDC) [1] estimates unmodeled dynamics and disturbances from one-step-delayed input and acceleration measurements and cancels them in the control law, and it already absorbs a large part of this structured reaction wrench. Learning an additional compensation wrench on top of TDC therefore leaves little headroom. Reinforcement learning (RL) has instead been used to tune controller gains, e.g., a PPO-trained [3] policy that adapts the cascaded gains of a quadcopter in flight [4]. Following this direction, this paper uses RL to optimize the TDC feedback gains and the intensity of an active vibration damper, and then analyzes what the learned policy actually does.

The contributions of this paper are: (1) an RL-based optimization of six TDC gains and one damper intensity for a PTM-equipped AUV, trained with a staged curriculum; (2) a comparison with the best grid-searched fixed gains and an oracle rule-based switcher, in which the learned policy reduces position RMSE by 20.5% and vibration energy by 35.7% relative to the best fixed baseline; and (3) an analysis of the learned gain trajectory showing that the improvement comes from a near-constant operating point rather than state-dependent gain scheduling.

* Dongsub Kim : +82-54-279-9525, kbs7517@postech.ac.kr
* Seungmin Kim: +82-54-279-9525, luckkim123@postech.ac.kr
**Son-Cheol Yu (corresponding author) : +82-54-279-9504, sncyu@postech.ac.kr

2. System Modeling and Baseline Control

2.1. AUV–PTM Coupled Dynamics

The vehicle carries a two-axis PTM for sensor pointing (Fig. 2). The coupled system follows the standard 6-DOF equation of motion [2]

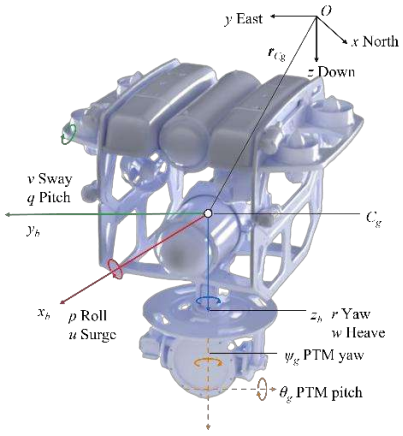

Fig. 2 BlueROV2 Heavy configuration with the two-axis PTM: NED frame, body frame (x_b, y_b, z_b), and PTM pan angle ψ_g and tilt angle θ_g.

$$M(\eta)\dot{\nu} + C(\nu)\nu + D(\nu)\nu + g(\eta) = \tau + \tau_g, \qquad (1)$$

where η and ν are the vehicle pose and body-frame velocity, M, C, D, and g are the mass (including added mass), Coriolis, damping, and restoring terms, τ is the control wrench, and τ_g is the PTM reaction wrench. From conservation of the PTM's angular momentum,

$$\tau_g \approx A\ddot{q}_g + C_d \left|\dot{q}_g\right| \dot{q}_g, \qquad (2)$$

where A and C_d depend on the retargeting profile. Because these coefficients are hard to identify online, τ_g is not modeled in the controller; it is treated as part of the lumped disturbance estimated by TDC.

2.2. Time-Delay Control and Vibration Damping

With p, R, v_b, and ω the position, attitude, body linear velocity, and body angular rate, and subscript d denoting desired values, the tracking errors are

$$e_p = p_{\mathrm{d}} - p, \quad e_v = v_{\mathrm{d}} - R v_{\mathrm{b}}, \tag{3}$$

$$e_R = \frac{1}{2}\left(R_{\mathrm{d}}^{\mathrm{T}} R - R^{\mathrm{T}} R_{\mathrm{d}}\right)^{\vee}, \quad e_\omega = \omega_{\mathrm{d}} - \omega, \tag{4}$$

where e_R is the SO(3) geometric attitude error [7]. Desired accelerations follow a PD-plus-feedforward law,

$$\alpha_v = R^{\mathrm{T}}\left(a_{\mathrm{d}} + K_{\mathrm{d,pos}} e_v + K_{\mathrm{p,pos}} e_p\right), \tag{5}$$

$$\alpha_\omega = K_{\mathrm{d,att}} e_\omega - K_{\mathrm{p,att}} e_R, \quad \nu_{\mathrm{r}} = [\alpha_v; \alpha_\omega]. \tag{6}$$

The disturbance is estimated from the previous step's acceleration and delivered wrench and injected into the control law with a diagonal trust gain Λ,

$$\hat{H}(t) \approx H(t-L) = \hat{M}\dot{\nu}(t-L) - \tau(t-L), \tag{7}$$

$$\tau = \hat{M}\nu_{\mathrm{r}} - \Lambda\hat{H}(t), \quad \Lambda = \mathrm{diag}\left(\lambda_{\mathrm{lin}} 1_3, \lambda_{\mathrm{ang}} 1_3\right), \tag{8}$$

where $\hat{M}$ is a nominal inertia estimate and L is the time delay. The four feedback gains and λ_{lin}, λ_{ang} are the six controller parameters optimized in Sec. 3. The wrench τ is distributed to the eight thrusters by a damped pseudo-inverse with smooth saturation, and the saturated wrench is fed back to the time-delay estimate to prevent windup.

A separate damper feeds the band-pass-filtered body rate (f_0 = 3.0 Hz, Q = 0.7) back as an attitude-only torque,

$$\omega_{\mathrm{BP}}(t) = \mathrm{BP}_{f_0, Q}\left(\omega(t)\right), \quad \tau_{\mathrm{damper}} = \left[0; -\alpha_t K_0 \omega_{\mathrm{BP}}(t)\right], \tag{9}$$

where $\alpha_t \in [0, 1.5]$ is the damper intensity set by the policy.

3. RL-Based Gain Optimization

3.1. Policy Architecture and Action Space

A policy π_θ, trained with PPO [3], sets the controller parameters at every control step from the vehicle and PTM state (Fig. 3). The TDC law and the damper of Sec. 2.2 are unchanged; the policy acts only through their parameters.

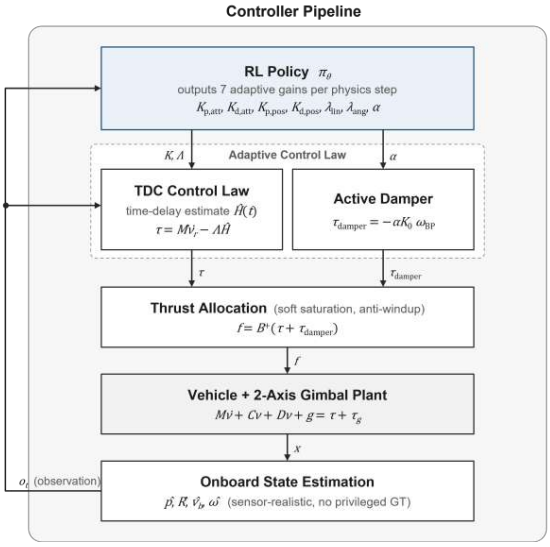

Fig. 3 Controller design: the RL policy sets the TDC gains and damper intensity from the onboard-estimated state, and thrust allocation and the AUV–PTM plant close the loop.

The action is seven-dimensional: $K_{p,att}$, $K_{d,att}$, $K_{p,pos}$, $K_{d,pos}$, λ_{lin}, λ_{ang}, and α. Each raw output is squashed to $z_t \in [0, 1]$ by a sigmoid and mapped to a validated safe range (Table 1),

$$g_t = g_{\mathrm{lo}} + z_t\left(g_{\mathrm{hi}} - g_{\mathrm{lo}}\right), \tag{10}$$

and the damper intensity is scaled as $\alpha_t = \alpha_{max}\, z_{\alpha,t}$. A rate limit on z_t prevents abrupt gain changes.

3.2. Observation and Reward Design

The 68-dimensional observation consists of (i) the tracking errors e_p, e_v, e_R and body rate ω, (ii) the PTM joint rate, acceleration, and pointing error, (iii) a vibration-energy statistic, (iv) the normalized TDC disturbance estimate and its change, (v) thruster-utilization statistics, and (vi) the previous action. All terms are taken from the onboard state estimator rather than simulator ground truth. The per-step cost penalizes tracking error and vibration,

$$\mathrm{J}_t = w_{att}\left\|\mathrm{e}_R\right\|^2 + w_{pos}\left\|\mathrm{e}_p\right\|^2 + w_{vib}\left\|\omega_{BP}\right\|^2 + J_{reg}, \tag{11}$$

where J_{reg} collects small penalties on damper effort, net energy injected by the damper, thruster utilization above a safety margin, and gain-change magnitude. The reward is $r_t = -J_t$, with an additional penalty c_{safety} when an episode is terminated for safety reasons (thruster overload, excessive tracking error, or numerical failure). The weights are listed in Table 2.

4. Simulation and Experimental Results

4.1. Experimental Setup and Baselines

Training and evaluation use MarineGym [6], built on NVIDIA Isaac Sim [5], with a BlueROV2 Heavy (eight thrusters) carrying the two-axis PTM. The control step is Δt = 0.016 s, and training uses 32 parallel environments for 48M frames in total. Tables 1 and 2 list the main parameters.

Parameter	Value / range
Mass $\hat{M}$	20.2 kg
Inertia $\hat{M}$	[1.280, 1.307, 0.504] kg·m^2
$K_{p,att}$ / $K_{d,att}$	[4.0, 10.0] / [1.7, 3.0]
$K_{p,pos}$ / $K_{d,pos}$	[1.5, 3.5] / [2.0, 3.0]
λ_{lin} / λ_{ang}	[0.06, 0.20] / [0.16, 0.40]
α (damper)	[0, 1.5]
L, Δt	0.1 s, 0.016 s

Table 1 Controller parameters and action ranges.

Item	Value
Algorithm, network	PPO, MLP [256, 256, 256]
Learning rate, clip, γ	5×10^{-4}, 0.1, 0.99
Envs, episode length	32, 12000 steps
Curriculum frames	8M + 8M + 8M + 24M
w_{att}, w_{pos}, w_{vib}	1.0, 1.0, 0.1
w_{res}, w_P, w_{act}, w_Δ	0.02, 0.05, 1.0, 0.5
c_{safety}	50

Table 2 Training settings and reward weights.

The baselines were selected by an exhaustive grid search over $K_{p,att}$, K_{pos}, and λ_{ang} for each PTM regime. The best fixed gains are A_{opt} ($K_{p,att}$ = 6.0) for the parked regime and B_{opt} ($K_{p,att}$ = 9.7) for the active regime. The two differ almost only in the attitude gain, so any single fixed gain set is a compromise. The learned policy is compared with Fixed A_{opt}, Fixed B_{opt}, and a rule-based switcher that toggles between A_{opt} and B_{opt} using the true PTM-active flag. The metrics are position RMSE, attitude RMSE, and vibration energy (band-pass power of ω_{BP}), averaged over three matched seeds.

4.2. Control Performance Comparison

Condition	Position RMSE (m)	Attitude RMSE (deg)	Vib. energy
Fixed A_{opt}	0.315	13.09	7.25
Fixed B_{opt}	0.303	10.97	8.83
Rule-based switcher	0.352	11.03	8.81
Learned (ours)	**0.241**	**10.86**	**5.68**

Table 3 Control performance of the baselines and the learned policy (3-seed mean).

As Table 3 shows, the learned policy outperforms every baseline on all three metrics. Relative to B_{opt}, the best fixed baseline, it reduces position RMSE by 20.5% (0.303 → 0.241 m) and vibration energy by 35.7% (8.83 → 5.68), while attitude RMSE improves slightly (10.97° → 10.86°). The oracle switcher does not outperform fixed B_{opt} (position RMSE 0.352 vs. 0.303 m), and a re-sweep of the grid found no fixed gain better than B_{opt} under the mixed schedule.

Fig. 4 shows representative time histories of the tracking errors under the mixed parked/active schedule. Fixed A_{opt}, Fixed B_{opt}, and the rule-based switcher all show large position-error excursions of up to about 0.6 m while the PTM retargets, whereas the learned policy keeps the position error near 0.1 m for most of the run, with only a few short peaks. The attitude error of the learned policy stays close to that of the switcher, which is consistent with the small attitude-RMSE difference in Table 3.

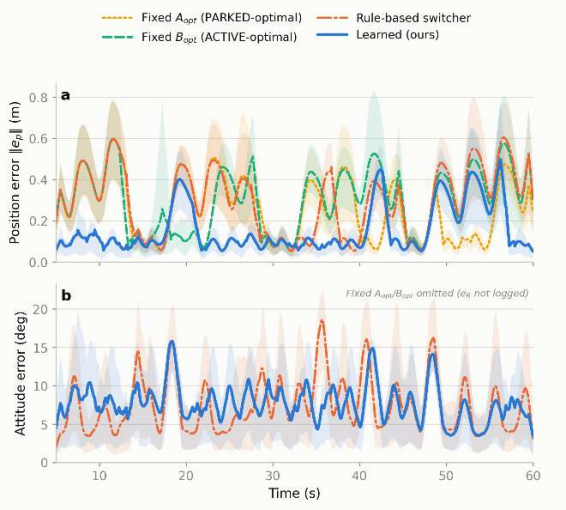

Fig. 4 Time histories of (a) position error $\|e_p\|$ and (b) attitude error for the baselines and the learned policy; shaded bands indicate the variation across seeds. Fixed A_{opt} and B_{opt} are omitted in (b) because e_R was not logged for these runs.

4.3. Analysis of Learned Gain Behavior

The learned gain trajectory shows that the policy does not perform state-dependent scheduling. All seven parameters differ by less than 0.3% between the parked and active regimes (e.g., $K_{p,att}$ = 9.636 vs. 9.644). Vehicle turn rate is strongly correlated with actuator-saturation risk (ρ = 0.82–0.83), yet its correlation with the policy's $K_{p,att}$ output is only ρ ≈ 0.02–0.04. The apparent adaptation early in each episode is an artifact of the rate limit: every episode ramps from the same reset value to the same converged value at the same rate, regardless of the trajectory, to the fourth decimal place across seeds. A weak but consistent effect remains at the extremes of the turn-rate distribution (top vs. bottom decile: +2.7% in $K_{p,att}$, −5.1% in $K_{p,pos}$, −8.1% in λ_{lin}), but it amounts to less than 8% of each parameter's range.

The performance gain therefore comes from a single operating point that dominates every fixed gain found by grid search, not from online adaptation to the disturbance regime. In this setting, RL acted as an effective optimizer of the controller parameters rather than as a gain scheduler.

5. Conclusion

This paper applied RL to optimize the gains and damper intensity of a TDC controller for an AUV subject to PTM reaction disturbances. In simulation, the learned parameters reduced position RMSE by 20.5% and vibration energy by 35.7% relative to the best grid-searched fixed gains, with a slight improvement in attitude RMSE. Analysis of the learned policy, however, showed that it converges to a near-constant operating point rather than scheduling gains according to the state. Achieving genuine state-dependent scheduling, for example by exploiting vehicle turn rate, and validating the controller on the physical BlueROV2 Heavy are left for future work.

Acknowledgment

This work was supported by the Korea Research Institute for Defense Technology Planning and Advancement (KRIT) – Grant funded by Defense Acquisition Program Administration (DAPA) (KRIT-CT-23-016, Simultaneous Localization and Mapping for UUV, 2026).

References

[1] K. Youcef-Toumi and O. Ito, “A time delay controller for systems with unknown dynamics,” ASME Journal of Dynamic Systems, Measurement, and Control, vol. 112, no. 1, pp. 133-142, 1990.

[2] T. I. Fossen, Handbook of Marine Craft Hydrodynamics and Motion Control, Wiley, 2011.

[3] J. Schulman, F. Wolski, P. Dhariwal, A. Radford, and O. Klimov, “Proximal policy optimization algorithms,” arXiv preprint arXiv:1707.06347, 2017.

[4] M. Timmerman, A. Patel, and T. Reinhart, “Adaptive gain scheduling using reinforcement learning for quadcopter control,” arXiv preprint arXiv:2403.07216, 2024.

[5] V. Makoviychuk et al., “Isaac Gym: High performance GPU-based physics simulation for robot learning,” arXiv preprint arXiv:2108.10470, 2021.

[6] S. Chu et al., “MarineGym: A high-performance reinforcement learning platform for underwater robotics,” arXiv preprint arXiv:2503.09203, 2025.

[7] T. Lee, M. Leok, and N. H. McClamroch, “Geometric tracking control of a quadrotor UAV on SE(3),” in Proc. 49th IEEE Conference on Decision and Control (CDC), 2010, pp. 5420-5425.

한국해양로봇기술연구회
2026 추계학술대회

A-P8

Tilt-Aware FFT-ICP Scan Registration for Pose-Graph SLAM with a Downward-Tilted Forward-Looking Sonar

김승민 · 박성민 · 김민종 · 유선철

포항공과대학교 (POSTECH)

Tilt-Aware FFT–ICP Scan Registration for Pose-Graph SLAM with a Downward-Tilted Forward-Looking Sonar

Seungmin Kim*, Seongmin Park**, Minjong Kim*, Son-Cheol Yu**
*Department of Convergence IT Engineering, Pohang University of Science and Technology (POSTECH)
**Department of Electrical Engineering, Pohang University of Science and Technology (POSTECH)

Key Words : Forward-Looking Sonar, Pose-Graph SLAM, Phase Correlation, Iterative Closest Point, Slant-Range Projection

Abstract : A forward-looking sonar (FLS) tilted toward the seafloor breaks the zero-elevation assumption of planar pose-graph simultaneous localization and mapping (SLAM) and biases the scale and overlap of scan registration. We propose a tilt-aware registration that combines fast Fourier transform (FFT) phase correlation with the iterative closest point (ICP) algorithm: it maps both registration inputs to ground-plane range, corrects the beam azimuth of the ICP input, trims ICP correspondences, and reinforces the FFT stage to reduce rejected estimates that fall back on odometry. In a cumulative simulation ablation, ground-plane projection, azimuth correction, and trimming reduced the median trajectory error of the conventional FFT–ICP registration by 79% and 71% on two trajectories (12.86 to 2.65 m and 11.76 to 3.44 m), and the proposed registration cut the odometry fallback rate from 73.6 and 81.8% to 0.4 and 5.4%; the FFT-stage reinforcement reduced fallbacks without a detected accuracy gain, and lost accuracy on Traj. II. A separate back-end trial keeping odometry factors and down-weighting loop closures brought the SLAM median to 0.36 m, overlapping its weak-drift odometry input (median 0.44 m). The evidence is limited to simulation.

1. Introduction

Underwater vehicles operate without GPS, so localization relies on sensors that tolerate turbid, low-visibility water. A forward-looking sonar (FLS) meets that requirement where optical cameras do not. FLS image registration underlies a lineage of pose-graph simultaneous localization and mapping (SLAM) systems [1, 2] that recover trajectories from sonar frames. In previous work [3], a coarse-to-fine registration method first estimated the inter-frame transform by phase correlation computed with the fast Fourier transform (FFT) [4] and then refined it with the iterative closest point (ICP) algorithm. It was evaluated only on frame pairs; SLAM was stated as future work.

One FLS pose-graph SLAM system confines the vehicle state to a plane and sets the sonar's elevation angle to zero because elevation is not recorded in its sonar imagery [5]. A sonar tilted down to observe the seafloor, where no vertical structure is in view [6], breaks that zero-elevation assumption. Prior work has addressed the elevation ambiguity by tracking optical-flow features into a terrain field for a similarly downward-tilted sonar [6], and by fusing the FLS with a second, narrow-beam sonar [7], without modifying the registration step itself. To the best of the authors' knowledge, no prior work quantifies the scale error slant-range projection introduces into FFT–ICP registration, the overlap loss from a body-fixed seafloor-return band, or the effect of either on pose-graph SLAM.

We identify the range mapping, used by both the FFT input image and the ICP point cloud (Fig. 1), as the stage where downward tilt enters registration, and we propose a tilt-aware FFT–ICP registration for pose-graph SLAM (Fig. 2). It maps both registration inputs to ground-plane range, corrects the beam azimuth of the ICP point cloud, trims ICP correspondences, and reinforces the FFT stage to reduce validation-gate rejections that trigger the odometry fallback. The contributions of this study are as follows:

1. **A geometric analysis of two tilt effects.** Under a flat-seafloor model, downward tilt introduces a projection scale factor, reflected in the FFT and ICP scale ratios, and an overlap effect hypothesized to bias the ICP estimate (Sections 3.2 and 3.3).
2. **The proposed registration in pose-graph SLAM.** Ground-plane projection with azimuth correction, trimmed ICP, and FFT-stage reinforcement each target one tilt effect or the odometry fallback, and replace the registration of a planar pose-graph SLAM system (Section 4).
3. **A simulation SLAM evaluation.** In a cumulative clean-odometry ablation (Table 1), ground-plane projection, azimuth correction, and trimming reduced the median absolute trajectory error (ATE) of the conventional FFT–ICP registration [3] by 79% and 71% on two trajectories, and the FFT-stage reinforcement cut odometry fallbacks to 0.4–5.4% with no detected gain and a Traj. II loss (Section 5).

* Seungmin Kim : +82-54-279-9525, luckkim123@postech.ac.kr
** Seongmin Park : +82-54-279-9525, psm9530@postech.ac.kr
* Minjong Kim : +82-54-279-9525, mjkim7108@postech.ac.kr
** Son-Cheol Yu (corresponding author) : +82-54-279-9504, sncyu@postech.ac.kr

2. Related Work

FLS registration methods include FFT-based phase correlation [4], sonar-specific feature descriptors [8], and a polar transform that decomposes registration into rotation and translation [9]. Graph matching avoids the local minima of non-convex ICP [10]. The previous FFT–ICP registration underlying this study belongs to this family [3], which aligns sonar images without modeling tilt-dependent range geometry.

The pose-graph SLAM lineage runs from imaging-sonar-aided navigation [1] to factor-graph formulations analyzing the sensor's degeneracies [2]. One representative system uses ICP scan-matching factors and consistency-filtered loop closures on a planar state [5]; this design has been verified only for that system.

Elevation ambiguity has been resolved by optical-flow tracking into a terrain field for a similarly downward-tilted sonar [6], and by fusing a forward-looking sonar with a second sonar [7]. A multibeam acoustic-lens sonar has separately generated three-dimensional point clouds from vehicle motion [11]. Side-scan mapping converts slant to ground range under an altitude-aided flat-floor assumption that sets object altitude to zero, and the resulting error has been quantified [12]; Eq. (1) applies the same correction to FLS registration. Such work recovers height by terrain inference or a second sensor, or quantifies flat-floor error, rather than correcting registration.

3. Pose-Graph SLAM and the Effect of Downward Tilt

3.1. Existing System

The baseline pipeline combines the frame-pair FFT–ICP registration of [3] with a planar pose-graph SLAM back end with the same factor types as [5] (grey blocks in Fig. 2). A smallest-of cell-averaging constant-false-alarm-rate (SOCA-CFAR) detector extracts feature points [5, 13] for the ICP point cloud. Phase correlation

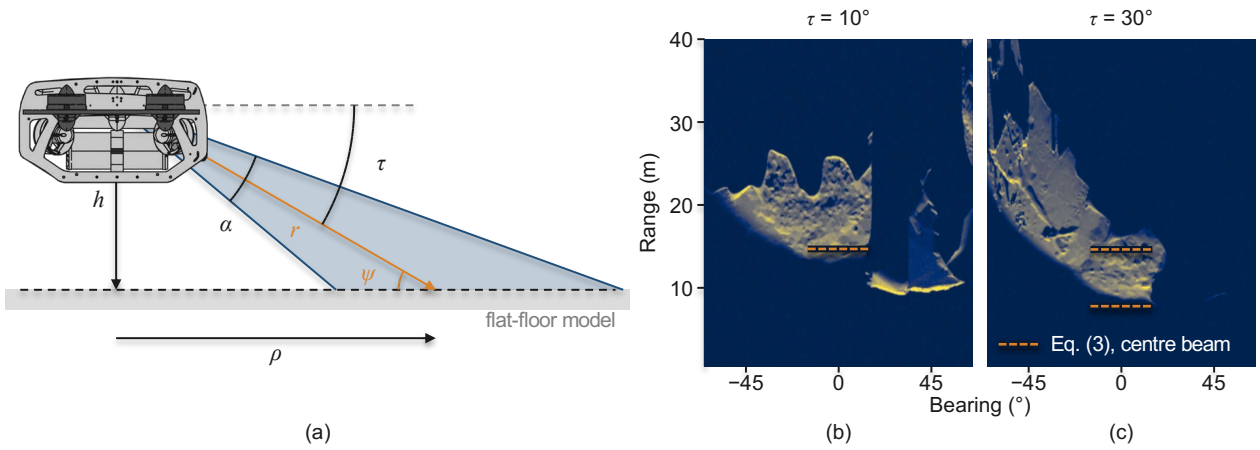

Fig. 1 (a) Downward-tilted forward-looking sonar on a BlueROV2 (schematic, not to scale; τ and α as in the simulation); (b), (c) recorded polar frames of Traj. III and Traj. I at 5.0 m altitude. Dashed lines are the band edges of Eq. (3) under the flat-seafloor model, which the structured simulated floor follows only approximately.

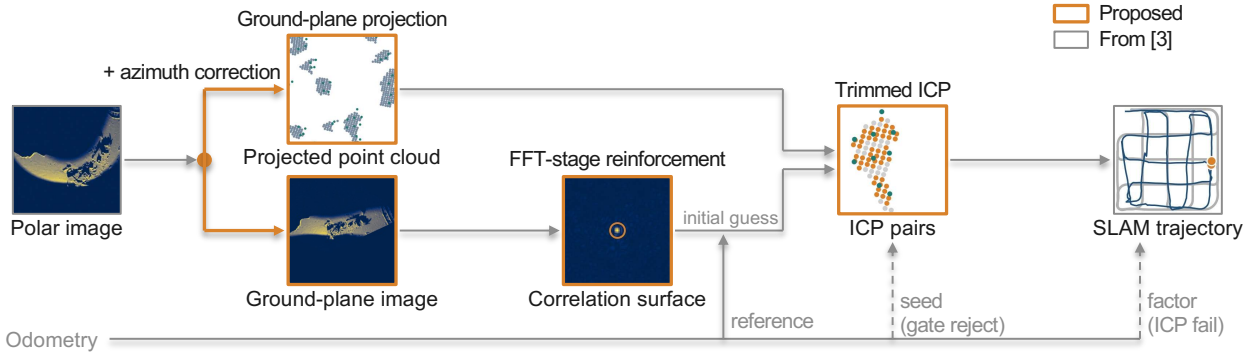

Fig. 2 Overview of the proposed tilt-aware registration in pose-graph SLAM. Highlighted blocks are proposed; grey blocks are the baseline. One range-to-ground projection feeds both the FFT and the ICP stage, and azimuth correction is applied to the point cloud only. For one Traj. I keyframe pair (orange marker on the trajectory), the zoomed ICP panel shows source points kept (orange) and dropped (grey) by trimming ($\gamma = 0.4$) against a target of three accumulated keyframes (cyan).

gives the FFT rotation on the polar image [4] and the translation on a range-mapped image. A fixed gate validates the FFT estimate against the odometry increment before it seeds ICP against recent keyframes [14, 15]; the refined transform forms the sequential factor.

Loop factors come from non-sequential scan matching: candidate keyframes within the field of view are selected by a bounded global search, re-selected by overlap, refined by ICP, checked by pairwise-consistent measurement-set filtering [16], and added with a robust kernel. Incremental smoothing and mapping optimizes the planar pose graph [17]. Odometry validates the FFT estimate, seeds ICP when the gate rejects it, and replaces the registration factor only when ICP initialization or validation fails (Fig. 2).

3.2. Slant-Range Scale Bias

Under a flat-seafloor model (Fig. 1), downward tilt introduces one systematic scale error and one overlap effect into FFT–ICP registration. A sonar return at slant range r maps to a ground-plane range

$$\hat{\rho} = \sqrt{r^2 - h^2}, \tag{1}$$

where h is the altimeter altitude, taken as the sonar's altitude above the floor in level flight, and $\hat{\rho}$ is the flat-floor ground-plane range.

A range mapping $\hat{\rho}(r)$ scales a return's true radial displacement by

$$s = \frac{d\hat{\rho}}{dr} \cdot \frac{\rho}{r}, \tag{2}$$

where $\rho = r\cos\psi$ is the true ground-plane range, ψ is the ray depression angle below horizontal with $\sin\psi = h/r$, and s is the registered-to-true displacement ratio along the beam, per return. Eq. (1) gives $s = 1$ within these assumptions; at $\hat{\rho} = r$, $s = \cos\psi$; at $\hat{\rho} = r\cos\tau$, $s = \cos\tau\cos\psi$, where τ is the tilt below horizontal.

The baseline applies both mappings: the ICP point cloud uses $\hat{\rho} = r$ and the FFT input image uses $\hat{\rho} = r\cos\tau$. Both are the zero-elevation assumption of Section 1, for a level and a τ-tilted sensor plane, and both scale radial displacement down. The FFT translation, scaled by the smaller factor, falls short of odometry by $1 - s$. Once it exceeds the fixed position gate (Section 5.1), the odometry fallback replaces the estimate. The FFT scale ratio of Table 2, taken over all attempted pairs before the gate, reflects this bias in part; the ICP ratio also reflects the azimuth correction (Section 4.1).

3.3. Seafloor-Return Band and Overlap

Under the same flat-seafloor, ideal-aperture model, a seafloor-viewing sonar's returns fall within a slant-range band

$$r \in \left[\frac{h}{\sin(\tau + \alpha/2)}, \frac{h}{\sin(\tau - \alpha/2)}\right], \tag{3}$$

where α is the sonar's vertical aperture and the ray depression angle spans $\psi \in [\tau - \alpha/2,\ \tau + \alpha/2]$; this far edge is finite only when $\tau > \alpha/2$, and otherwise the sonar's range window sets the band instead. This band is fixed to the vehicle body rather than to the seafloor, so the imaged patch shifts forward with the keyframe-to-keyframe

displacement instead of remaining centered on a common footprint. If the returns are assumed to be spread evenly across the band, and cross-track and terrain-relief effects are neglected, the overlap between two keyframes shrinks as their along-track displacement grows relative to the band's along-track ground length. Points falling outside the shared overlap enter spurious nearest-neighbor correspondences, which can bias the recovered ICP translation.

The baseline's ICP keeps a fraction $\gamma = 0.8$ of the correspondences and can therefore retain points outside the shared overlap.

4. Proposed Tilt-Aware Registration

We propose three components that change the registration front end and leave the back end of Section 3.1 unchanged (highlighted blocks in Fig. 2). Ground-plane projection with azimuth correction targets the slant-range scale bias of Section 3.2. Trimmed ICP targets the overlap effect of Section 3.3. FFT-stage reinforcement targets the validation-gate rejections that trigger the odometry fallback.

4.1. Ground-Plane Projection with Azimuth Correction

We apply Eq. (1), using the altimeter reading (the FFT image reuses its mapping until the altitude crosses a 0.25 m step), to both the FFT input image and the ICP point cloud, replacing the two baseline range mappings of Section 3.2 with one shared convention. A beam-azimuth correction restores the horizontal bearing of returns seen by a tilted beam, since the ICP point cloud is otherwise drawn with horizontal-plane bearings. A floor point (X, Y, h) appears at beam azimuth $\beta = \operatorname{atan2}(Y,\ X\cos\tau + h\sin\tau)$; its closed-form inverse is the horizontal bearing $\phi = \arcsin\!\left(c/\sqrt{1+b^2}\right) + \arctan b$, $b = \tan\beta\cos\tau$, $c = \tan\beta\, h\sin\tau/\hat{\rho}$, with the configured tilt τ, altimeter reading h, and $\hat{\rho}$ of Eq. (1); without altitude, no correction applies. It has no free parameter. We apply it to the ICP point cloud only, as it hurt FFT phase correlation in a preliminary trial; +GP adds it with the projection (Table 1).

4.2. Trimmed ICP

We compute the ICP estimate with a trimmed objective

$$E(\mathbf{T}) = \sum_{i=1}^{\lfloor \gamma N \rfloor} \left\| \mathbf{T}(\mathbf{p}_{(i)}) - \mathbf{q}_{(i)} \right\|^2, \tag{4}$$

where $\mathbf{T} \in SE(2)$ is the planar rigid transform being estimated, $\{(\mathbf{p}_i, \mathbf{q}_i)\}_{i=1}^{N}$ are the N correspondences found within the search radius, ordered by increasing residual so that $(\cdot)_{(i)}$ denotes the i-th smallest, and γ is the kept fraction, following the trimmed-objective form of [18]. We fix γ rather than estimate it. A maximum-distance outlier gate is applied jointly with trimming [15], so the kept share is at most γ; the search radius and this gate are held at the same values in every configuration (Section 5.1). Trimming tolerates the partial overlap of Section 3.3; +Trim lowers γ from 0.8 to 0.4.

4.3. FFT-Stage Reinforcement

We reinforce the FFT stage with four measures, added one at a time as configurations (Table 1). (i) +MultiRot: among K rotation hypotheses extracted from the polar-image phase correlation, we carry each candidate to translation and keep the one with the strongest translation-correlation peak, because a single global rotation peak of the polar correlation surface was often wrong at the working tilt. (ii) +Filter: we apply a low-pass mask, switch contrast-limited adaptive histogram equalization (CLAHE) off, and add a Hann window to the translation cross-power spectrum, all three together. The mask suppresses the high-frequency speckle that makes up a large share of that spectrum at the working tilt; CLAHE adds noise to correlations of mostly blank images; the window limits leakage at the zero-padded border. (iii) +Rewarp: for a pair the validation gate rejects, one inverse-warp re-estimation re-aligns the polar images using the rejected estimate and repeats the phase correlation, to recover some rejected pairs. (iv) Proposed: sub-pixel peak localization uses a parabolic fit in place of upsampled discrete Fourier transform (DFT) refinement. Proposed thus has all three components.

Config.	Adds
Baseline	registration settings of [3] ($\gamma = 0.8$, $K = 1$)
+GP	ground-plane projection and azimuth correction
+Trim	trimmed ICP, $\gamma = 0.4$
+MultiRot	$K = 9$ rotation hypotheses
+Filter	low-pass mask, CLAHE off, Hann window
+Rewarp	inverse-warp re-estimation
Proposed	parabolic sub-pixel peak

Table 1 Configurations of the cumulative ablation; each row adds one step to the previous row.

5. Experiments

5.1. Setup and Metrics

Runs used Stonefish [19], a BlueROV2 model, and a 512-beam sonar with $130° \times 20°$ aperture and 0.5–40 m range window. The simulated floor is a static rock-and-structure mesh; its height under the vehicle spans about 5 m (5th–95th percentile), comparable to the 4.6–6.4 m median altitude, so the flat-seafloor model of Section 3.2 holds only approximately. Recorded lawnmower trajectories are Traj. I (640 s) and Traj. II (336 s), both at 30° tilt, and Traj. III at 10°. Seven configurations, Baseline to Proposed (Table 1, Fig. 2), each add one step; Baseline uses the registration settings of the previous study [3] on the present back end and is no reproduction. The search radius (10.0 m), outlier gate (3.0 m), keyframe rule, validation gate, pairwise-consistency set size, ICP convergence threshold, and planar iSAM2 were fixed across configurations, Baseline included. The gate passes an FFT estimate within 0.25 m and 10° of the odometry increment, a keyframe needs at least 1 s and more than 1 m of motion or 10° of rotation, and ICP matches three previous keyframes.

Traj. II informed projection mode, γ, and K (Baseline to +MultiRot) and is held out only for +Filter, +Rewarp, and Proposed, whose settings, the ICP-only azimuth correction, and the pairwise-consistency set size were tuned on Traj. I. Their agreement is consistency, not validation on unseen data.

Clean odometry is the simulator ground-truth pose, so errors are optimistic. Drifting odometry perturbs only the SLAM input, with a 2% (weak) or 10% (strong, author-chosen) translation scale error and a heading random walk of 0.1 or $0.5°/\sqrt{\text{s}}$; evaluation uses clean ground truth. The weak level is about twice the ±1.01% long-term accuracy of a Doppler velocity log (DVL) of this class [20], and its heading error reaches about 2.5° (1σ) at the end of Traj. I, like a calibrated magnetic compass's 1–3° accuracy [21]; since aided heading error is bounded, the walk is conservative. Drift runs used Traj. I with same-queue clean runs; configurations shared noise realizations by round (Table 3).

Metrics. Each configuration ran $n = 4$ times in one queue per trajectory, cyclically shifted between rounds. ATE RMSE pairs each final SLAM keyframe with ground truth at its sensor time before one whole-run SE(2) alignment, the same for SLAM and odometry input. Fallback rate is the share of registrations seeded by odometry after the gate rejects the FFT estimate. FFT and ICP scale ratios are medians of the four run-wise medians of estimated over true translation over attempted pairs (FFT, before the gate) and refinements (ICP); pair sets differ by configuration. ICP converged in every refinement; odometry factors were at most 4.2% of sequential factors (not Proposed†). Cells are median [min, max]; the only (low-power) test is complete separation, i.e., non-overlapping ranges, with exact two-sided $p = 2/70$, or $2/16 = 0.125$, the smallest attainable, between drift configurations paired by round, unadjusted for multiplicity. Pre-declared comparisons were ATE for Baseline vs +Trim and +Trim vs Proposed on Traj. I and II, the fallback rate of Proposed vs +MultiRot, and, under weak drift, Proposed vs clean-odometry Proposed, vs Baseline, and vs +Trim (declared before its added runs; Proposed vs +MultiRot secondary); all other comparisons, the strong-drift level, and the

Config.	ATE RMSE (m)	Fallback (%)	FFT scale	ICP scale
Traj. I				
Baseline	12.86 [12.19, 14.28]	73.6 [73.5, 74.4]	0.719	0.795
+GP	9.50 [8.84, 10.14]	61.1 [61.0, 61.1]	0.918	0.895
+Trim	2.65 [2.10, 3.30]	61.4 [61.1, 61.6]	0.914	0.994
+MultiRot	2.68 [2.21, 2.86]	4.1 [4.0, 4.5]	0.935	0.958
+Filter	2.59 [2.29, 2.81]	2.0 [1.7, 2.0]	0.931	0.958
+Rewarp	2.58 [2.14, 4.67]	0.3 [0.3, 0.3]	0.930	0.950
Proposed	2.35 [2.10, 2.52]	0.4 [0.0, 0.6]	0.932	0.950
Traj. II				
Baseline	11.76 [11.25, 12.37]	81.8 [81.5, 81.8]	0.741	0.766
+GP	11.37 [10.99, 11.53]	61.5 [61.3, 61.5]	0.883	0.833
+Trim	3.44 [3.23, 3.55]	61.5 [61.3, 61.8]	0.883	0.985
+MultiRot	3.29 [3.08, 3.94]	14.4 [14.4, 14.4]	0.913	0.940
+Filter	3.63 [3.11, 3.96]	8.0 [7.0, 10.2]	0.924	0.939
+Rewarp	3.70 [2.97, 3.83]	5.7 [4.3, 5.9]	0.921	0.934
Proposed	4.08 [3.72, 4.30]	5.4 [4.8, 7.0]	0.926	0.936

Table 2 Cumulative ablation on Traj. I and II (median [min, max], $n = 4$; scale ratios: median of the four run medians).

odometry input, declared without a decision rule, are descriptive.

5.2. Contribution of Each Component

Compared with the conventional FFT–ICP registration [3] (Baseline), +Trim reduces the median ATE by 79% and 71% on Traj. I and II with non-overlapping ranges (Table 2, Figs. 3(a) and 4), and the FFT stage adds no detected gain (Proposed 82% and 65%); the larger step is +GP to +Trim. Projection in +GP raises the FFT scale ratio but keeps the trimming of the baseline ($\gamma = 0.8$). Trimming in +Trim drops the largest-residual correspondences and raises the ICP scale ratio to 0.985–0.994, consistent with removing those lost to the body-fixed band (Section 3.3). Descriptively, keyframe-path length over true length rises from Baseline to +GP to +Trim (Traj. I 0.715, 0.842, 0.934; Traj. II 0.773, 0.834, 0.922), though on both +Trim is closer to one than Proposed (0.917 and 0.890). Most of the accuracy gain therefore appears with trimming, whose mechanism is not separated.

Proposed lowers the fallback rate from 61.4 and 61.5% (+Trim) to 0.4 and 5.4%, entirely below +MultiRot on both trajectories, yet the ATE of +Trim and Proposed overlaps on Traj. I. Under clean odometry, a fallback seeds ICP with the simulator's exact motion, so an FFT seed cannot be expected to lower ATE. The FFT-stage gain is therefore fewer fallbacks; its accuracy benefit can show only under drifting odometry (Section 5.3).

On Traj. II, Proposed lies entirely above +Trim (4.08 vs. 3.44 m), possibly because under-scaled FFT seeds replace exact odometry seeds (untested). On Traj. I, scale ratios near one mean scale bias alone does not explain the ATE floor, whose origin is not established. The Traj. II result limits the FFT-stage claim to fewer fallbacks.

5.3. Tilt Angle and Odometry Drift

Proposed lowers the fallback rate of Baseline from 40.4 to 0.9% at 10° (Traj. III), while their ATE overlaps (Table 3, Fig. 3(c)). At this tilt τ does not exceed $\alpha/2$, so under the flat-seafloor model the band has no finite far edge (Section 3.3); in recorded frames it reaches about 26 m at the centre beam (16 m at 30°) (Fig. 1). Traj. III's path differs from Traj. I and II, so the overlap is not attributed to tilt alone.

In the drift queue, Proposed cuts Baseline's median ATE by 80%, 86%, and 75% under clean, weak, and strong odometry (Fig. 3(b)), and its median fallback rate is at most 1.6%, so nearly all ICP refinements start from FFT estimates, not the drifting stream. Under weak drift, +Trim and Proposed overlap (1.93 vs. 1.99 m), as do +MultiRot and Proposed, so no FFT-stage accuracy gain is detected.

The odometry input lies entirely below every default-back-end configuration in Table 3 under weak drift and overlaps Proposed under strong drift. Proposed† (odometry factors kept, loop closures down-weighted) lowered the weak-drift median from 2.39 to 0.36 m (same-noise input 0.44 m), with a setting tuned on Traj. I only.

Config.	ATE RMSE (m)	Fallback (%)
Traj. III, clean		
Baseline	0.88 [0.86, 0.94]	40.4 [40.4, 40.6]
Proposed	0.71 [0.66, 1.21]	0.9 [0.4, 1.3]
Traj. I, clean		
Baseline	12.48 [11.22, 14.88]	73.6 [73.5, 73.6]
+MultiRot	2.44 [2.34, 2.50]	4.8 [4.0, 5.1]
Proposed	2.52 [2.05, 2.64]	0.3 [0.0, 0.9]
Traj. I, weak drift		
Odom. input	0.44 [0.36, 0.65]	n/a
Baseline	13.93 [8.52, 15.90]	78.1 [77.1, 78.2]
+Trim	1.93 [1.55, 3.57]	64.4 [63.6, 65.9]
+MultiRot	2.15 [1.99, 2.41]	4.8 [4.5, 7.1]
Proposed	1.99 [1.77, 2.70]	0.3 [0.0, 0.6]
Proposed†	0.36 [0.30, 0.38]	0.6 [0.0, 1.1]
Traj. I, strong drift		
Odom. input	2.28 [1.85, 3.29]	n/a
Baseline	10.43 [8.60, 12.76]	83.0 [81.4, 83.8]
Proposed	2.62 [2.42, 3.09]	1.6 [0.3, 2.1]

Table 3 Tilt and odometry-drift conditions (median [min, max], $n = 4$). Traj. I clean rows come from the drift run queue, apart from Table 2. †Modified back end, separate queue (its Proposed 2.39 m).

6. Conclusion

Compared with the conventional FFT–ICP registration, ground-plane projection and azimuth correction followed by trimming reduced the median trajectory error of planar pose-graph SLAM by 79% and 71% on two simulated trajectories, and the FFT-stage reinforcement then cut the odometry fallback rate from 61.4 and 61.5% to 0.4 and 5.4% (73.6 and 81.8% for the conventional registration).

Limitations are the simulation-only evidence with clean ground-truth odometry, the unseparated effect of floor-height variation on the scale ratios, a back-end change, tested on Traj. I only, to approach weak-drift odometry, and no detected accuracy gain from the FFT stage, whose full configuration lay above +Trim on partially held-out Traj. II.

Future work covers real DVL and inertial odometry, field data, trajectories unused for any setting choice, seafloor relief varied in a controlled way, and uncertainty-weighted registration factors.

Acknowledgment

This work was supported by the Korea Research Institute for Defense Technology Planning and Advancement (KRIT) – Grant funded by Defense Acquisition Program Administration (DAPA) (KRIT-CT-23-016, Simultaneous Localization and Mapping for UUV, 2026).

References

[1] Johannsson, H., Kaess, M., Englot, B., Hover, F., and Leonard, J., "Imaging Sonar-Aided Navigation for Autonomous Underwater Harbor Surveillance", Proc. 2010 IEEE/RSJ International Conference on Intelligent Robots and Systems, 2010, pp. 4396–4403.

[2] Westman, E. and Kaess, M., "Degeneracy-Aware Imaging Sonar Simultaneous Localization and Mapping", IEEE Journal of Oceanic Engineering, Vol. 45, No. 4, 2020, pp. 1280–1294.

[3] Kim, M.-J., Kim, S.-M., and Yu, S.-C., "Robust Underwa-

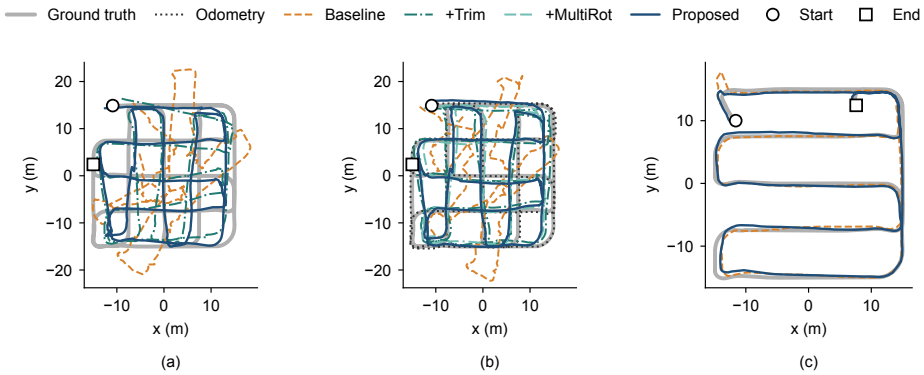

Fig. 3 Top-view trajectories after SE(2) alignment: (a) Traj. I, clean odometry; (b) Traj. I, weak drift; (c) Traj. III ($\tau = 10°$), clean odometry. Each curve is one representative replicate.

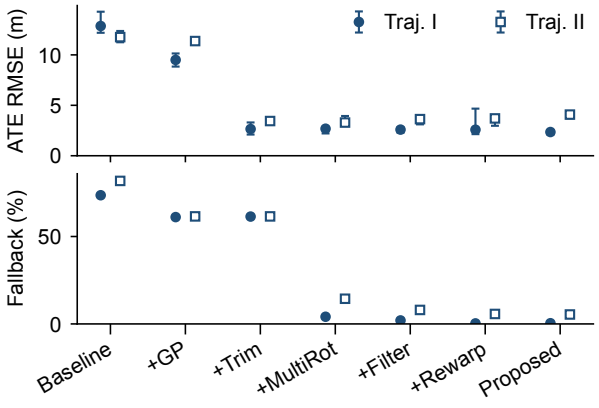

Fig. 4 ATE RMSE (top) and fallback rate (bottom) of the seven configurations on Traj. I and II (median and min–max, $n = 4$).

ter Robot Localization via Frequency-Spatial Domain Fusion of Imaging Sonar Data", Proc. 2025 Fall Conference of the Korean Marine Robot Technology Society (KMRTS), Daegu, Korea, 2025, pp. 135–138.

[4] Hurtós, N., Ribas, D., Cufí, X., Petillot, Y., and Salvi, J., "Fourier-based Registration for Robust Forward-looking Sonar Mosaicing in Low-visibility Underwater Environments", Journal of Field Robotics, Vol. 32, No. 1, 2015, pp. 123–151.

[5] McConnell, J., Chen, F., and Englot, B., "Overhead Image Factors for Underwater Sonar-Based SLAM", IEEE Robotics and Automation Letters, Vol. 7, No. 2, 2022, pp. 4901–4908.

[6] Wang, J., Shan, T., and Englot, B., "Underwater Terrain Reconstruction from Forward-Looking Sonar Imagery", Proc. 2019 International Conference on Robotics and Automation (ICRA), 2019, pp. 3471–3477.

[7] Joe, H., Cho, H., Sung, M., Kim, J., and Yu, S.-C., "Sensor Fusion of Two Sonar Devices for Underwater 3D Mapping with an AUV", Autonomous Robots, Vol. 45, No. 4, 2021, pp. 543–560.

[8] Aykin, M.D. and Negahdaripour, S., "On Feature Matching and Image Registration for Two-dimensional Forward-scan Sonar Imaging", Journal of Field Robotics, Vol. 30, No. 4, 2013, pp. 602–623.

[9] Zhang, J., Sohel, F., Bian, H., Bennamoun, M., and An, S., "Forward-Looking Sonar Image Registration Using Polar Transform", Proc. OCEANS 2016 MTS/IEEE Monterey, 2016, pp. 1–6.

[10] Zhuang, L., Chen, X., Lu, W., and Yan, Y., "Graph Matching for Underwater Simultaneous Localization and Mapping Using Multibeam Sonar Imaging", Journal of Marine Science and Engineering, Vol. 12, No. 10, 2024, pp. 1859.

[11] Cho, H., Kim, B., and Yu, S.-C., "AUV-Based Underwater 3-D Point Cloud Generation Using Acoustic Lens-Based Multibeam Sonar", IEEE Journal of Oceanic Engineering, Vol. 43, No. 4, 2018, pp. 856–872.

[12] Burguera, A. and Oliver, G., "High-Resolution Underwater Mapping Using Side-Scan Sonar", PLOS ONE, Vol. 11, No. 1, 2016, pp. e0146396.

[13] Weiss, M., "Analysis of Some Modified Cell-Averaging CFAR Processors in Multiple-Target Situations", IEEE Transactions on Aerospace and Electronic Systems, Vol. AES-18, No. 1, 1982, pp. 102–114.

[14] Besl, P.J. and McKay, N.D., "A Method for Registration of 3-D Shapes", IEEE Transactions on Pattern Analysis and Machine Intelligence, Vol. 14, No. 2, 1992, pp. 239–256.

[15] Pomerleau, F., Colas, F., Siegwart, R., and Magnenat, S., "Comparing ICP Variants on Real-World Data Sets", Autonomous Robots, Vol. 34, No. 3, 2013, pp. 133–148.

[16] Mangelson, J.G., Dominic, D., Eustice, R.M., and Vasudevan, R., "Pairwise Consistent Measurement Set Maximization for Robust Multi-Robot Map Merging", Proc. 2018 IEEE International Conference on Robotics and Automation (ICRA), 2018, pp. 2916–2923.

[17] Kaess, M., Johannsson, H., Roberts, R., Ila, V., Leonard, J.J., and Dellaert, F., "iSAM2: Incremental Smoothing and Mapping Using the Bayes Tree", The International Journal of Robotics Research, Vol. 31, No. 2, 2012, pp. 216–235.

[18] Chetverikov, D., Svirko, D., Stepanov, D., and Krsek, P., "The Trimmed Iterative Closest Point Algorithm", Proc. 16th International Conference on Pattern Recognition (ICPR), 2002, pp. 545–548.

[19] Cieślak, P., "Stonefish: An Advanced Open-Source Simulation Tool Designed for Marine Robotics, With a ROS Interface", Proc. OCEANS 2019 – Marseille, 2019, pp. 1–6.

[20] Water Linked AS, "DVL A50 Datasheet", Document revision WL-21035-4--DVL-A50-Datasheet--v5, [Online]. Available: https://www.waterlinked.com/datasheets/dvl-a50 (Accessed Sep. 11, 2026).

[21] Kinsey, J.C., Eustice, R.M., and Whitcomb, L.L., "A Survey of Underwater Vehicle Navigation: Recent Advances and New Challenges", Proc. 7th IFAC Conference on Manoeuvring and Control of Marine Craft (MCMC), Lisbon, Portugal, 2006.

학술세션 B

B-P1	대양전기공업(주) 수중로봇 솔루션	93
B-P2	AUV 도킹 유도를 위한 딥러닝 기반 레이저 광원-끝점 검출	97
B-P3	무인수상선 해상시험을 위한 무인기 자율 추종 및 공중 영상 관제 기술	103
B-P4	임의 단일 물체의 자율 시각 커버리지를 위한 학습 기반 경로계획기	109
B-P5	Investigation of Effective State Representation for Side-Scan Sonar SLAM Under Elevation Degeneracy	117
B-P6	BB2 세일 후류 압력장 기반 AUV 상대 위치 추정 모델 개발	125
B-P7	외란 관측기 기반 모델 예측 제어를 이용한 무인수상정의 강인 궤적 추종	135
B-P8	피드백 기반 인식 정제를 통한 열악한 해상 환경에서의 강인한 카메라-레이다 융합	141

B-P1

대양전기공업(주) 수중로봇 솔루션

정수남

대양전기공업(주)

DAEYANG

수중로봇

- 수중로봇 개발 내역
- 구조함 탑재 한국형 수중무인탐사기(KROV)
- 2500미터급 동력형 수중자율이동체(PCAUV)
- 무인기뢰처리기(MDV)

한국해양로봇기술연구회
2026 추계학술대회

B-P2

AUV 도킹 유도를 위한 딥러닝 기반 레이저 광원-끝점 검출

Deep Learning-Based Laser Source-Endpoint Detection for AUV Docking Guidance

유수빈 · 길상민 · 권승곤 · 손현중 · 강진일

(주)볼시스 기업부설연구소

AUV 도킹 유도를 위한 딥러닝 기반 레이저 광원-끝점 검출

유수빈 · 길상민 · 권승곤 · 손현중 · 강진일
㈜볼시스 기업부설연구소

Deep Learning-Based Laser Source - Endpoint Detection for AUV Docking Guidance

Su-Bin Yu, Sang-Min Gil, Seung-Gon Kwon, Hyeon-Joong Son, Jin-Il Kang
BORSYS Corporate R&D Center

Key Words : AUV, Docking Guidance, Laser Direction Estimation, Deep Learning, Keypoint Detection

Abstract : *This paper introduces a deep learning-based laser direction estimation method for AUV docking guidance. A two-stage cascaded framework combining YOLOv8s and RTMPose-t is employed to detect the laser region and estimate the coordinates of the light source and endpoint. The laser direction angle is then calculated using the camera's field of view (FOV). To this end, endpoint labels are added to the existing ULDB dataset, and labeling criteria are established through preliminary experiments to construct a keypoint dataset of 1,226 images. Experimental results show that YOLOv8s achieves an mAP50 of 0.9938, while RTMPose-t achieves a mean angle error of 2.14° and an Acc@10° of 98.9%. The integrated pipeline also demonstrates laser direction angle estimation and alignment-state identification in frontal observations. The proposed method provides both position and direction information of underwater lasers and can be applied to AUV docking guidance.*

1. 서론

자율무인잠수정(Autonomous Underwater Vehicle, AUV)의 장기운용에 필요한 배터리 충전과 데이터 전송을 위해 정밀하고 안정적인 도킹 기술이 요구된다[1]. 원거리 접근에는 USBL(Ultra-Short Baseline)과 같은 음향 기반 위치 추정 기술이 활용되지만, 도킹 스테이션 인근에서는 다중경로 반사와 측정 오차로 인해 정밀도가 저하될 수 있다. 이에 따라 종말 단계 접근에서는 카메라 기반 도킹 유도 기술이 연구되고 있다[2].

기존 광학 기반 도킹 유도에서는 주로 LED 광원의 영상 내 위치를 이용하여 수중 로봇의 접근 방향을 판단하였으며[3][4][5], 딥러닝 기반 수중 광학 비콘 검출 방법도 연구되었다[6]. 그러나 LED 광원은 지향성이 낮아 광원의 방향 정보를 직접 추정하기 어렵고, 수중환경의 반사광과 빛의 산란은 광원 검출의 정확도를 저하시킬 수 있다. 이에 본 연구에서는 LED보다 높은 지향성을 갖는 레이저 광원을 활용하여 광원의 위치와 방향 정보를 함께 추정하고, 이를 AUV 도킹 유도에 활용하는 방법을 제안한다.

수중 무선 광통신(Underwater Wireless Optical Communication, UWOC) 분야에서는 2단계 Cascaded Framework를 이용한 레이저 광원 검출 방법이 제안되었으나[7], 광원의 위치만으로는 레이저 진행 방향을 추정하는 데 한계가 있었다.

본 연구에서는 기존 Cascaded Framework를 광원과 끝점의 두 특징점 검출 구조로 확장하였다. 먼저 YOLOv8s[8]를 이용하여 레이저 영역을 검출하고, RTMPose-t[9]를 적용하여 광원과 끝점의 좌표를 추정한다. 이후 카메라의 시야각(Field of View, FOV) 정보를 기반으로 레이저의 방향각을 산출한다. 이를 위해 UWOC Light Source Detection Benchmark(ULDB) 데이터셋[7]에 끝점 라벨을 추가하고, 일관된 특징점 추정을 위한 라벨링 기준을 수립하였다. 마지막으로 제안 기법의 검출 및 방향각 추정 성능을 정량적으로 평가하고, AUV 도킹 유도에 대한 적용 가능성을 검토하였다.

* 유수빈 : ㈜볼시스 기업부설연구소 051-404-3120, *make@borsys.kr*
* 강진일 : ㈜볼시스 기업부설연구소 051-403-3100, contact*@borsys.kr*

2. 제안 방법

2.1 ULDB 데이터셋 구성 및 끝점 라벨링

본 연구에서는 레이저 방향을 추정하기 위해 ULDB 데이터셋[7]에 끝점 라벨을 추가하였다. 기존 데이터셋의 학습, 검증 및 시험 데이터 분할과 바운딩박스 및 광원 라벨을 활용하고, 레이저 방향을 나타내는 끝점 라벨을 추가하였다. 이때 빛 번짐과 반사, 정면 관측 상태를 고려하여 라벨링 기준을 수립하였으며, 최종적으로 적용한 기준은 다음과 같다.

a. 방향이 명확한 영상
레이저 방향이 명확하게 식별되는 영상에서는 레이저와 바운딩박스 경계가 만나는 지점을 끝점으로 정의하였다. 영상 내부의 선명한 지점을 끝점으로 지정할 경우 빛의 산란과 번짐 정도에 따라 라벨 위치가 달라질 수 있으므로, 바운딩박스 경계를 기준으로 끝점 위치의 일관성을 확보하였다.

b. 방향 판별이 어려운 영상
심한 빛 번짐이나 반사광으로 레이저 방향을 판단하기 어려운 영상은 RTMPose-t 학습 및 평가에서 제외하였다. 다만 빛 번짐이나 반사가 일부 존재하더라도 레이저 방향이 명확한 경우에는 끝점을 지정하여 데이터에 포함하였다.

c. 정면 관측 영상
레이저 방향과 카메라 관측 방향이 정렬된 경우에는 레이저가 선 형태가 아닌 원형 또는 점 형태에 가깝게 관측된다. 이 경우 별도의 끝점을 정의하기 어렵지만, 도킹 방향이 정렬된 상태로 해석할 수 있다. 따라서 정면 관측 영상은 광원과 끝점을 동일한 좌표로 지정하여 데이터에 포함하였다.

d. 배경 영상
레이저가 존재하지 않는 영상은 배경 영상으로 구분하였다. 배경 영상에는 바운딩박스와 특징점 라벨을 부여하지 않았다. 해당 영상은 배경 영상에서 레이저를 잘못 검출하는 현상을 줄이기 위해 YOLOv8s 학습에 포함하였다. 유효한 특징점이 존재하지 않으므로 RTMPose-t 학습 및 평가에서는 제외하였다.

한국해양로봇기술연구회 2026년 추계학술대회 (2026. 11. 13(금) / 부산항국제전시컨벤션센터(부산))

이를 통해 끝점 라벨의 일관성을 확보하고, 방향 판별이 어려운 데이터의 학습 영향을 줄이고자 하였다.

2.2 딥러닝 기반 광원 - 끝점 특징점 검출

본 연구에서는 수중 레이저 영역과 광원 및 끝점을 검출하기 위해 객체 검출과 특징점 검출을 결합한 2단계 Cascaded Framework[7]를 적용하였다. 첫 번째 단계에서는 YOLOv8s[8]로 입력 영상의 레이저 영역을 검출하고, 두 번째 단계에서는 RTMPose-t[9]로 검출 영역 내 광원과 끝점의 좌표를 추정한다. 이후 두 특징점의 좌표를 이용하여 레이저 방향각을 산출하며, 전체 처리 과정은 그림 1에 나타내었다.

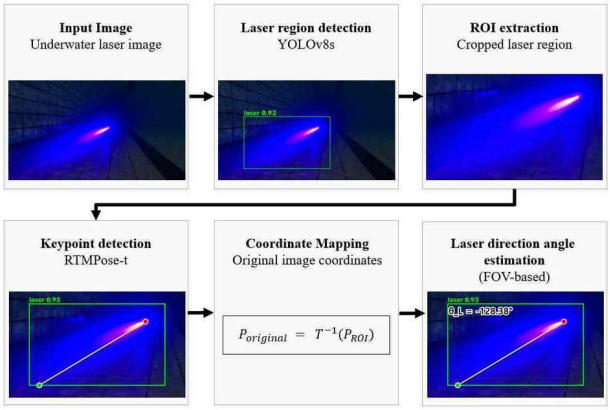

그림 1 제안한 레이저 방향 추정 파이프라인

YOLOv8s는 입력 영상을 320×320 크기로 변환하여 레이저 영역을 검출한다. 검출된 레이저 영역을 관심 영역(Region of Interest, ROI)으로 추출한 후 256×256 크기로 변환하여 RTMPose-t에 입력한다. RTMPose-t가 예측한 광원과 끝점의 좌표는 원본 영상 좌표계로 역변환하여 레이저 방향각 산출에 사용한다. YOLOv8s는 기존 레이저 영역 라벨을, RTMPose-t는 기존 광원 라벨과 추가한 끝점 라벨을 이용하여 각각 학습하였다.

2.3 카메라 시야각 기반 레이저 방향각 산출

본 연구에서는 카메라 시야각 기반 단일 광원 위치 산출 방법[5]을 광원과 끝점의 두 특징점에 확장 적용하여 레이저 방향각을 산출한다.

입력 영상의 해상도 $W \times H$, 영상 중심 좌표 $c_x = W/2$, $c_y = H/2$, 카메라의 수평 및 수직 시야각을 FOV_x, FOV_y라 하면, 영상 좌표를 각도 좌표로 변환하기 위한 계수 k_x, k_y는 다음과 같다.

$$k_x = \frac{W}{2\tan\left(\frac{FOV_x}{2}\right)}, \qquad k_y = \frac{H}{2\tan\left(\frac{FOV_y}{2}\right)} \tag{1}$$

영상 내 특징점 (x, y)의 수평각 α와 수직각 β는 다음과 같이 계산한다.

$$\alpha = \tan^{-1}\left(\frac{x - c_x}{k_x}\right), \qquad \beta = \tan^{-1}\left(\frac{c_y - y}{k_y}\right) \tag{2}$$

수평각과 수직각은 각각 오른쪽과 위쪽을 양의 방향으로 정의한다. 광원과 끝점의 각도 좌표를 (α_s, β_s), (α_e, β_e)라 하면, 레이저 방향각 θ_L은 수직 상단 0°를 기준으로 시계 방향을 양의 방향으로 하여 다음과 같이 계산한다.

$$\theta_L = \mathrm{atan2}(\alpha_e - \alpha_s,\ \beta_e - \beta_s) \tag{3}$$

산출된 레이저 방향각은 카메라 시야각을 반영한 레이저 방향을 나타내며, AUV의 이동 방향 판단에 활용할 수 있다.

본 연구는 레이저 방향각 산출까지를 대상으로 하며, 구체적인 도킹 제어 명령과 제어 성능 검증은 향후 연구 범위로 한다.

3. 실험 및 결과

3.1 데이터 구성 및 평가 방법

3.1.1 데이터셋 및 실험 구성

실험에는 총 2,200장의 수중 레이저 영상으로 구성된 ULDB 데이터셋을 사용하였으며, 기존 데이터 분할과 바운딩박스 및 광원 라벨을 유지하면서 끝점 라벨을 추가하였다.

전체 데이터셋의 끝점 라벨링에 앞서, 라벨링 기준을 수립하기 위한 1~4차 실험을 수행하였다. ULDB 학습 데이터 중 500장을 선정하여 학습 400장과 내부 검증 100장으로 구분하였으며, 초기 라벨을 이용하여 1차 및 2차 실험을 수행하였다. 이후 500장 중 311장은 기존 라벨을 유지하고 189장을 재라벨링하여 3차 및 4차 실험을 수행하였다. 각 데이터 구성에서 학습 Epoch를 150과 300으로 설정하여 결과를 비교하였으며, 원본 검증 및 시험 데이터는 사용하지 않았다.

1~4차 실험을 통해 수립한 라벨링 기준을 적용하여 총 1,226장의 RTMPose-t 데이터셋을 구성하였으며, 모델별 데이터 분할은 표 1에 나타내었다.

표 1 모델별 데이터셋 구성

적용모델	학습	검증	시험	합계
YOLOv8s	1,540	330	330	2,200
RTMPose-t	856	190	180	1,226

YOLOv8s와 RTMPose-t는 각각 시험 데이터 330장과 180장으로 평가하였으며, 통합 파이프라인은 RTMPose-t 시험 데이터 180장을 대상으로 시각화하였다.

3.1.2 모델 학습 및 평가 방법

YOLOv8s와 RTMPose-t는 Scratch 방식으로 학습하였으며, 모델별 학습 조건은 표 2에 나타내었다.

표 2 모델별 학습 조건

적용모델	YOLOv8s	RTMPose-t
입력 크기	320x320	256x256
학습 방식	Scratch	Scratch
Optimizer	SGD	AdamW
초기 학습률	0.01	0.001
Batch Size	32	32
Epoch	300	150
학습률 스케줄	Warmup 및 Linear Decay	Warmup 및 Cosine

YOLOv8s의 레이저 영역 검출 성능은 Precision(정밀도), Recall(재현율), mAP50 및 mAP50-95로 평가하였다. Precision과 Recall은 각각 검출 결과의 정확성과 실제 레이저 영역

한국해양로봇기술연구회 2026년 추계학술대회 (2026. 11. 13(금) / 부산항국제전시컨벤션센터(부산))

의 검출 비율을 나타낸다. mAP50은 IoU 임계값 0.5를 기준으로, mAP50-95는 0.5부터 0.95까지의 여러 임계값에서 검출 성능을 평가하는 지표이다.

RTMPose-t는 평균 각도 오차(Mean Angle Error, MAE)를 주요 지표로, Acc@10°와 PCK(Percentage of Correct Keypoints)를 보조 지표로 사용하였다. Acc@10°는 각도 오차가 10° 이내인 영상의 비율이며, PCK@0.03은 바운딩박스의 긴 변을 기준으로 정규화한 특징점 위치 오차가 0.03 이내인 비율을 나타낸다.

평균 각도 오차는 정답 광원-끝점 방향과 예측 광원-끝점 방향 사이의 각도 차이로 계산하였다. 정답 및 예측 광원-끝점 좌표로 구성한 방향 벡터를 각각 $\overrightarrow{v_{GT}} = P_e - P_s$, $\overrightarrow{v_{pred}} = \hat{P}_e - \hat{P}_s$라 할 때, 각도 오차 $\theta_{err,i}$는 두 벡터 사이의 각도로 계산한다.

$$\theta_{err,i} = \mathrm{atan2}\left(\left|\overrightarrow{v_{GT,i}} \times \overrightarrow{v_{pred,i}}\right|,\ \overrightarrow{v_{GT,i}} \cdot \overrightarrow{v_{pred,i}}\right) \quad (4)$$

여기서 ×와 ·은 2차원 벡터의 외적과 내적을 의미한다. 전체 유효 영상 N장에 대한 평균 각도 오차는 다음과 같다.

$$MAE(Mean\ \angle\ \mathrm{Error}, ^\circ) = \frac{180}{\pi N}\sum_{i=1}^{N}\theta_{\mathrm{err,i}} \quad (5)$$

평균 각도 오차가 작을수록 예측 방향이 정답 방향에 가까움을 의미한다. 정면 관측 영상은 방향 벡터의 크기가 0이므로 PCK 평가에만 포함하고, 평균 각도 오차 및 Acc@10° 평가에서는 제외하였다.

RTMPose-t의 단독 성능 평가에는 정답 바운딩박스를, 통합 파이프라인에는 YOLOv8s의 예측 바운딩박스를 사용하여 광원과 끝점의 좌표를 추정하였다.

3.2 결과 및 분석

3.2.1 라벨링 기준 수립 실험 결과 및 분석

1~4차 실험에서는 라벨링 기준과 학습 Epoch에 따른 특징점 검출 성능을 비교하였다. 1·2차와 3·4차 실험은 서로 다른 데이터 구성으로 수행하였으며, 각 그룹 내에서는 동일한 데이터를 사용하였다. 실험 결과는 표 3에 나타내었다.

표 3 라벨링 기준 수립 실험 결과

평가 지표	초기 데이터		수정 데이터	
	1차	2차	3차	4차
	150 Epoch	300 Epoch	150 Epoch	300 Epoch
평균 각도 오차 (°) ↓	4.04	3.51	3.72	3.69
Acc@10° (%) ↑	92	94	91	94
PCK@0.03 ↑	0.645	0.645	0.815	0.845
광원 PCK@0.03 ↑	0.96	0.99	0.98	0.99
끝점 PCK@0.03 ↑	0.33	0.30	0.65	0.70

1·2차 실험에서는 광원의 PCK@0.03이 각각 0.960, 0.990으로 높게 나타났으나, 끝점은 각각 0.330, 0.300으로 상대적으로 낮은 정확도를 보였다. 평균 각도 오차는 4.04°에서 3.51°로 감소하였으며, Acc@10°는 92%에서 94%로 증가하였다. 이는 끝점의 위치 정확도가 낮더라도 레이저 방향은 비교적 정확하게 추정할 수 있음을 보여준다.

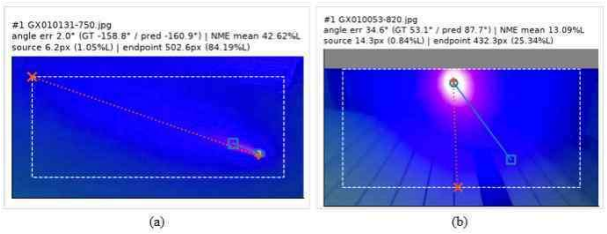

그림 2 1·2차 실험의 특징점 검출 오차 사례
(a)끝점 위치 오차, (b)정면 관측 영상의 레이저 방향각 오차

그림 2는 1·2차 실험에서 확인된 특징점 검출 오차 사례를 보여준다. 그림 2(a)는 끝점 위치 오차가 크게 발생한 사례이며, 그림 2(b)는 정면에 가까운 관측 조건에서 레이저 방향각 오차가 증가한 사례이다. 초기 라벨링에서는 빛 번짐과 작업자의 판단에 따라 끝점 위치가 달라지는 문제가 확인되었다. 이에 따라 레이저 중심축과 바운딩박스 경계의 교차점을 끝점으로 지정하였다.

수정된 데이터를 사용한 3·4차 실험에서는 끝점의 PCK@0.03이 각각 0.650, 0.700으로 나타났으며, 평균 각도 오차는 3.72°, 3.69°, Acc@10°는 91%, 94%로 나타났다. 1·2차 실험보다 끝점 PCK는 높았으나 방향 추정 성능은 유사하였다. 다만 검증 데이터 구성이 달라, 라벨링 수정에 따른 직접적인 성능 향상으로 단정하기 어렵다.

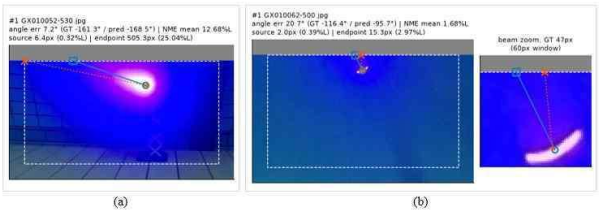

그림 3 3·4차 실험의 특징점 검출 오차 사례
(a)레이저 방향각 오차, (b)빛 번짐 발생 영상의 레이저 방향각 오차

그림 3은 3·4차 실험의 오차 사례로, 그림 3(a)는 방향각 오차가 발생한 사례이며, 그림 3(b)는 빛 번짐이 발생한 영상에서의 방향각 오차를 보여준다. 이를 고려하여 방향 판별이 어려운 영상은 특징점 학습 대상에서 제외하고, 정면 관측 영상은 광원과 끝점을 동일한 좌표로 지정하였다.

3.2.2 YOLOv8s 레이저 영역 검출 성능 평가

YOLOv8s의 레이저 영역 검출 성능을 평가하기 위해 ULDB 시험 데이터 330장을 사용하였다. 평가 결과는 표 4에 나타내었다.

표 4 YOLOv8s 레이저 영역 검출 성능

평가 지표	결과
Precision	0.9928
Recall	0.9896
mAP50	0.9938
mAP50-95	0.8123

평가 결과, Precision과 Recall은 각각 0.9928, 0.9896으로 나타났으며, mAP50과 mAP50-95는 각각 0.9938, 0.8123을 기록하였다. 이를 통해 YOLOv8s가 수중 레이저 영역을 높은

한국해양로봇기술연구회 2026년 추계학술대회 (2026. 11. 13(금) / 부산항국제전시컨벤션센터(부산))

정확도로 검출하며, 후속 RTMPose-t의 입력으로 활용할 수 있음을 확인하였다.

3.2.3 RTMPose-t 특징점 검출 성능 평가

RTMPose-t의 특징점 검출 성능을 평가하기 위해 끝점 라벨링 기준에 따라 선별한 시험 데이터 180장을 사용하였다. 평가 결과는 표 5에 나타내었다.

표 5 RTMPose-t 특징점 검출 성능

평가 지표	결과
평균 각도 오차 (°) ↓	2.14
Acc@10° (%) ↑	98.9
PCK@0.03 ↑	0.842
광원 PCK@0.03 ↑	1.000
끝점 PCK@0.03 ↑	0.683

표 5에서 평균 각도 오차는 2.14°, Acc@10°는 98.9%로 나타나 높은 레이저 방향 추정 성능을 확인하였다. 특징점별 PCK@0.03은 광원 1.000, 끝점 0.683으로 나타났으며, 전체 PCK@0.03은 0.842를 기록하였다. 광원은 높은 위치 정확도를 보인 반면, 끝점은 상대적으로 낮은 정확도를 보였다.

결과적으로 RTMPose-t는 끝점의 위치 정확도가 상대적으로 낮음에도 높은 레이저 방향 추정 성능을 보였으며, 이를 통해 제안 방법의 유효성을 확인하였다.

3.2.4 통합 파이프라인 적용 결과

통합 파이프라인의 적용 결과를 그림 4에 나타내었다.

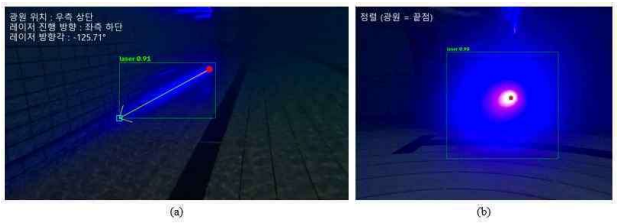

그림 4 통합 파이프라인 적용 결과
(a)레이저 방향각 산출, (b)정면 관측 영상의 정렬 상태

그림 4(a)는 선형 레이저 영상에서 YOLOv8s의 영역 검출과 RTMPose-t의 특징점 추정 결과를 보여준다. 예측된 광원과 끝점을 연결한 방향은 영상에서 관찰되는 레이저의 중심축과 거의 일치하였으며, 두 특징점을 이용하여 산출한 레이저 방향각을 도(°) 단위로 함께 표시하였다.

그림 4(b)는 정면 관측 영상의 적용 결과로, 광원과 끝점이 동일한 위치에 검출되어 방향각 대신 정렬 상태를 나타내었다. 이는 정면 관측 영상에 대해 설정한 처리 기준이 통합 파이프라인에서도 적용됨을 보여준다.

4. 결론

본 연구에서는 AUV 도킹 유도를 위해 YOLOv8s와 RTMPose-t 기반 레이저 방향 추정 방법을 제안하였다. 기존 UL DB 데이터셋에 끝점 라벨을 추가하고, 라벨링 기준 수립을 위한 1~4차 실험을 통해 빛 번짐과 반사, 정면 관측 상태를 고려한 라벨링 기준을 수립하여 총 1,226장의 특징점 데이터셋을 구성하였다. 이를 기반으로 레이저 영역과 광원 및 끝점을 검출하고, 카메라 시야각을 이용하여 레이저 방향각을 산출하였다.

모델 성능 평가 결과, YOLOv8s는 mAP50 0.9938, mAP50-95 0.8123을 기록하였으며, RTMPose-t는 평균 각도 오차 2.14°, Acc@10° 98.9%를 달성하였다. 특히 끝점의 위치 정확도가 상대적으로 낮음에도 레이저 방향을 정확하게 추정할 수 있음을 확인하였다. 또한 통합 파이프라인의 시각화를 통해 레이저 방향각 산출과 정면 관측 영상의 정렬 상태를 확인하였다.

제안 기법은 기존의 광원 위치 검출을 넘어 레이저의 방향 정보를 함께 제공함으로써 AUV 도킹 과정에서 접근 방향 및 정렬 상태 판단에 활용될 수 있다. 향후 실시간 추론 성능과 실제 수중환경에서의 도킹 제어 성능을 검증하여 AUV 자율 도킹 유도 시스템으로의 적용 가능성을 평가할 계획이다.

참 고 문 헌

[1] J. Liu et al., “A Review of Underwater Docking and Charging Technology for Autonomous Vehicles”, Ocean Engineering, Vol. 297, Article No. 117154, 2024.

[2] N. Palomeras et al., “AUV Homing and Docking for Remote Operations”, Ocean Engineering, Vol. 154, 2018, pp. 106 - 120.

[3] P.-M. Lee, et al., “Visual Servoing for Underwater Docking of an Autonomous Underwater Vehicle with One Camera”, OCEANS 2003, Vol. 2, 2003, pp. 677-682.

[4] J.-Y. Park, et al., “Experiments on Vision Guided Docking of an Autonomous Underwater Vehicle Using One Camera”, Ocean Engineering, Vol. 36, No. 1, 2009, pp. 48-61.

[5] D. Li, et al., “Terminal Underwater Docking of an Autonomous Underwater Vehicle Using One Camera and One Light”, Marine Technology Society Journal, Vol. 50, No. 6, 2016, pp. 58-68.

[6] B. Zhang et al., “Fast Underwater Optical Beacon Finding and High Accuracy Visual Ranging Method Based on Deep Learning”, Sensors, Vol. 22, No. 20, Article No. 7940, 2022.

[7] B. Jia, et al., “Deep Learning-Based Cascaded Light Source Detection for Link Alignment in Underwater Wireless Optical Communication”, IEEE Photonics Journal, Vol. 16, No. 5, Article No. 7801512, 2024, pp. 1-12.

[8] J. Redmon et al., “You Only Look Once: Unified, Real-Time Object Detection”, Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR), 2016, pp. 779-788.

[9] T. Jiang et al., “RTMPose: Real-Time Multi-Person Pose Estimation based on MMPose”, arXiv preprint arXiv:2303.07399, 2023.

한국해양로봇기술연구회
2026 추계학술대회

B-P3

무인수상선 해상시험을 위한 무인기 자율 추종 및 공중 영상 관제 기술

Development of a UAV-Based Autonomous Tracking and Aerial Monitoring System for USV Sea Trials

김성민 · 이영준 · 김상수 · 이현우 · 강호준 · 한종부 · 김기훈

충남대학교 / 선박해양플랜트연구소 / 과학기술연합대학원대학교

무인수상선 해상시험을 위한 무인기 자율 추종 및 공중 영상 관제 기술

김성민[1,2], 이영준[2], 김상수[2,3], 이현우[2], 강호준[2,3], 한종부[2], 김기훈[2]
[1]충남대학교 메카트로닉스공학과, [2]선박해양플랜트연구소, [3]과학기술연합대학원대학교 선박해양공학

Development of a UAV-Based Autonomous Tracking and Aerial Monitoring System for USV Sea Trials

Sung-Min Kim[1,2], Yeongjun Lee[2], Sangsu Kim, Hyunwoo Lee, Hojun Kang, Jong-Boo Han[2], Kihun Kim[2]

[1]Department of Mechatronics Engineering, Chungnam National University
[2]Korea Research Institute of Ships & Ocean Engineering (KRISO)
[3]Dept. of Ship & Ocean Eng., University of Science and Technology(UST)

Key Words : 무인수상선(Unmanned Surface Vehicles), 무인기(Unmanned Aerial Vehicles), 자율 추종, 관제시스템, 새만금해상시험장

Abstract : This study developed a technique that enables an unmanned aerial vehicle (UAV) to autonomously follow an unmanned surface vehicle (USV) and provide aerial video for monitoring USV sea trials. Sea trials require continuous monitoring of the vessel, but observation from shore is limited in range. Aerial imaging by a UAV offers a wide field of view; however, manual control of the UAV and its camera requires a dedicated operator. In the developed technique, the UAV moves to an operator-selected following point relative to the USV, controls its heading and camera tilt to keep the USV in view, and returns to the landing pad for precision landing using a visual marker. Field experiments were conducted with the unmanned catamaran MAIV-1 at the Saemangeum inner-sea test site. Wind and delays in UAV position updates were found to degrade landing precision and following stability, which will be addressed in future work.

1. 서론

해양 자율무인기술의 실해역 검증을 위해 다양한 해상 시험이 수행되고 있다. 선박해양플랜트연구소(Korea Research Institute of Ships & Ocean Engineering, KRISO)는 이러한 해상 시험을 수행하기 위해 새만금 해상시험장을 구축하였으며, 이곳에서 무인수상선(Unmanned surface vehicles, USV)의 해상 시험을 진행하고 있다.

해상 시험에서는 시험 대상의 상태와 주변 해상 상황을 지속적으로 관찰하고 기록하는 관제가 필요하다. 육상에서 육안으로 관측 가능한 거리와 시야는 제한적이므로, 넓은 시야를 확보할 수 있는 무인기(Unmanned aerial vehicles, UAV)를 이용한 항공 촬영은 해양 관측 및 무인수상선 연계 임무에 활용되어 왔다[1]. 무인기를 활용한 관제는 조종자가 기체 위치와 카메라 방향을 지속적으로 원격 조작해야 하므로, 공중관제를 전담하는 인력이 필요하다. 무인기가 무인수상선을 자율적으로 추종하며 촬영할 수 있다면 전담 인력 없이 공중 영상 관제가 가능하다.

본 논문에서는 효율적인 해상 시험 관제를 위해 무인기를 활용한 영상 관제 기술을 제안하고, 이를 위해 개발한 무인기 자율 추종 기술과 새만금 해상시험장에서 진행된 실해역 검증 실험 결과를 소개한다.

* 김성민 : CNU-KRISO, 010-9430-6141, 2246143@naver.com
* 이영준 : KRISO, 042-866-3864, leeyeongjun@kriso.re.kr
* 김상수 : UST-KRISO, 010-4043-0499, sooo056@kriso.re.kr
* 이현우 : KRISO, 042-866-3887, hyunwoo@kriso.re.kr
* 강호준 : UST-KRISO, 042-866-3902, hjkang3854@kriso.re.kr
* 한종부 : KRISO, 042-866-3839, jbhan@kriso.re.kr
* 김기훈 : KRISO, 042-866-3814, khkim@kriso.re.kr(교신저자)

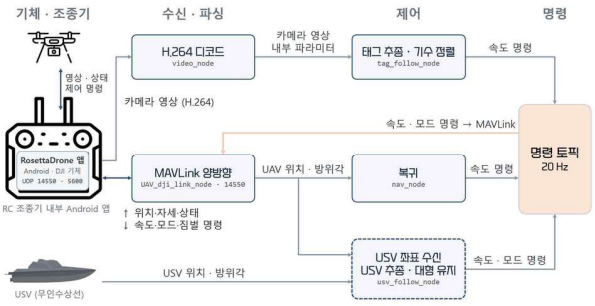

Fig. 1 소프트웨어 구성도

2. 무인기 자율 추종 및 공중 영상 관제 기술

2.1 시스템 개요

본 시스템의 목적은 무인기가 무인수상선을 자율적으로 추종하며 공중 관제영상을 관제 시스템에 제공하는 것이다. Fig. 1은 이러한 시스템의 소프트웨어 구성을 나타낸 개념도이다. 시스템은 무인기, 조종기, 육상관제소로 구성되며, 육상관제소는 무인수상선 관제 시스템과 통합되어 운용된다.

무인기는 상용 기체인 DJI Mavic 2 Pro[2]를 사용하였다. 조종기에는 DJI통신 프로토콜을 MAVLink 프로토콜[3]로 변환하는 안드로이드 기반 오픈소스 애플리케이션인 RosettaDrone[4]이 설치된다. 조종기와 육상관제소는 Wi-Fi와 같은 무선통신으로 연결된다. 육상관제소는 이 연결을 통해 무인기의 운동 상태 정보와 촬영 영상을 수신하고, 무인기와 카메라 짐벌에 제어 명령을 송신한다. 운동 상태 정보는 무인기의 위도, 경도, 이륙 지점 기준 상대 고도 및 자세이다.

육상관제소의 소프트웨어는 ROS2(Robot operating system 2,

ROS2)[5]를 기반으로 구성된다. ROS2에서는 기능별로 분리된 노드(node)가 토픽(topic)을 통해 정보를 주고받는다. 수신된 무인기의 운동 상태 정보와 촬영 영상(image)은 ROS 2 토픽으로 변환된다. 추종, 복귀, 착륙 기능을 담당하는 각 노드는 이 토픽을 이용하여 제어 명령을 전달한다. 육상관제소는 무인수상선 관제 시스템과 이더넷 통신으로 연결되어 무인수상선의 위치를 수신하며, 무인기 영상은 무인수상선 관제 화면에 함께 표시된다.

2.2 임무 시나리오

무인기가 무인수상선을 자율 추종하며 공중관제하는 임무는 여러 단위 기술의 조합으로 수행된다. 임무는 Fig. 2와 같이 이륙, 추종 촬영, 복귀, 착륙의 순서로 진행된다.

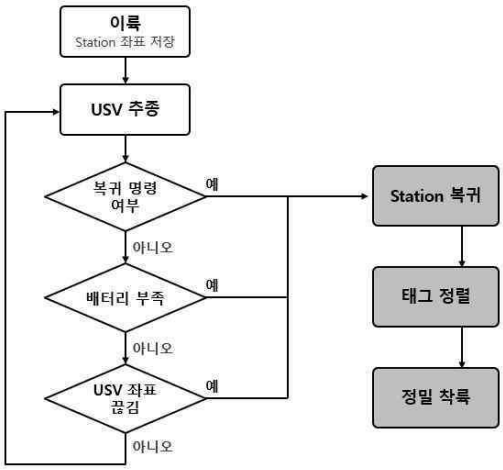

Fig. 2 임무 시나리오

무인기는 이륙 시 현재 위·경도를 이착륙장 좌표로 지정한다. 이륙 이후 무인수상선의 좌표를 수신할 때까지 공중에서 제자리비행(hovering)으로 대기한다. 본 시스템은 무인수상선을 선도체(leader), 무인기를 추종체(follower)로 하는 선도-추종 구조[6]를 따른다. 추종점은 무인수상선 선체 좌표계에서 정의된 상대 위치로, 운용자는 좌현·우현·선미 추종점 중 하나를 선택하여 어떤 상대 위치에서 무인수상선을 촬영할지 지정할 수 있다. 해당 위치에서 무인수상선을 지향하도록 무인기의 기수 방향(heading)과 카메라의 상하 각도(tilt)를 제어한다. 무인수상선 추종 비행 중 운용자의 복귀 명령, 배터리 부족, 무인수상선 위치 수신 중단 시 무인기는 이착륙장으로 자동 복귀한다. 무인기의 위성항법시스템(Global navigation satellite system, GNSS)오차를 고려하여 이착륙장에는 정밀한 착륙을 위한 마커가 설치되어 있다. 본 논문에서는 마커(marker)로서 AprilTag[7]를 사용하였다.

2.3 요소기술

2.3.1 이착륙 기술

이륙과 착륙 동작에는 무인기 제조사에서 제공하는 자동이착륙 기능을 일부 이용한다. 이륙 후 무인기는 현재 위·경도를 이착륙장 좌표로 저장한다. 복귀 시 무인기는 앞서 지정한 이착륙장 좌표로 복귀를 진행한다.

그러나 GNSS 수평 위치 오차로 인해 해당 좌표만으로는 정밀 착륙이 어렵다. 이에 이착륙장 상공에 도착한 후 카메라의 상하 각도를 하방으로 설정하여 이착륙장에 부착된 AprilTag를 찾는다. AprilTag가 발견되면 마커와 카메라 간의 상대 위치를 계산하고 이를 통해 무인기의 자세를 정렬한다. 무인기의 정렬 이후, 이륙 지점 기준 상대 고도를 3m까지 낮춘 후, 착륙한다. AprilTag 정렬은 비례 제어를 사용하였으며, 허용 오차는 0.1m로 설정하였다.

2.3.2 무인수상선 추종

무인기가 무인수상선을 추종하려면 무인수상선의 위치를 기준으로 추종점의 위치를 산출하고, 추종점에서 무인수상선을 향하는 기수각과 카메라 상하 각도를 결정해야 한다. 이를 위해서는 두 기체 간 상대 위치가 필요하므로, 먼저 무인수상선과 무인기의 위·경도 좌표 차이를 거리 차이로 변환한다. 거리 변환은 식(1)과 식(2)의 Haversine 공식[8]을 이용하였다.

$$a = \sin^2\left(\frac{\varphi^r}{2}\right) + \cos(\varphi^s)\cos(\varphi^a)\sin^2\left(\frac{\lambda^r}{2}\right) \quad (1)$$
$$[\varphi^r = \varphi^s - \varphi^a,\ \lambda^r = \lambda^s - \lambda^a]$$

$$d = 2R\ \sin^{-1}(\sqrt{a}) \quad (2)$$

여기서 φ는 위도, λ는 경도이며, 첨자 s는 무인수상선, a는 무인기를 의미한다. R은 지구 반지름, d는 두 지점 사이의 거리를 의미한다. 식(2)에서는 지구를 반지름 R = 6,371,000m의 구로 근사한다. 이러한 근사로 인한 오차는 무인기와 무인수상선 간 40m 거리에서 약 9cm로 기체의 GNSS 기반 수평 제자리비행 오차 (±1.5 m)[2]에 비해 무시할 만큼 충분히 작다.

추종점에서 무인기의 기수 방향이 무인수상선을 향하도록 무인기에서 무인수상선을 바라본 방위각(ψ_d)를 식(3)과 같이 계산하고 이를 무인기의 목표 기수각으로 사용하였다. 방위각과 기수각은 모두 진북을 0° 로 한다. (무인기의 기수가 진북을 향할 때 ψ = 0°)

$$\psi_d = \tan^{-1}\frac{\sin(\lambda^r)\cos(\varphi^s)}{\cos(\varphi^a)\sin(\varphi^s) - \sin(\varphi^a)\cos(\varphi^s)\cos(\lambda^r)} \quad (3)$$

카메라의 상하 각도는 조위차에 의해 해수면의 높이가 매번 다르고, 이착륙장과 해수면 간 격차가 있으므로 현장에서 조율할 수 있도록 식(4)와 같이 결정하였다. 여기서 θ는 카메라의 상하 각도이며, 사분면을 고려하여 계산한다. h_{rel}는 무인기의 이륙 지점 기준 상대 고도, h_{below} 는 이륙 지점과 해수면 간 고도 차이를 의미한다.

$$\theta = -\tan^{-1}\left(\frac{h_{rel} + h_{below}}{d}\right) \quad (4)$$

2.3.3 시선 유지를 위한 기수각 제어

2.3.2절에서 산출한 목표 기수각(ψ_d)은 두 기체의 상대 위치로부터 계산되므로, 상대 위치가 바뀌면 함께 변한다. 특히 추종점이 변경되면 무인기가 무인수상선 주위를 이동하므로 목표 기수각이 짧은 시간 동안 크게 변한다.

무인기의 기수각 제어를 위해 기수각 오차에 비례하는 각속도 명령만 사용할 경우, 목표 기수각이 빠르게 변하면 무인수상선이 관제 영상 밖으로 이탈할 수 있다. 이를 보완하기 위해 두 기체의 상대 속도로부터 목표 기수각 변화율 $\dot{\psi}_d$를 식(5)와 같이 계산하고, 이를 앞먹임(feed-forward)항으로 더하여 식(6)과 같이 각속도 명령을 생성하였다.

$$\dot{\psi}_d = \frac{\cos(\psi_d)\, v^r_{east} - \sin(\psi_d)\, v^r_{north}}{\max(d,\ 1\,\mathrm{m})} \quad (5)$$
$$[v^r_{north} = v^s_{north} - v^a_{north}\ ,\ v^r_{east} = v^s_{east} - v^a_{east}]$$

$$\omega_{cmd} = K_{ff}\,\dot{\psi}_d + K_{\psi}(\psi_d - \psi) \quad (6)$$

여기서 v^r_{north}는 무인수상선과 무인기의 북쪽 방향 상대속도, v^r_{east}는 동쪽 방향 상대 속도이다. 두 기체가 근접하여 d가 0에 가까워질 때 $\dot{\psi}_d$가 발산하는 것을 막기 위해 분모의 하한을 1m로 두었다. ω_{cmd}는 기수 각속도 명령, ψ는 무인기의 현재 기수각, K_ψ는 비례 게인, K_{ff}는 앞먹임 게인이다.

3. 검증 실험

3.1 개요

제안한 기술을 검증하기 위해 새만금 해상시험장에서 실험을 진행하였다. 추종 대상은 KRISO가 자체 개발한 무인 쌍동선 MAIV-1(Fig. 3(a))이며, 무인기는 DJI Mavic 2 PRO 모델(Fig. 3(b))이다. 실험 내용은 Fig. 2와 같은 임무 시나리오를 검증하였다.

(a) 무인수상선 MAIV-1 (b) 무인기 DJI Mavic 2

Fig. 3 추종 대상 및 추종체

3.1.1 새만금 해상시험장

선박해양플랜트연구소는 해양무인시스템의 실증시험 및 성능평가 기술 개발을 위해 전북특별자치도 군산시 새만금 내해에 해상시험장을 구축하였다(Fig. 4). 본 시험장은 해양무인시스템 및 자율운항 기술의 개발 단계별 시험과 성능검증을 지원하고, 공인 시험평가 체계 구축을 위한 실증 기반을 확보하는 것을 목적으로 한다. 특히, 수중·수상·공중의 다양한 운용 환경에서 무인시스템의 실증시험을 수행할 수 있도록 전용 해상시험 구역을 확보하여 운영하고 있다.

(a) 운용 개념도 (b) 해상시험장 전경

Fig. 4 KRISO 새만금 해양무인시스템 해상시험장

3.1.2 해양환경 조건

실험은 새만금 해상시험장에서 2026년 10월 2일 11시에 진행되었다. 풍속은 인근 선유도 관측소 기준 3.1m/s, 풍향은 355° 이다. 무인수상선의 운항 속도는 약 1.5m/s(3 knots)이다.

3.2 실험 결과

3.2.1 무인수상선 추종 실험

Fig. 5(a)는 무인수상선의 경로(초록색 점선)와 무인기의 추종 경로(빨간색 실선)를 나타낸 것이다. 비행 도중 추종점의 변경에 따라 무인기의 상대 위치가 변했음을 확인할 수 있으며, 이착륙장으로 복귀하는 과정까지 확인할 수 있다. Fig. 5(b)는 무인기와 무인수상선 간 거리를 시간에 따라 나타낸 것이다.

육상관제소는 무인기 위치 메시지를 5Hz로 끊김 없이 수신하였으나, 비행 중 동일한 위경도가 0.6초 이상 반복된 구간을 위치 갱신 지연으로 판단하여 음영으로 표시하였다.

Fig. 5의 무인수상선 추종 실험 결과에서는 무인기의 추종 경로가 매끄럽지 않고 불안정한 양상을 보였다. 무인기와 무인수상선 간 수평 거리의 이상값 구간과 위치 갱신 지연의 구간이 일치하므로, 위치 갱신 지연이 경로 불안정의 원인으로 추정된다. 이 구간에서는 무인수상선이 이동하는 동안 무인기 위치가 갱신되지 않아 측정 거리가 증가하고, 갱신 시점에 급격히 감소한다. 위치 메시지는 지속적으로 수신되었으므로 육상관제소와 조종기 간 링크의 단절은 아니라고 판단된다. 본 결과는 단일 비행에서 획득하였으며, 두 기체 모두 RTK가 아닌 GNSS를 사용하였으므로 거리 측정값에는 m단위의 오차가 존재할 수 있다.

(a) 무인수상선 및 무인기 이동 경로

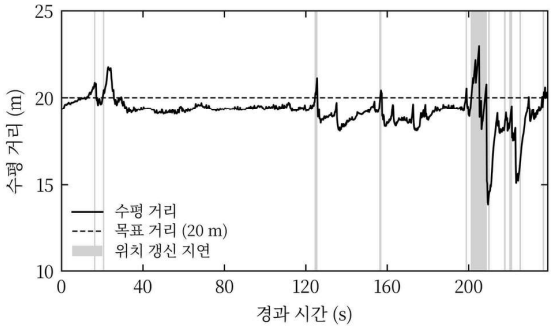

(b) 무인수상선-무인기 거리오차 변화

Fig. 5 무인수상선 추종 실험 결과

3.2.2 이착륙 실험

Fig. 6(a)는 정렬을 마친 무인기의 모습이며, Fig.6(b)는 AprilTag를 이용하여 정밀 착륙을 진행한 무인기의 모습이다. 이착륙 실험 결과 태그를 이용한 정렬 진행 이후 착륙하는 과정에서 정렬 기준으로 삼은 카메라와 태그 중심 간 수평 거리는 약 17cm였다. 이는 무인기의 GNSS만을 이용했을 때의 오차(약 1.5m) 보다 작은 값이다. 정렬 단계의 허용 오차가 0.1m임을 고려하였을 때, 나머지 오차는 3m 고도에서 정렬 이후 하강하는 과정에서 바람에 의한 오차로 추정된다.

(a) (b)

Fig. 6 이착륙 실험 결과

3.2.3 대형 위치별 촬영 결과

Fig. 7(a)는 무인수상선의 좌현, (b)는 무인수상선의 우현, (c)는 무인수상선의 선미 방향에서 촬영한 사진이다. 각 추종점은 무인수상선으로부터 수평 방향 20m, 고도 10m에 위치한다.

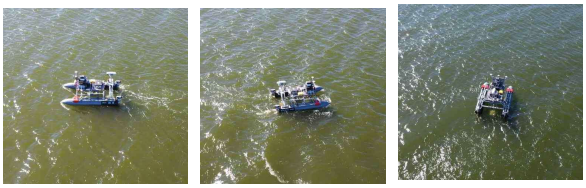

(a) 좌현 보기 (b) 우현 보기 (c) 선미 보기

Fig. 7 무인수상선 대형 위치별 촬영 사진

3.2.4 관제시스템

무인기에서 송출되는 영상은 1632 × 1088의 해상도, 프레임률 30fps로 송출된다. 이 원본 영상을 육상관제소의 관제 시스템에 연동한 결과, 관제 시스템의 응답 시간이 급격히 증가하였다. 이에 따라 무인수상선의 GNSS, 도플러 속도계(Doppler velocity log, DVL), 측면 주사 소나(side-scan sonar)와 같은 다른 센서 값의 수신에도 지연이 발생하였다. 이를 해결하기 위해 영상 해상도와 프레임률을 각각 816 × 544, 3fps로 낮추었다. 그 결과 대역폭은 약 46Mbps에서 2.4Mbps로 약 95% 감소하였고, 평균 응답 시간은 약 200ms로 측정되었다. Fig. 8은 육상관제소에서 확인한 영상의 모습이다.

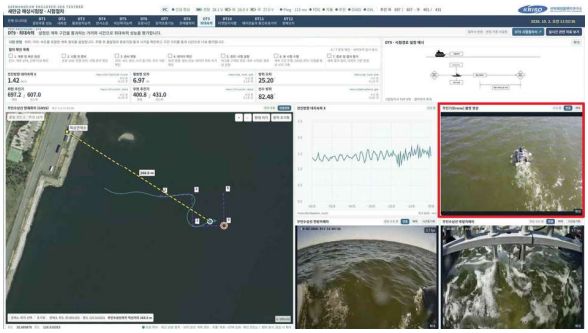

Fig. 8 관제 시스템 확인 결과

4. 결론

본 연구에서는 무인수상선 해상시험의 공중 영상 관제를 위해 무인기가 무인수상선을 자율적으로 추종하며 촬영하는 기술을 개발하였다. 개발한 기술은 이착륙, 무인수상선 추종, 시선 유지를 위한 기수각 제어로 구성되며, 촬영 영상을 무인수상선 관제 시스템에 실시간으로 제공한다.

새만금 해상시험장에서 KRISO가 자체 개발한 무인 쌍동선 MAIV-1을 대상으로 실해역 실험을 수행하였다. 무인기는 무인수상선의 좌현, 우현, 선미 방향 추종점에서 무인수상선을 촬영하였으며, 마커를 이용한 착륙의 수평 오차는 약 17cm로 GNSS만을 이용한 경우보다 작았다.

다만 바람과 같은 해상 환경과 위치 갱신 지연이 착륙 정밀도와 추종의 안정성을 저하시키는 것을 확인하였다. 향후 연구에서는 착륙 하강 구간에서의 외란 보상과 위치 갱신 지연을 고려한 제어 기법을 적용할 예정이다. 나아가 본 연구를 통해 무인기를 이용한 자율 관제 기술이 무인수상선뿐 아니라 원격 조종 무인잠수정(Remotely operated vehicle, ROV) 등 해상 및 수중에서 운용 가능한 다양한 무인 이동체의 관제에 활용될 수 있을 것으로 기대된다.

후기

본 논문은 2024년도 해양수산부 재원으로 해양수산과학기술진흥원의 지원을 받아 수행된 연구임(RS-2023-00256122, 해양 무인시스템 통합실증시험·평가기술 개발).

참 고 문 헌

[1] I. Bae and J. Hong, “Survey on the developments of unmanned marine vehicles: Intelligence and cooperation,” Sensors, vol. 23, no. 10, p. 4643, 2023.

[2] DJI, “Mavic 2 Pro/Zoom user manual,” v2.2, 2020. [Online]. Available: https://www.dji.com/support/product/mavic-2

[3] A. Koubaa, A. Allouch, M. Alajlan, Y. Javed, A. Belghith, and M. Khalgui, “Micro air vehicle link (MAVLink) in a nutshell: A survey,” IEEE Access, vol. 7, pp. 87658 - 87680, 2019.

[4] RosettaDrone Project, “RosettaDrone: MAVLink and H.264 video for DJI drones,” GitHub repository. [Online]. Available: https://github.com/RosettaDrone/rosettadrone (accessed Oct. 19, 2026).

[5] S. Macenski, T. Foote, B. Gerkey, C. Lalancette, and W. Woodall, “Robot Operating System 2: Design, architecture, and uses in the wild,” Sci. Robot., vol. 7, no. 66, Art. no. eabm6074, 2022.

[6] J. P. Desai, J. P. Ostrowski, and V. Kumar, “Modeling and control of formations of nonholonomic mobile robots,” IEEE Trans. Robot. Autom., vol. 17, no. 6, pp. 905 - 908, 2001.

[7] E. Olson, “AprilTag: A robust and flexible visual fiducial system,” in Proc. IEEE Int. Conf. Robot. Autom. (ICRA), 2011, pp. 3400 - 3407.

[8] J. P. Snyder, Map Projections: A Working Manual, U.S. Geological Survey Professional Paper 1395. Washington, DC, USA: U.S. Government Printing Office, 1987.

한국해양로봇기술연구회
2026 추계학술대회

B-P4

임의 단일 물체의 자율 시각 커버리지를 위한 학습 기반 경로계획기

표승현 · 박대길

과학기술연합대학원대학교 / 선박해양플랜트연구소

2026 한국해양로봇기술연구회 추계학술대회

임의 단일 물체의 자율 시각 커버리지를 위한 학습 기반 경로계획기

2026. 11. 13 (금)

표승현[1,2], 박대길[1,2,†]

[1] 과학기술연합대학원대학교 선박해양공학
[2] 선박해양플랜트연구소 해양공공디지털연구본부

*본 연구는 선박해양플랜트연구소(KRISO) 주요 프로젝트 사업인 "수중무인이동체의 하이브리드동력 설계를 위한 HILS 핵심기술 개발" (PES5940)의 지원을 받아 수행된 연구임.

목차

1. 개요
    1. 강화학습 기반 자율 시각 coverage의 필요성
2. 방법론
    1. 시스템 개요
    2. 보상함수의 구현
    3. NBV 파이프라인
3. 실험 및 결과
    1. 실험 구성
4. 결론

1. 개요

1) 강화학습 기반 자율 시각 coverage의 필요성

- **자율적인 수중 구조물 검사를 위한 학습 기반 방법론**
  - 시각 coverage : 형상 정보를 기반으로, 표면의 시각적인 정보를 획득하는 inspection 임무
    - 예시: 해양 플랜트 수중 구조물에 대한 정기 파손 검사, 침몰선 내부 수색
  - 사람이 조종하거나, 대상 물체/구조물 주위로 잔디깎이/원형 궤도를 추종하며 얻은 데이터 → 3차원 복원 수행

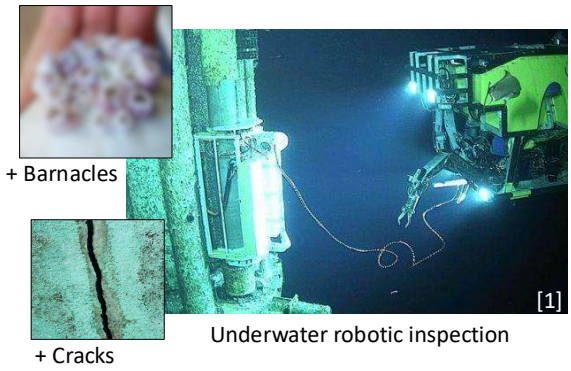

Underwater robotic inspection

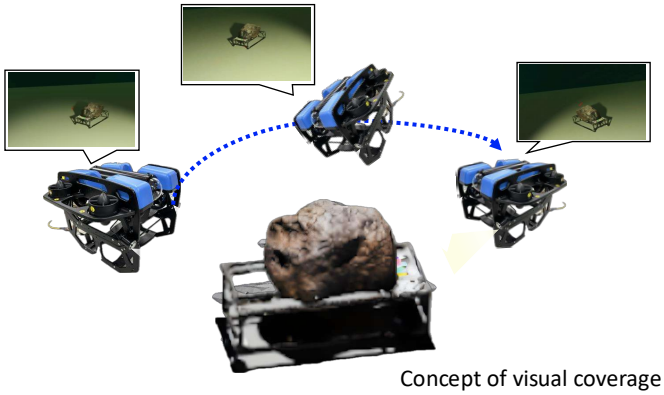

Concept of visual coverage

[1] SONOMATIC INC, WORK class ROV solutions

"전체 표면 정보 중, 얼마나 많은 영역을 충분한 품질로 획득했는가?"

2. 방법론

1) 시스템 개요

- **수중 시각 coverage 임무를 위한 수중 시각 인지 환경 및 학습 파이프라인**
  - 병렬 시뮬레이션 환경에 **수중 광학 & 동역학 모델 적용**
  - Jerlov 수중 광학 유형 분류로 Domain randomization 구현
  - PPO 강화학습 알고리즘에 대상 물체의 형상, 표면, 위치 정보를 입력, **5자유도의 직교좌표계 위치 변화 action 수행**

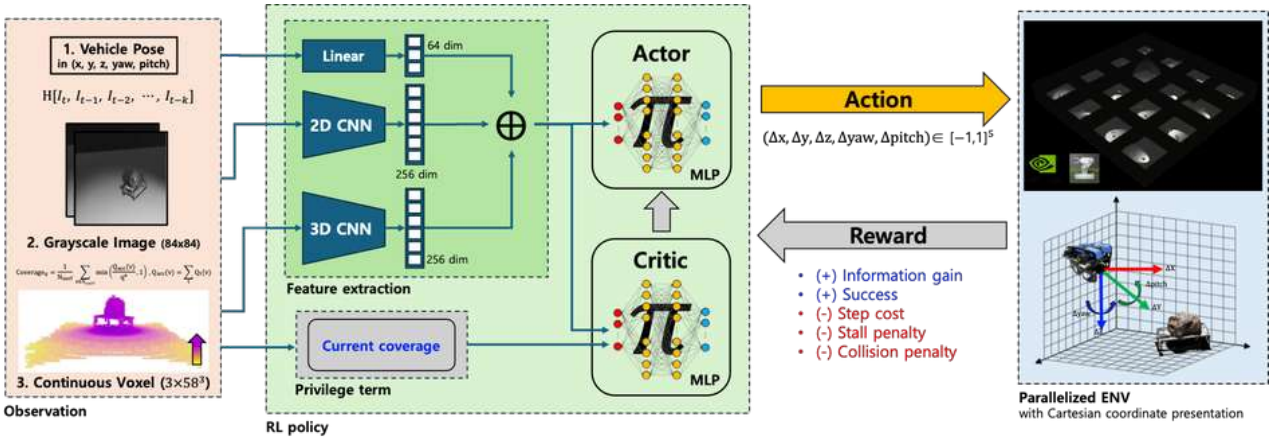

2. 방법론

2) 보상 함수의 구현

$$R_t = k_c\, G_t + R_{success} - P_{stall} - P_{step} - P_{safety}$$

1. Information gain　2. Success　3. Stall　4. Step cost　5. safety (collision)

1. $\boldsymbol{R_{coverage_q}} = \frac{1}{N}\sum_v \frac{1}{2}\ln\left(1 + \frac{Q_t(v)}{Q_{acc}(v)+\epsilon}\right)$

2. $\boldsymbol{R_{success}} = \text{cov_bonus} \cdot 1$　When cov_q ≥ cov_threshold

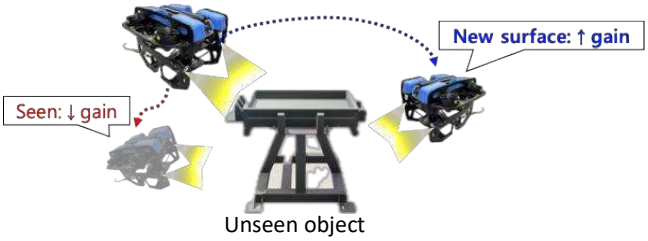

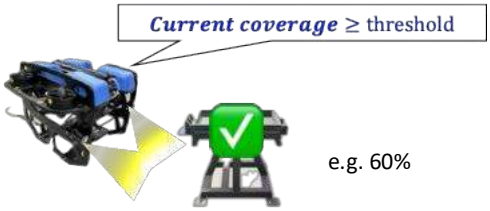

3. $\boldsymbol{P_{stall}} = k_{still} \cdot 1$　When Δcov_q $< 1e-4$

4. $\boldsymbol{P}_{\text{step}} = k_{\text{step}} \cdot a_t - c_{step}$　When cov_q ≥ cov_threshold

5. $\boldsymbol{P}_{\text{safety}} = 100$　When contact with object is occurred

2. 방법론

3) NBV 파이프라인

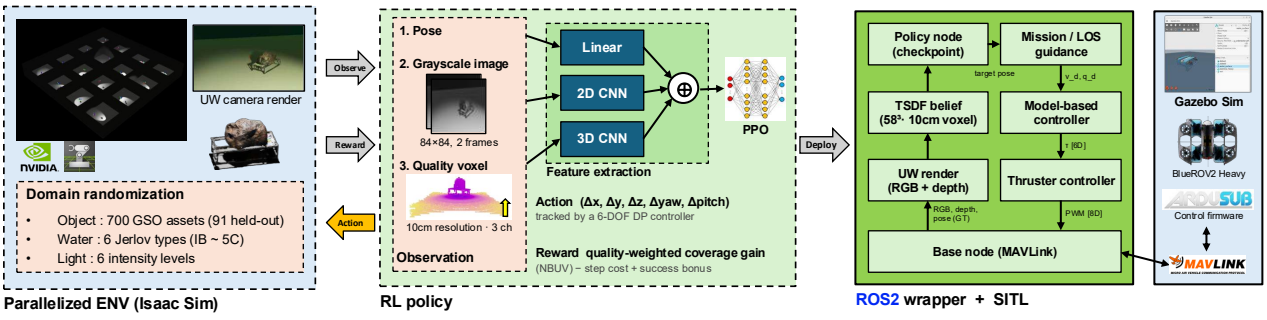

학습된 NBV 정책을 Perception-planning-control에 포함하기 위한 파이프라인 구현

3. 실험 및 검증

1) 실험 구성

- **평가 지표**
  - 방법론에 따른 Visual coverage 임무의 **시간 효율성** 분석
  - NBV 궤적에 따라 획득된 RGB 이미지 → 3차원 복원물로 **정성적 결과, 정량적 지표** 분석

- **사용된 하드웨어 및 학습 요소**
  - 학습 → NVIDIA RTX PRO 6000 Blackwell (VRAM 96GB)
  - 성능 평가 → NVIDIA RTX 4080 super (VRAM 16GB)
  - 각 방법론 모델은 총 300K step으로 학습 수행

방법론	상태 표현	Reward	비교 목적
Manual orbit	-	-	기준 성능 제시
Proposed	연속 복셀 + 이미지 시퀀스	Quality-aware coverage비율	제안한 방법

3. 실험 및 검증

1) 실험 구성

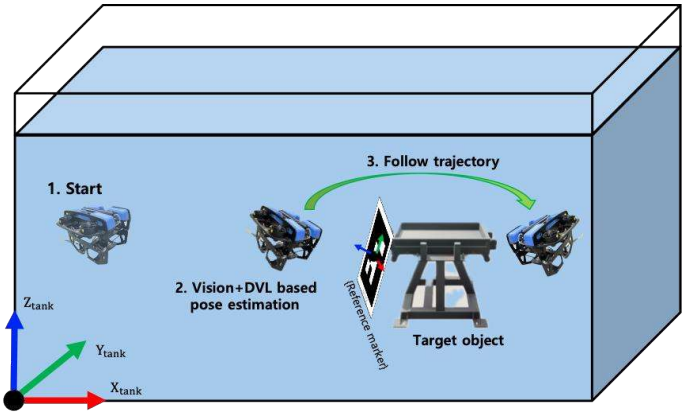

BlueROV2 Heavy:

- PID-based 5-DoF velocity control
- Navigation: DVL + Barometer + Gyro

Target object:

In CAD

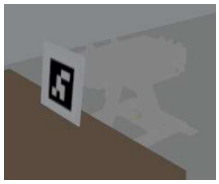

In Simulator

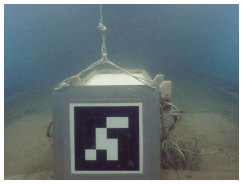

In real environment

4. 결론

1) 정리 및 제언

정리:

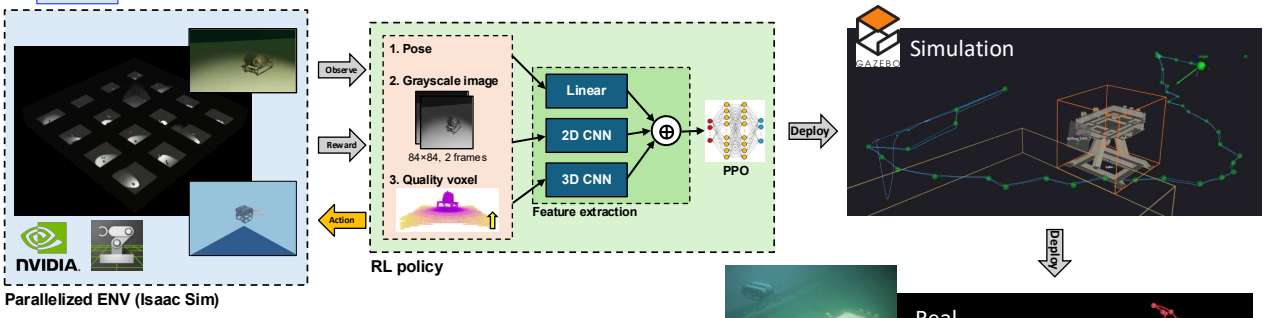

추후 연구:

1. 수중 **depth map** 획득을 통한 실시간 정책 작동 및 실험 검증
2. 보다 구체적인 수중 이미징 모델 & 동역학 모델 (Real-to-sim)
3. Coverage 와 reconstruction을 보완하는 view 선정

Offline visual coverage mission @ real environment

Thank You

Dept. of Ship & Ocean Eng.
Marine Intelligence Robotics Lab.
Mobile. +82-10-3405-2156
E-mail. pyotension@kriso.re.kr
Homepage. https://https://robot.ust.ac.kr/
Address. 32, Yuseong-daero 1312, Daejeon, KOREA

한국해양로봇기술연구회
2026 추계학술대회

B-P5

Investigation of Effective State Representation for Side-Scan Sonar SLAM Under Elevation Degeneracy

임진호 · 홍성훈

계명대학교 인식기반 지능로봇 연구실

Investigation of Effective State Representation for Side-Scan Sonar SLAM Under Elevation Degeneracy

Jinho Im[1] and Seonghun Hong[1*]
[1] *Robotic Intelligence & Perception Lab., Keimyung University, Daegu, 42601, Korea*
[*] *Corresponding author*

Key Words : Side-scan sonars, Underwater SLAM, Elevation degeneracy, State representation

Abstract : *Side-scan sonar (SSS) has emerged as a promising sensing modality for underwater simultaneous localization and mapping (SLAM) because of its long-range sensing capability and wide-area seabed coverage. In landmark-based SSS SLAM, salient seabed features are typically represented using slant-range and azimuth observations derived from acoustic measurements. However, due to the sensing geometry of SSS, landmark elevation remains only weakly constrained by the measurements. This limitation, referred to in this work as elevation degeneracy in SSS SLAM, can increase estimation errors when conventional full 6-DOF formulations are directly adopted. This study investigates how landmark elevation uncertainty influences state estimation in landmark-based SSS SLAM under elevation degeneracy. In particular, Jacobian analysis of the slant-range and azimuth observation model is performed to examine how native SSS measurements contribute to each component of the vehicle state and influence the overall estimation behavior. Based on this analysis, an effective vehicle state representation is identified according to the state sensitivities imposed by the sensing geometry. The effectiveness of the resulting reduced 4-DOF state representation, which excludes roll and pitch, is validated through comparative physics-based underwater simulation experiments against a conventional 6-DOF formulation.*

1. Introduction

Side-scan sonar (SSS) has been widely utilized in underwater robotics due to its capability to provide long-range acoustic measurements with wide-area seabed coverage. Unlike conventional imaging sensors, SSS fundamentally acquires one-dimensional (1D) acoustic backscatter signals, referred to as pings, in which re flected intensity is measured primarily as a function of slant range [1, 2]. In many existing applications, these sequential ping measurements are stacked over time to construct two-dimensional (2D) acoustic images, en abling image-domain interpretation of underwater environments. Based on such image representations, visual landmarks or salient acoustic features can be extracted and incorporated into simultaneous localization and mapping (SLAM) frameworks for underwater navigation and mapping.

Several existing studies have explored SSS-based SLAM using image-level feature extraction approaches. Fallon et al. [3] fused acoustic ranging and SSS mea surements within a graph-based SLAM framework, while Zhang et al. [4] utilized visual feature correspondences extracted from stacked SSS imagery for pose-graph optimization. These approaches typically rely on ground range projection and altitude-dependent geometric approximations to associate image-domain features with three-dimensional (3D) landmark representations. Although effective in many practical scenarios, such for mulations inherently involve ambiguity in the vertical direction because conventional SSS measurements do not directly provide elevation information.

In feature-poor or homogeneous seabed environments, where reliable image-domain feature extraction becomes difficult, directly utilizing native slant-range measure ments at the ping level can provide a more suitable al ternative to conventional image-level formulations [5]. Compared to stacked-image-based approaches, ping-level processing preserves the original sensing geometry of SSS measurements and avoids additional distor tions introduced during image formation or ground-range projection. However, directly incorporating slant-range based landmark observations into a SLAM framework also exposes a fundamental estimation issue that becomes more explicit at the ping-measurement level. In particular, uncertainty in landmark vertical positions can propagate into the vehicle state estimation process, particularly under full 6-degrees-of-freedom (DOF) formulations. This issue, referred to in this work as elevation degeneracy in SSS SLAM (Fig.1), can induce unstable coupling between the vehicle's vertical position (typically, depth from water surface) and pitch states, ultimately increasing estimation errors.

* Jinho Im: +82-53-580-5354, *jinho_im@kmu.kr*
* Seonghun Hong: +82-53-580-5354, *sh.hong@kmu.ac.kr*

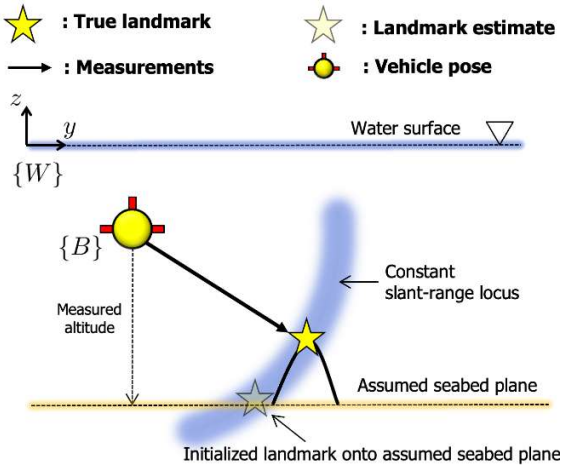

Fig. 1 Illustrative example of elevation degeneracy in SSS SLAM shown in the frontal view of the global frame $\{W\}$. From a single vehicle pose, an SSS measurement constrains the landmark to lie along a constant slant-range locus, leaving its elevation insufficiently constrained. In many SSS SLAM frameworks, the initialized landmark position may deviate from the true landmark location due to the inherent elevation ambiguity of the measurement.

Despite its practical importance, the effect of elevation degeneracy on state estimation in SSS SLAM has received limited explicit attention in the literature. While some approaches adopt reduced-dimensional state representations [6], the relationship between the SSS measurement model and the resulting estimation behavior has not been systematically analyzed. In this paper, we examine how elevation uncertainty in ping-level SSS SLAM affects the state sensitivity and estimation accuracy. In particular, we discuss the limitations of full 6-DOF state representations and consider a reduced 4-DOF state representation comprising horizontal position, depth, and yaw. The effect of elevation degeneracy under different state formulations is further evaluated through comparative physics-based simulation studies.

2. Problem Formulation

This study considers a landmark-based SSS SLAM framework in which seabed features observed by SSS are represented as landmarks in the environment map. By directly utilizing slant-range and azimuth measurements with in the native sensing geometry of SSS, the elevation-related degeneracy inherent in SSS observations

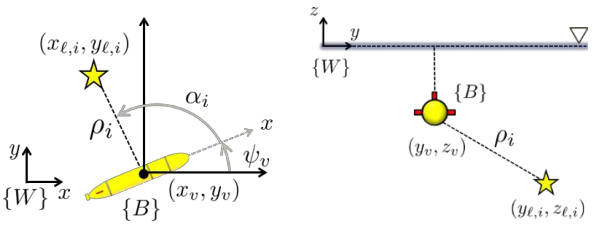

Fig. 2 Coordinate frames and measurement geometry of SSS observations under the reduced 4-DOF vehicle state representation. The vehicle pose (x_v, y_v, z_v, ψ_v) and the landmark position $(x_{\ell,i}, y_{\ell,i}, z_{\ell,i})$ are represented in the global frame. The measurements ρ_i and α_i denote the slant range and azimuth, respectively. The azimuth measurement is primarily associated with the horizontal relative geometry between the vehicle and the landmark, while the slant-range measurement reflects their full 3D separation.

can be more explicitly analyzed. The system state consists of the vehicle state and the landmark states. The full state vector at time step k defined as

$$\mathbf{x}_k = [\mathbf{x}_v \quad \mathbf{x}_{\ell,1} \quad \mathbf{x}_{\ell,2} \quad \cdots \quad \mathbf{x}_{\ell,i} \quad \cdots \quad \mathbf{x}_{\ell,n_\ell}]^\top, \tag{1}$$

where $\mathbf{x}_v$ denotes the vehicle pose state, and $x_{\ell,i} = [x_{\ell,i}, y_{\ell,i}, z_{\ell,i}]^\top$ represents the 3D position of the ith landmark. The stochastic measurement model using the slant-range and azimuth observations obtained from the ith landmark is expressed as

$$\mathbf{z}_i = \begin{bmatrix}\rho_i \\ \alpha_i\end{bmatrix} = \begin{bmatrix}h_1(\mathbf{x}_v, \mathbf{x}_{\ell,i}) \\ h_2(\mathbf{x}_v, \mathbf{x}_{\ell,i})\end{bmatrix} + \mathbf{v} = \begin{bmatrix}\sqrt{\Delta x_i^2 + \Delta y_i^2 + \Delta z_i^2} \\ \text{atan2}(\Delta y_i, \Delta x_i)\end{bmatrix} + \mathbf{v} \tag{2}$$

where $\boldsymbol{v} \sim \mathcal{N}(0, \mathrm{R})$ refers to the zero-mean Gaussian measurement noise vector, and $(\Delta x_i, \Delta y_i, \Delta z_i)$ denotes the relative position of the i th landmark in the vehicle body frame. Let $(x_v y_v, z_v)$ denote the vehicle position in the global frame. The relative landmark position in the global frame is then defined as

$$\begin{bmatrix}\delta x_i \\ \delta y_i \\ \delta z_i\end{bmatrix} = \begin{bmatrix}x_{\ell,i} - x_v \\ y_{\ell,i} - y_v \\ z_{\ell,i} - z_v\end{bmatrix}. \tag{3}$$

This relative position depends on the vehicle orientation represented by roll ϕ_v, pitch θ_v, and yaw ψ_v. The corresponding body-frame relative position is obtained as

$$\begin{bmatrix}\Delta x_i \\ \Delta y_i \\ \Delta z_i\end{bmatrix} = \mathcal{R}(\phi_v, \theta_v, \psi_v) \begin{bmatrix}\delta x_i \\ \delta y_i \\ \delta z_i\end{bmatrix} \tag{4}$$

where $\mathcal{R}(\phi_v, \theta_v, \psi_v)$ denotes the rotation matrix parameterized by the vehicle orientation angles.

A complete representation of an unmanned underwater vehicle (UUV) pose in 3D space requires a 6-DOF state vector that includes both 3-axis position and orientation. In this study, however, we focus on examining how SSS slant-range and azimuth measurements influence the update of both the vehicle and landmark states in a landmark-based SLAM formulation. For this purpose, we first consider a full state vector $\mathbf{x}_k = [\mathbf{x}_v^\top \mathbf{x}_{\ell,i}^\top]^\top$ that includes a 6-DOF vehicle's pose $\mathbf{x}_v = [x_v\ y_v\ z_v\ \phi_v\ \theta_v\ \psi_v]^\top$ and a single landmark state $\mathbf{x}_{\ell,i} = [x_{\ell,i}\ y_{\ell,i}\ z_{\ell,i}]^\top$. Under the side-looking geometry of SSS, where $\Delta x_i \approx 0$, and under typical seabed-mapping conditions where the vehicle maintains small roll and pitch angles, i.e., $\phi_v \approx 0$ and $\theta_v \approx 0$, the measurement Jacobian can be approximated as

$$\mathrm{H}_i = \frac{\partial \mathbf{h}(\mathbf{x}_v,\ \mathbf{x}_{\ell,i})}{\partial \mathbf{x}_k} = \begin{bmatrix}\frac{\partial h_1(\mathbf{x}_v,\ \mathbf{x}_{\ell,i})}{\partial \mathbf{x}_k}^\top & \frac{\partial h_2(\mathbf{x}_v,\ \mathbf{x}_{\ell,i})}{\partial \mathbf{x}_k}^\top\end{bmatrix}$$
$$\approx \begin{bmatrix}\frac{-\delta x_i}{\gamma_i} & \frac{-\delta y_i}{\gamma_i} & \frac{-\delta z_i}{\gamma_i} & 0 & 0 & 0 & \frac{\delta x_i}{\gamma_i} & \frac{\delta y_i}{\gamma_i} & \frac{\delta z_i}{\gamma_i} \\ \frac{\delta y_i}{\Delta y_i^2} & \frac{-\delta x_i}{\Delta y_i^2} & 0 & 0 & \frac{\delta z_i}{\Delta y_i} & -1 & \frac{-\delta y_i}{\Delta y_i^2} & \frac{\delta x_i}{\Delta y_i^2} & 0\end{bmatrix} \tag{5}$$

where

$$\gamma_i = \sqrt{\delta x_i^2 + \delta y_i^2 + \delta z_i^2}\,. \tag{6}$$

The Jacobian H_i characterizes the sensitivity of the slant-range and azimuth measurements to the vehicle and landmark states. The zero entries corresponding to roll indicate that the SSS measurements provide no direct update for the roll state. In contrast, the pitch-related term in the azimuth Jacobian is proportional to the landmark's vertical relative position. This implies that pitch estimation is coupled with the estimated landmark elevation.

In conventional 3D landmark-based SLAM with range-bearing observations, the coupling between vehicle orientation and landmark position can provide meaningful geometric constraints. However, in SSS SLAM, landmark elevation is only weakly constrained by the sensing geometry of SSS measurements. Consequently, fluctuations in the estimated landmark elevation can propagate into the pitch-state update, potentially increasing estimation errors in a full 6-DOF formulation. To alleviate this issue, this study adopts a reduced 4-DOF vehicle pose representation consisting of 3D position and yaw while excluding roll and pitch from the vehicle state. This approximation is motivated by the operating characteristics of survey-class UUVs during steady-state seabed mapping missions, where roll and pitch angles typically remain small in the absence of aggressive maneuvers. Fig. 2 illustrates the geometric relationship between the vehicle and landmark states under the reduced 4-DOF representation, where the azimuth measurement is mainly associated with the horizontal relative geometry, while the slant-range measurement reflects the full 3D separation. The system dynamics are modeled as a nonlinear stochastic process, expressed as

$$\dot{\mathbf{x}}_v \begin{bmatrix}\dot{x}_v \\ \dot{y}_v \\ z_v \\ \dot{\psi}_v\end{bmatrix} = \begin{bmatrix}v_x \cos\psi_v - v_y \sin\psi_v \\ v_x \sin\psi_v + v_y \cos\psi_v \\ v_z \\ \omega_\psi\end{bmatrix} + \mathbf{w} \tag{7}$$

where $v_x, v_y,$ and v_z denote, the linear velocities along the x-, y-, and z- axis repectively, and ω_ψ indicates the yaw rate. These quantities form the control input vector $u = [v_x\ v_y\ v_z\ \omega_\psi]^\top$. The linear velocities can be measured using a Doppler velocity log (DVL), while the yaw rate is obtained from an inertial measurement unit (IMU). The process noise vector $\mathbf{w}$ is assumed to follow a zero-mean Gaussian distribution.

3. Simulation Study

3.1 Simulation Setup and Scenario

To evaluate the proposed formulation in SSS SLAM, simulation experiments are conducted using Stonefish [7], a physics-based underwater simulation environment that supports multiple sensing modalities, including SSS. The simulated UUV is equipped with an IMU, a DVL, and an SSS. The IMU and DVL operate at 50 Hz, while the SSS provides ping measurements at 10 Hz with a maximum sensing range of 100 m. The survey area covers a 300 m × 300 m region, where the seabed terrain exhibits height variations of approximately 3 m, which are negligible relative to the overall spatial scale. As illustrated in Fig. 3, a set of fixed objects is placed at predefined locations in the global frame, slightly protruding from an otherwise homogeneous seabed. These objects generate distinguishable acoustic backscatter responses and are treated as landmarks for SLAM. The simulated UUV follows three predefined lawnmower survey trajectories designed to repeatedly observe the same landmarks from different viewpoints. Examples of the sensing configuration and the resulting SSS imagery are shown in Fig. 4. In the simulated survey trajectories, the vehicle roll and pitch remained within approximately $-0.16°$ to $0.02°$ and $-0.29°$ to $0.33°$, respectively, consistent with the small-angle approximation ($\phi_v \approx 0$ and $\theta_v \approx 0$).

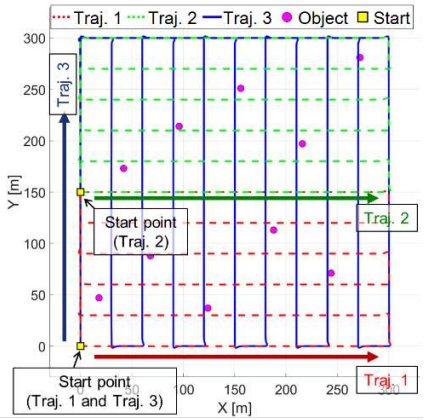

Fig. 3 Simulation scenario showing the placement of fixed landmarks and the three predefined lawnmower survey trajectories used for evaluation.

For performance evaluation, the proposed formulation is compared with a conventional 6-DOF state representation under identical simulation conditions. Both formulations are implemented within the same EKF-based SLAM framework and use the same measurements, data association results, and the same process and measurement noise settings for the common state components, ensuring that any performance difference can be attributed solely to the state representation. To investigate how landmark elevation uncertainty influences state estimation, the azimuth uncertainty σ_α is varied at three levels ($1°$, $2°$, and $4°$, denoted as L, M, H, respectively). This analysis particularly focuses on the azimuth component of the SSS observation, since the approximated azimuth Jacobian in Eq. (5) contains a nonzero pitch-related term associated with the landmark elevation, whereas the approximated slant-range Jacobian contains zero entries for the attitude states under the assumed sensing geometry. This implies that the slant-range measurement does not directly contribute to attitude-state updates, while the azimuth measurement can propagate landmark elevation uncertainty into the pitch-state estimation process. Newly observed landmark states are initialized using the corresponding SSS measurement together with the vehicle's estimated 3D position and nominal altitude, assuming that the landmark is located near the seabed. Since SSS measurements do not directly constrain landmark elevation, a relatively large initial covariance is assigned to the vertical component of the landmark state to reflect this elevation degeneracy and preserve conservative uncertainty estimates in the vertical direction during filtering. Note that this landmark elevation uncertainty is associated with the landmark initialization and is distinct from the azimuth measurement uncertainty σ_α varied in the simulation study. Estimation accuracy is evaluated using the ATE (absolute trajectory error) of both the vehicle and landmark states. Specifically, the evaluation separately considers the horizontal vehicle position (x_v, y_v), vehicle depth (i.e., vertical position) z_v , horizontal landmark position (x_ℓ, y_ℓ), and landmark elevation z_ℓ. All metrics are computed over the three survey trajectories to assess the accuracy of each formulation under different observation geometries.

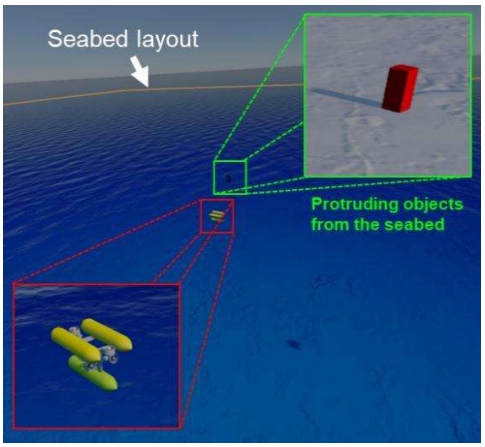

(a)

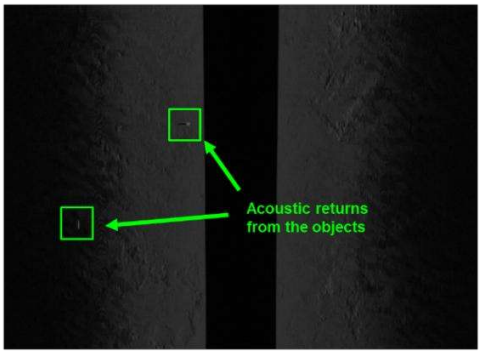

(b)

Fig. 4 Examples from `Traj. 1`. (a) Snapshot of the simulated survey environment showing objects protruding from an otherwise homogeneous seabed. (b) Corresponding SSS image generated from ping measurements, where the protruding objects produce distinguishable acoustic backscatter responses appearing as localized intensity regions.

3.2 Results

Fig. 5 shows the qualitative horizontal trajectory estimation results for the three simulated survey trajectories. Both the conventional 6-DOF and proposed 4-DOF formulations successfully recover the overall lawnmower trajectory patterns under different azimuth uncertainty settings. Quantitative results in Table 1 further show that the horizontal localization performance of the two formulations remains comparable in terms of both the vehicle

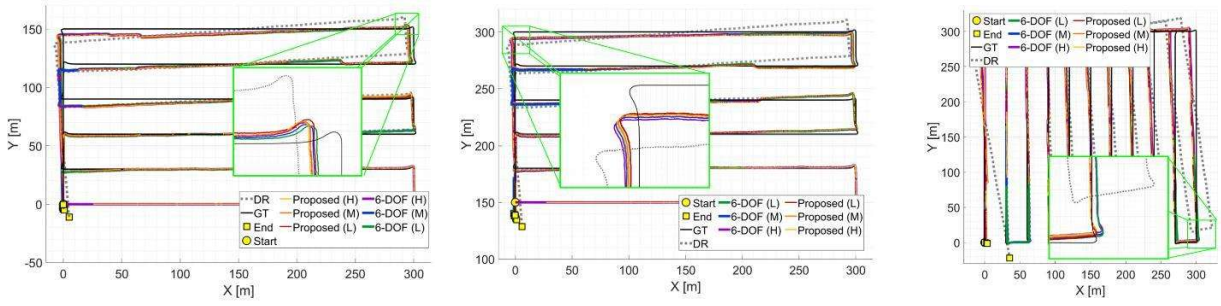

`Traj. 1` `Traj. 2` `Traj. 3`

Fig. 5 Qualitative comparison of horizontal trajectory estimation results across three simulated survey trajectories. Both the conventional 6-DOF and proposed 4-DOF formulations successfully recover the overall lawnmower trajectory patterns under different azimuth uncertainty settings, yielding comparable horizontal localization performance despite the different state representations and observation models..

horizontal position (x_v, y_v) and landmark horizontal position (x_ℓ, y_ℓ). Although certain trajectories and uncertainty settings show slightly lower horizontal errors for either formulation, the overall difference remains limited. This behavior can be attributed to the different observation models used in the two formulations, where the conventional 6-DOF formulation directly utilizes the full 3D geometry of the slant-range and azimuth observation model, while the proposed formulation adopts a reduced state representation based on the dominant sensitivity components of the sensing geometry.

In contrast, the two formulations exhibit substantially different behavior in the vertical states. As summarized in Table 1, the conventional 6-DOF formulation consistently produces significantly larger errors in both the vehicle depth z_v and landmark elevation z_ℓ compared with the proposed formulation across all trajectories.

This degradation mechanism is further illustrated in Fig. 6, which shows the estimated pitch trajectories of the DR and conventional 6-DOF formulation. Note that the proposed 4-DOF formulation is omitted because pitch is not included in its state to be estimated. As the azimuth uncertainty decreases, the azimuth measurement update is assigned higher confidence, leading to larger pitch fluctuations in the conventional 6-DOF formulation due to the elevation-dependent sensitivity of the measurement Jacobian discussed in Section 2. Fig.7 illustrates how these pitch fluctuations affect the vehicle depth estimation. In the conventional 6-DOF formulation, the vehicle depth estimates exhibit progressively larger drift and unstable behavior under lower azimuth uncertainty settings, despite the higher confidence assigned to the measurements. This behavior indicates that the underlying elevation degeneracy remains structurally unresolved in the conventional formulation, and that

Table 1 Estimation performance comparison across three survey trajectories under different vehicle state representations and azimuth uncertainty settings. The metrics report the ATE of the vehicle horizontal position $(\boldsymbol{x_v, y_v})$, vehicle depth $\boldsymbol{z_v}$, landmark horizontal position $(\boldsymbol{x_\ell, y_\ell})$, and landmark elevation $\boldsymbol{z_\ell}$. L, M, and H denote low, medium, and high azimuth uncertainty settings corresponding to $\boldsymbol{\sigma_\alpha = 1}$°, **2**°, and **4**°, respectively. Note that minor numerical differences appearing beyond the second decimal place are considered negligible.

Method	Traj. 1				Traj. 2				Traj. 3			
	ATE [m]				ATE [m]				ATE [m]			
	(x_v, y_v)	z_v	(x_ℓ, y_ℓ)	z_ℓ	(x_v, y_v)	z_v	(x_ℓ, y_ℓ)	z_ℓ	(x_v, y_v)	z_v	(x_ℓ, y_ℓ)	z_ℓ
DR	6.06	1.77	-	-	5.99	1.79	-	-	15.74	3.28	-	-
6-DOF (L)	3.32	4.47	2.59	4.62	3.24	5.01	1.85	3.09	4.18	10.28	3.27	7.30
6-DOF (M)	3.61	3.86	3.34	4.05	3.36	3.74	2.03	2.65	4.36	10.13	3.32	7.38
6-DOF (H)	3.80	3.68	3.94	3.87	3.47	3.52	2.11	2.49	4.63	8.31	3.41	6.18
Proposed (L)	3.90	0.73	2.56	1.96	3.16	0.73	1.80	1.41	4.61	1.08	2.92	1.04
Proposed (M)	3.97	0.73	3.53	1.91	3.21	0.73	1.97	1.45	4.90	1.08	2.94	1.03
Proposed (H)	4.06	0.73	4.06	1.98	3.25	0.73	2.05	1.50	5.10	1.08	2.98	1.05

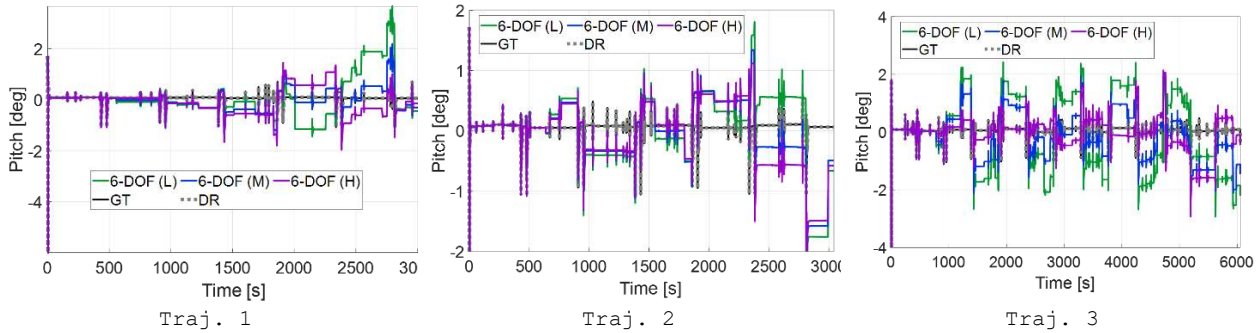

Fig. 6 Pitch estimation results of the DR and conventional 6-DOF formulation across three simulated survey trajectories under different azimuth uncertainty settings. Note that the proposed 4-DOF formulation is omitted because pitch is not included in its estimation state.

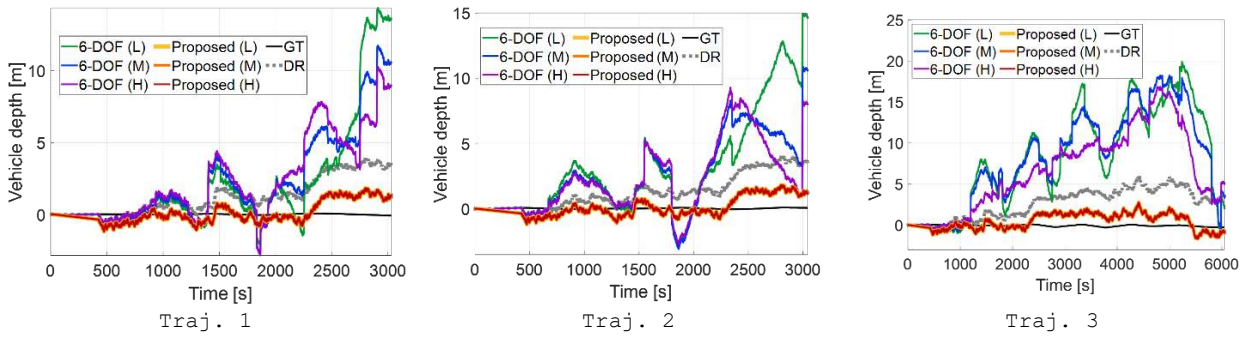

Fig. 7 Time histories of the vehicle depth across three simulated survey trajectories. In the conventional 6-DOF formulation, fluctuations in the estimated landmark elevation propagate into the pitch-state update, inducing unstable coupling between the vehicle depth and pitch states and ultimately increasing estimation errors. By contrast, the proposed 4-DOF formulation maintains stable depth estimation behavior across different azimuth uncertainty settings.

assigning excessive confidence to the azimuth measurement update amplifies the resulting estimation errors. In contrast, the proposed 4-DOF formulation maintains nearly invariant z_v-ATE values across different azimuth uncertainty settings because roll and pitch are excluded from the estimation state.

The same trend is also observed in the reconstructed landmark map. As shown in Table 1, the conventional 6-DOF formulation produces substantially larger landmark elevation errors (i.e., in z_ℓ) than the proposed formulation across all trajectories and uncertainty settings. This is further visualized in Fig. 8, which compares the landmark elevation ATE for `Traj. 3`. In the conventional 6-DOF formulation, landmarks detected later in the mission exhibit progressively larger vertical errors due to the accumulated drift in the vehicle vertical-state estimation. By contrast, the proposed formulation maintains consistently low landmark elevation errors across all landmarks and azimuth uncertainty settings, demonstrating significantly more stable vertical-state estimation behavior under elevation degeneracy.

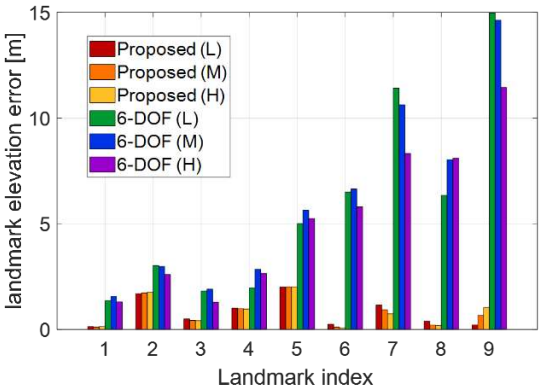

Fig. 8 Comparison of landmark elevation ATE for `Traj. 3` under different azimuth uncertainty settings. The proposed formulation maintains uniformly low landmark elevation errors across all landmarks and uncertainty settings, whereas the conventional 6-DOF formulation exhibits progressively larger errors for landmarks observed later in the mission, reflecting the accumulated growth of vertical-state estimation drift.

4. Conclusion

This paper investigated the effect of landmark elevation uncertainty on state estimation in landmark-based SSS SLAM under elevation degeneracy. Through Jacobian analysis of the slant-range and azimuth observation model, the relationship between the native sensing geometry of SSS measurements and the resulting state-estimation behavior was examined. In particular, the analysis showed that uncertainty in landmark elevation can propagate into the vehicle pitch-state update in conventional full 6-DOF

formulations, potentially degrading the accuracy of vertical-state estimation. Based on this analysis, a reduced 4-DOF vehicle state representation excluding roll and pitch was considered according to the state sensitivities imposed by the sensing geometry. The effectiveness and performance of landmark-based SSS SLAM with the proposed state representation was demonstrated through comparative physics-based underwater simulation experiments against a conventional 6-DOF formulation under different measurement uncertainty conditions.

References

[1] S. Reed, I. T. Ruiz, C. Capus, and Y. Petillot, “The fusion of large scale classified side-scan sonar image mosaics,” *IEEE Trans. Image Process.*, vol. 15, no. 7, 2049-2060, 2006.

[2] P. Blondel, *The Handbook of Sidescan Sonar.* Springer, 2009.

[3] M. F. Fallon, M. Kaess, H. Johannsson, and J. J. Leonard, “Efficient AUV navigation fusing acoustic ranging and side-scan sonar,” in *Proc. IEEE Int. Conf. Robot. Autom.*, 2011, pp. 2398-2405.

[4] J. Zhang, Y. Xie, L. Ling, and J. Folkesson, “A fully-automatic side-scan sonar simultaneous localization and mapping framework,” *IET Radar, Sonar & Navig.*, vol. 18, no. 5, pp. 674-683, 2024.

[5] J. Im and S. Hong, “Side-scan sonar slam using ping-level landmark detection in feature-poor seabed environments,” *IEEE Robotics and Automation Letters*, 2026.

[6] E. Davenport, K. Nguyen, J. Jang, C. Ma, S. Fish, L. Lenain, and F. Meyer, “A landmark-aided navigation approach using side-scan sonar,” *IEEE J. Ocean. Eng.*, 2025.

[7] M. Grimaldi, P. Cieślak, E. Ochoa, V. Bharti, H. Rajani, I. Carlucho, M. Koskinopoulou, Y. R. Petillot, and N. Gracias, “Stonefish: Supporting machine learning research in marine robotics,” in *Proc. IEEE Int. Conf. Robot. Autom*, 2025, pp. 1-7.

한국해양로봇기술연구회
2026 추계학술대회

B-P6

BB2 세일 후류 압력장 기반 AUV 상대 위치 추정 모델 개발

Development of a Model for AUV's Relative Position Estimation from the BB2 Sail-Wake Pressure Field

손영주 · 남보우 · 변성훈

서울대학교 / 선박해양플랜트연구소

본문 125쪽 학술세션 B

서울대학교 조선해양공학과
내항조종연구실 Seakeeping & Manoeuvring Lab.

BB2 세일 후류 압력장 기반 AUV 상대 위치 추정 모델 개발

Development of a Model for AUV's Relative Position Estimation from the BB2 Sail-Wake Pressure Field

Young Ju Son [1], Bo Woo Nam[1,†], Byun Sung Hoon[2]
[1] Department of Naval Architecture & Ocean Engineering, Seoul National University
[2] Korea Research Institute of Ships & Ocean engineering (KRISO)
2026.11.13 (Fri.)

This research was supported by Korea Institute for Advancement of Technology(KIAT) grant funded by the Korea Government(MOTIR) (RS-2025-02263945, HRD Program for Industrial Innovation).

Introduction

서울대학교 조선해양공학과
내항조종연구실 Seakeeping & Manoeuvring Lab.

➢ Lateral Line System of Fish

❖ What is the Lateral Line System (LLS) of fish?

- The fish lateral line system (LLS) is a specialized sensory network of mechanoreceptors, called neuromasts, that detects water movements, vibrations, and pressure gradients.
- The LLS enables fish to perceive their environment in dark or murky water and hunt or avoid predators.

❖ Working principle of LLS and application

- Local flow disturbance around the fish produces pressure differences and water displacement near the body surface. These disturbances deform the neuromast structure and are converted into neural signals.
- Inspired by this mechanism, an Artificial Lateral Line System (ALLS) can be constructed using arrays of pressure sensors on the hull surface of autonomous underwater vehicles (AUVs) or robotic fish to detect the motion state.

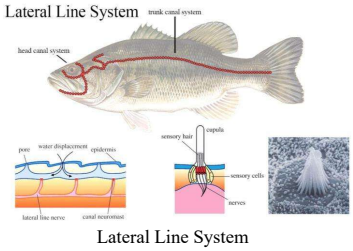

Lateral Line System

Low-vision : Mexican cavefish

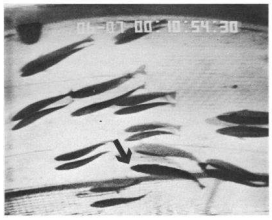
Blind Fish Experiment[1]

[1] Pitcher, T. J., Partridge, B. L., & Wardle, C. S. (1976). A blind fish can school. *Science, 194*(4268), 963–965. https://doi.org/10.1126/science.982056

Problem Statement

➢ AUV Following at a Fixed Offset in a Submarine's Sail Wake

❖ AUV returning after mission completion

- The submarine stays underway at low speed while the AUV approaches.
- We assume the AUV matches the submarine's speed and maintains a fixed offset in the sail wake.

❖ Position estimation with limited sensing

- During recovery, the AUV must estimate its position relative to the submarine.
- Sonar use and other underwater sensing options are constrained

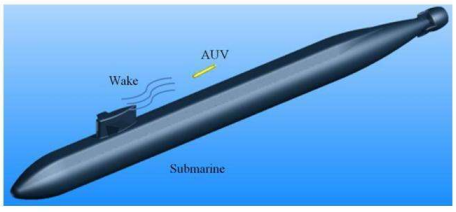

Fig. 1. An AUV moving in the wake of a submarine.

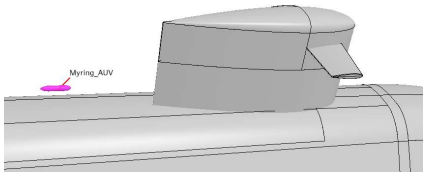

[2] Mai et al. (2024), Establishment of empirical formulae for hydrodynamic derivatives of submarine considering design parameters. International Journal of Naval Architecture and Ocean Engineering, (https://doi.org/10.1016/j.ijnaoe.2023.100537)

Problem Statement

➢ **Target Model** : REMUS 100 AUV (w/o control fins)

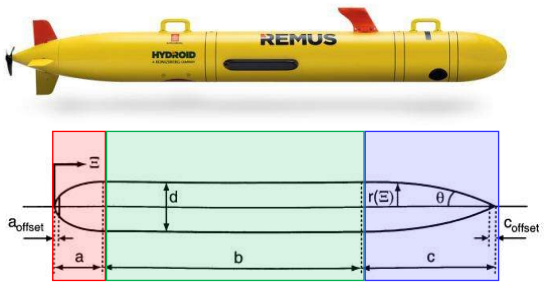

Nose **Mid Body** **Tail**

✓ **Myring hull profile equation**

$$r_{nose} = \frac{1}{2}d\left[1-\left(\frac{x+a_{offset}-a}{a}\right)^2\right]^{\frac{1}{n}}$$

$$r_{body} = \frac{1}{2}d$$

$$r_{tail} = \frac{1}{2}d - \left[\frac{3d}{2c^2} - \frac{tan\theta}{c}\right](x-l)^2 + \left[\frac{d}{c^3} - \frac{tan\theta}{c^2}\right](x-l_f)^3$$

Sensor Location on AUV Surface (17 probes)

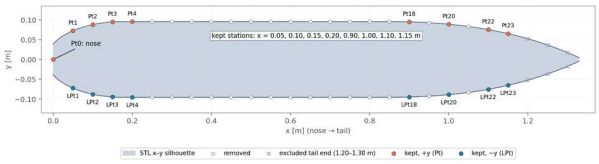

Geometric property of Hull

Properties	value
Nose Length [m]	0.191
Mid Body Length [m]	0.654
Tail Length [m]	0.541
Nose Offset [m]	0.0165
Tail Offset [m]	0.0368
Vehicle Length [m]	1.33
Vehicle Diameter [m]	0.191

Problem Statement

➢ **Target Model** : BB2 Submarine's Sail (w/o horizontal sailplanes)

- ❖ The BB2 sail uses a NACA 0022 profile[3].
- ❖ The model omits the horizontal sailplanes.
- ❖ The hull's bottom-wall effect is neglected.
- ❖ The sail chord is c = 10.99 m.

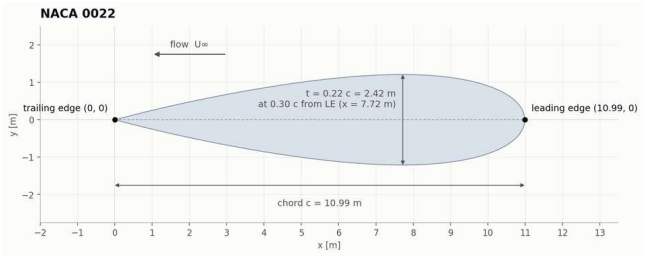

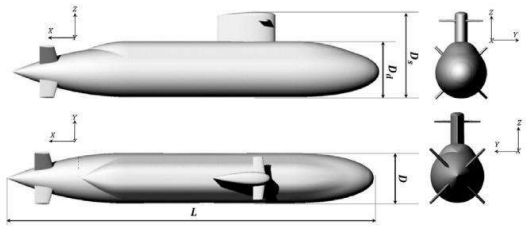

Fig. 1. Geometry of the BB2 submarine.

Properties	value
Length [m]	70.2 [m^3]
Diameter [m]	9.6 [m^3]
Depth to deck [m]	10.6 [m^3]
Depth to sail top [m]	16.2 [m^3]
Displacement volume [m]	4440 [m^3]

[3] Carrica, P. M., Kim, Y., & Martin, J. E. (2019). Near-surface self propulsion of a generic submarine in calm water and waves. *Ocean Engineering, 183*, 87–105. https://doi.org/10.1016/j.oceaneng.2019.04.082

5

Numerical Methods

➢ **Data Generation** : Potential Panel Method & CFD

❖ Potential Flow Analysis

- ✓ **Flow assumptions** : Incompressible, inviscid, irrotational
- ✓ **Hull condition** : No penetration
- ✓ **Role** : Rapid dense data sampling where viscous-wake is limited

$$u = \nabla\phi$$

$$\nabla^2\phi = 0 \qquad (n\cdot\nabla\varphi)\big|_S = 0$$

$$\varphi(x) = U_\infty \cdot x + \sum_{j=1}^{N}\sigma_j G_j(x) \qquad G_j(x) = \int_{S_j}\left(\frac{1}{4\pi|x-\xi|}\right)dS_\xi$$

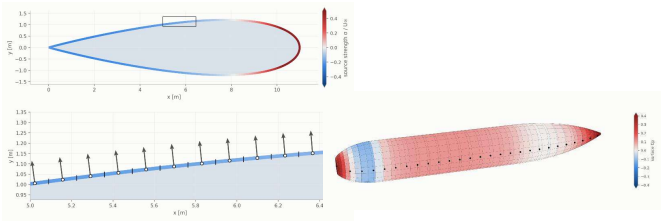

❖ CFD method

- ✓ **Flow assumptions** : Incompressible, viscous RANS
- ✓ **Turbulence model**: $k-\omega$ SST
- ✓ **Role** : Higher-fidelity data sampling including viscosity

$$\nabla\cdot\bar{u} = 0$$

$$\rho\left(\frac{\partial\bar{u}}{\partial t} + (\bar{u}\cdot\nabla)\bar{u}\right) = -\nabla\bar{p} + \nabla\cdot\left[2(\mu+\mu_t)\bar{S} - \frac{2\rho k}{3}I\right]$$

$$\bar{S} = \frac{\nabla\bar{u} + \nabla\bar{u}^T}{2} \qquad \mu_t = \mu_t(k,\omega;SST)$$

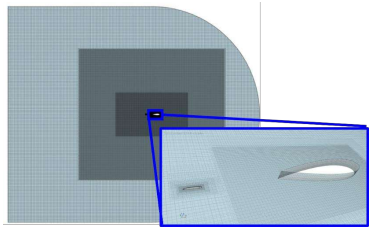

6

➢ Data Generation : Potential Panel Method & CFD

❖ Potential Flow Analysis

- ✓ **Flow assumptions** : Incompressible, inviscid, irrotational
- ✓ **Hull condition** : No penetration
- ✓ **Role** : Rapid dense data sampling where viscous-wake is limited

$$u = \nabla\phi$$

$$\nabla^2\phi = 0 \qquad (n \cdot \nabla\varphi)\big|_S = 0$$

$$\varphi(x) = U_\infty \cdot x + \sum^{N} \sigma_i G_i(x) \qquad C_i(x) - \int \left(\frac{1}{\quad} \right) dS_\xi$$

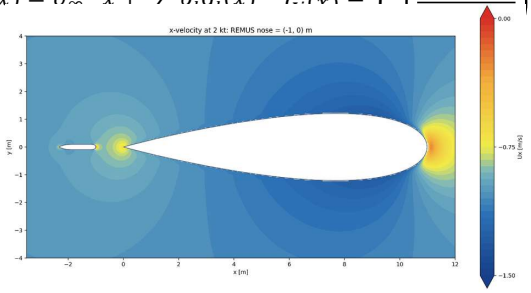

❖ CFD method

- ✓ **Flow assumptions** : Incompressible, viscous RANS
- ✓ **Turbulence model**: $k-\omega$ SST
- ✓ **Role** : Higher-fidelity data sampling including viscosity

$$\nabla \cdot \bar{u} = 0$$

$$\rho\left(\frac{\partial \bar{u}}{\partial t} + (\bar{u} \cdot \nabla)\bar{u}\right) = -\nabla\bar{p} + \nabla \cdot [2(\mu + \mu_t)\bar{S} - \frac{2\rho k}{3} I]$$

$$\bar{S} \quad \nabla\bar{u} + \nabla\bar{u}^T \qquad \mu_t = \mu_t(k, \omega; SST)$$

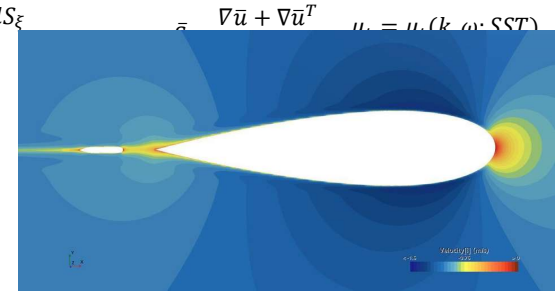

➢ Data Generation : Potential Panel Method & CFD

❖ Potential Flow Analysis

- ✓ **Position sampling** : $\Delta s = 0.1\ [m]$
- ✓ **Velocity sampling** : $U_\infty = [1,2,3,4][kts]$

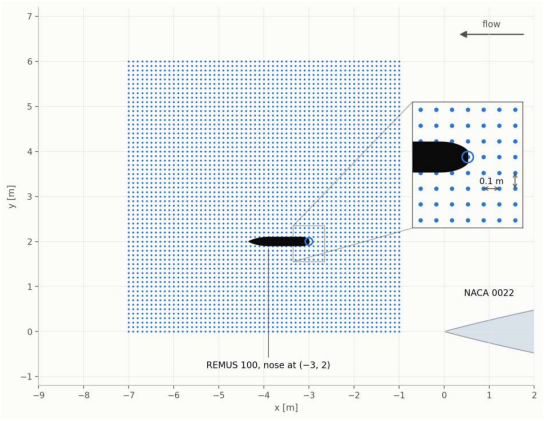

❖ CFD method

- ✓ **Position sampling** : $\Delta s = 2\ [m]$
- ✓ **Velocity sampling** : $U_\infty = [2,3][kts]$

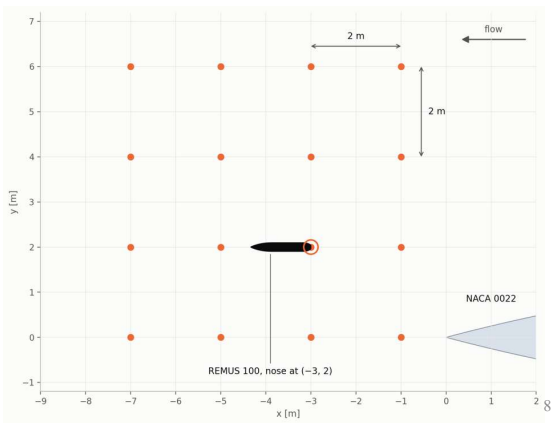

➢ Estimation Models

❖Notation & Pressure Model

$$\mathbf{p} = [\,p_1,\ \ldots,\ p_n\,]^\top$$

$$q(U_\infty) = \frac{1}{2}\,\rho\,U_\infty^2$$

$$p_k^{\mathrm{pot}}(\mathbf{x}, U_\infty) = C_{p,k}^{\mathrm{pot}}(\mathbf{x})\,q(U_\infty)$$

$$r_k = p_k^{\mathrm{CFD}} - p_k^{\mathrm{pot}}(\mathbf{x}, U_\infty)$$

$$\mathbf{z}(\mathbf{p}) = (\mathbf{p} - \boldsymbol{\mu}) \oslash \boldsymbol{\sigma}$$

$$\mathbf{x} = (x,\ y), \qquad \boldsymbol{\theta} = [\,x,\ y,\ U_\infty\,]^\top$$

$$\mathcal{D} = \left\{\left(\mathbf{z}(\mathbf{p}_i^{\mathrm{pot}}),\ \boldsymbol{\theta}_i\right)\right\}_{i=1}^{M}, \qquad \mathbf{p}_i^{\mathrm{pot}} = \mathbf{C}_p^{\mathrm{pot}}(\mathbf{x}_i)\,q(U_{\infty,i}), \quad U_{\infty,i} \in \{2,\ 3\}\ \mathrm{kt}$$

$$\mathbf{z}_* = \mathbf{z}(\mathbf{p}_*), \qquad \mathbf{p}_* \in \{\mathbf{p}^{\mathrm{CFD}},\ \mathbf{p}^{\mathrm{corr}}\}$$

❖Weighted KNN

$$\hat{\boldsymbol{\theta}}(\mathbf{z}_*) = \frac{\sum_{i \in \mathcal{N}_5(\mathbf{z}_*)} w_i\,\boldsymbol{\theta}_i}{\sum_{i \in \mathcal{N}_5(\mathbf{z}_*)} w_i}$$

$$w_i = \frac{1}{\|\mathbf{z}_* - \mathbf{z}_i\|^2}$$

$$[\,\hat{x},\ \hat{y},\ \hat{U}_\infty\,]^\top = \hat{\boldsymbol{\theta}}(\mathbf{z}_*)$$

❖Gaussian Process regression (ARD kernel)

$$k(\mathbf{z}, \mathbf{z}') = \exp\!\Big(-\frac{1}{2}\sum_{j=1}^{n}\frac{(z_j - z_j')^2}{\ell_j^2}\Big)$$

$$\hat{\theta}_m(\mathbf{z}_*) = \bar{\theta}_m + \sigma_{\theta,m}\,\mathbf{k}_*^\top(\mathbf{K} + \sigma_\varepsilon^2\mathbf{I})^{-1}\,\tilde{\boldsymbol{\theta}}_m, \qquad m \in \{x,\ y,\ U_\infty\}$$

$$\tilde{\theta}_{i,m} = \frac{\theta_{i,m} - \bar{\theta}_m}{\sigma_{\theta,m}}, \qquad K_{ij} = k(\mathbf{z}_i, \mathbf{z}_j), \quad (\mathbf{k}_*)_i = k(\mathbf{z}_*, \mathbf{z}_i)$$

$$\ell_j = \min\Big\{20,\ \max\Big\{0.25,\ \frac{1}{\max_m|\mathrm{corr}(z_j, \theta_m)|}\Big\}\Big\}$$

$$[\,\hat{x},\ \hat{y},\ \hat{U}_\infty\,]^\top = [\,\hat{\theta}_x,\ \hat{\theta}_y,\ \hat{\theta}_{U_\infty}\,]^\top$$

❖Probabilistic inverse estimation

$$\hat{\mathbf{p}}(\mathbf{x}, U_\infty) = \mathbf{C}_p^{\mathrm{pot}}(\mathbf{x})\,q(U_\infty)$$

$$L(\mathbf{x}, U_\infty) = \frac{1}{2}\sum_{k=1}^{n}\frac{\left(p_k^{\mathrm{corr}} - \hat{p}_k(\mathbf{x}, U_\infty)\right)^2}{q(U_\infty)^2\,s_k^2} + \sum_{k=1}^{n}\ln\!\big(q(U_\infty)\,s_k\big)$$

$$(\hat{x},\ \hat{y},\ \hat{U}_\infty) = \underset{(x,y)\in\mathcal{G},\ U_\infty\in\mathcal{U}}{\arg\min}\ L\big((x, y), U_\infty\big)$$

$$\mathcal{G} = \{-7,\ -6.9,\ \ldots,\ -1\} \times \{0,\ 0.1,\ \ldots,\ 6\}\ \mathrm{m}, \qquad \mathcal{U} = \{1.5,\ 1.55,\ \ldots,\ 3.5\}\ \mathrm{kt}$$

$$s_k^2 = \frac{1}{N}\sum_{i=1}^{N}\left(\frac{\hat{r}_k^{(-j_i)}(\mathbf{p}_i) - r_{ik}}{q(U_{\infty,i})}\right)^2$$

➢ Correction Model

❖Ridge

$$\hat{\mathbf{r}}(\mathbf{p}) = \mathbf{m} + \mathbf{W}^\top\mathbf{z}(\mathbf{p})$$

$$\mathbf{W} = (\mathbf{Z}^\top\mathbf{Z} + \alpha\mathbf{I})^{-1}\,\mathbf{Z}^\top(\mathbf{R} - \mathbf{1}\mathbf{m}^\top)$$

$$\mathbf{p}^{\mathrm{corr}} = \mathbf{p}^{\mathrm{CFD}} - \hat{\mathbf{r}}(\mathbf{p}^{\mathrm{CFD}})$$

❖Gaussian Process

$$\mathbf{s}(\mathbf{p}) = \mathbf{V}_m^\top\mathbf{z}(\mathbf{p})$$

$$\kappa(\mathbf{s}, \mathbf{s}') = \exp\!\Big(-\frac{\|\mathbf{s} - \mathbf{s}'\|^2}{2\ell^2}\Big)$$

$$\hat{\mathbf{r}}(\mathbf{p}) = \mathbf{m} + (\mathbf{R} - \mathbf{1}\mathbf{m}^\top)^\top(\mathbf{K} + \sigma^2\mathbf{I})^{-1}\,\boldsymbol{\kappa}_*$$

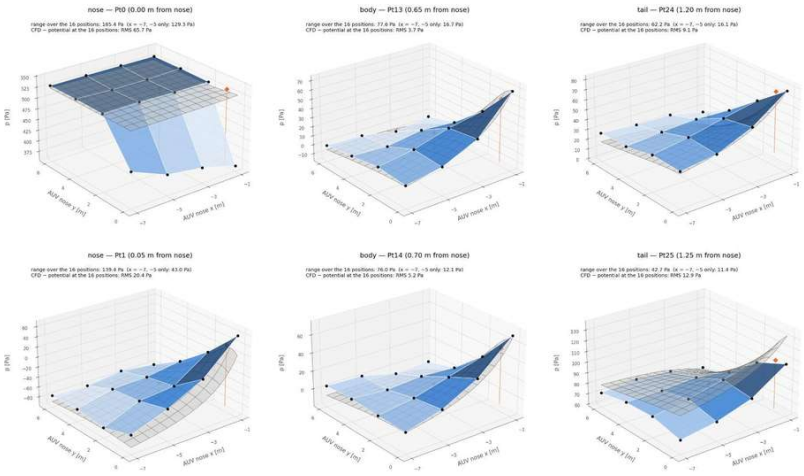

서울대학교 조선해양공학과
내항조종연구실 Seakeeping & Manoeuvring Lab.

Results

11

서울대학교 조선해양공학과
내항조종연구실 Seakeeping & Manoeuvring Lab.

➢ Position Estimation Results

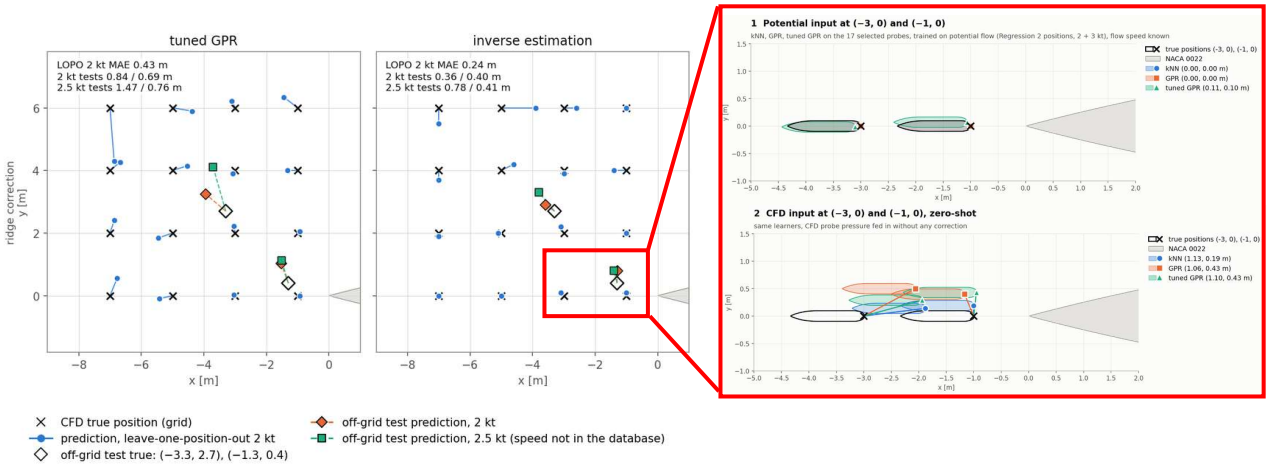

12

Results

➢ Position Estimation Results

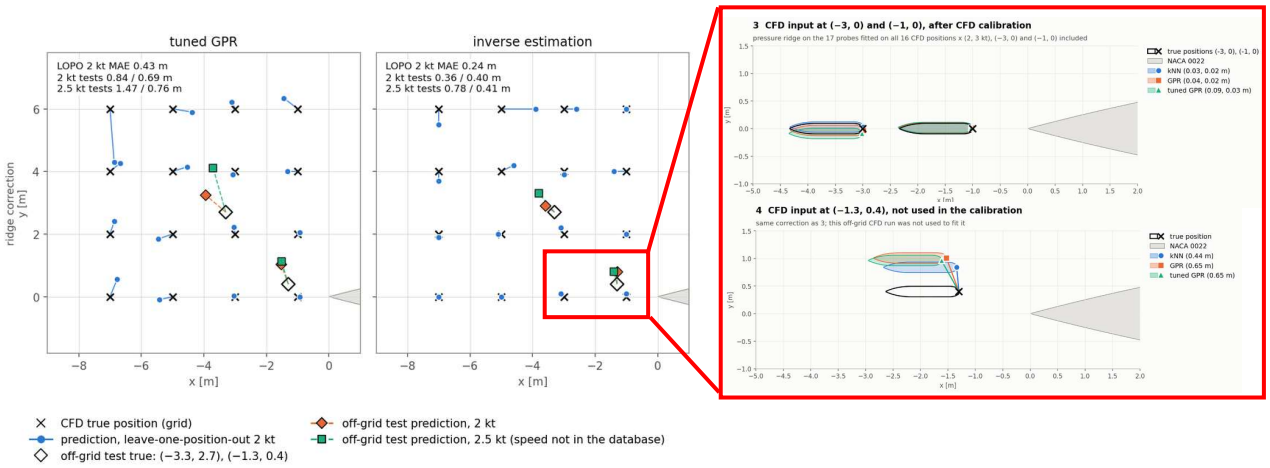

13

한국해양로봇기술연구회
2026 추계학술대회

B-P7

외란 관측기 기반 모델 예측 제어를 이용한 무인수상정의 강인 궤적 추종

DOB-MPC for Robust Trajectory Tracking of Autonomous Surface Vehicles

박기용 · 김진환

한국과학기술원 (KAIST)

DOB-MPC for Robust Trajectory Tracking of Autonomous Surface Vehicles

Mobile Robotics & Intelligence Lab.

Kiyong Park[1] and Jinwhan Kim[1*]

[1]KAIST

ENGINEERING FOR MANKIND KAIST

Introduction

Challenges of ASV control

< Underactuation >

< Environmental disturbance >

diesel engine

servo actuator

- - - throttle command —— thrust

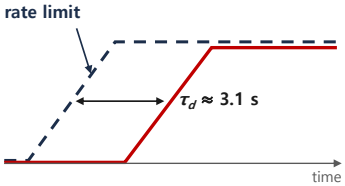

< Engine dynamics >

Background

Model Predictive Control (MPC)

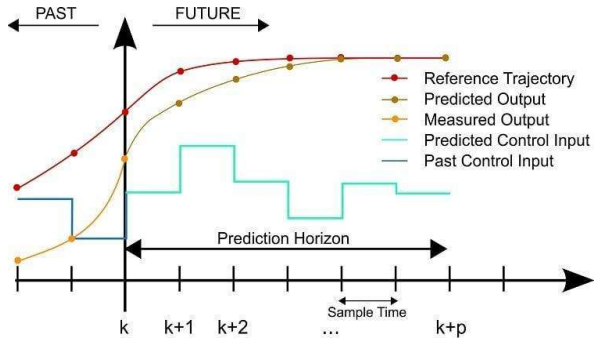

< Receding-horizon prediction >

$$\min_{\mathbf{x}(\cdot),\mathbf{u}(\cdot)} \sum_{i=0}^{N-1} \ell\left(\mathbf{x}_i, \mathbf{r}_i, \mathbf{u}_i\right) + \ell_T\left(\mathbf{x}_N, \mathbf{r}_N\right),$$
$$\text{s.t.} \quad \mathbf{x}_0 - \mathbf{x}_{\text{init}} = 0,$$
$$\mathbf{x}_{i+1} - f_d\left(\mathbf{x}_i, \mathbf{u}_i\right) = 0, \quad i = 0, \ldots, N-1,$$
$$g\left(\mathbf{u}_i\right) \leq 0, \quad i = 0, \ldots, N-1,$$

< MPC optimal control problem >

- Predict future states over a horizon
- Optimize inputs subject to constraints
- Naturally handles input constraints & underactuation

Background

Prior work — ASV control with MPC

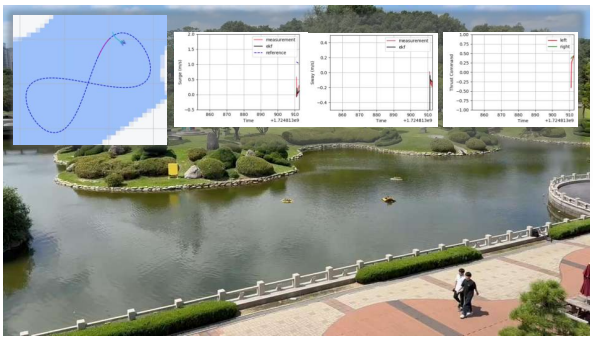

< Duck-pond trajectory tracking >

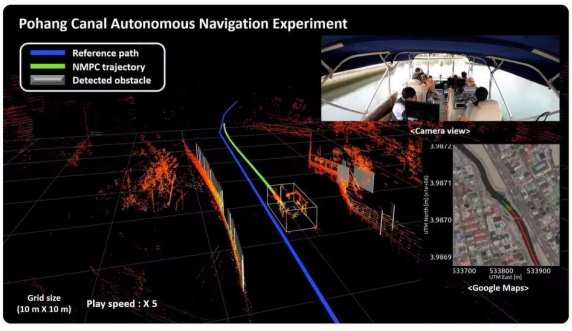

< Canal navigation >

MPC works well in calm environment → tracking degrades under disturbance & model uncertainty

DOB-MPC

Control structure

Objective

- Make the error between system states and reference trajectory 0

$$J(t) = \sum_{i=0}^{N-1} (\| \eta_{t+i} - \mathrm{r}_{t+i} \|_Q^2 + \| \Delta \mathrm{u}_{t+i} \|_P^2) + \| \eta_{t+N} - \mathrm{r}_{t+N} \|_R^2$$

"state" "global path" "Input efforts"

$$\eta = [x, y, \psi, u, v, r]^T$$

Subject to

$$\mathrm{x}_{k+1} = f(\mathrm{x}_k, \mathrm{u}_k) + \mathrm{w}_k$$

"Estimated disturbance"

$$\mathrm{F}_{min} \le \mathrm{F} \le \mathrm{F}_{max} \qquad \dot{\mathrm{F}}_{min} \le \dot{\mathrm{F}} \le \mathrm{F}_{max}$$

$$\delta_{min} \le \delta \le \delta_{max} \qquad \dot{\delta}_{min} \le \dot{\delta} \le \dot{\delta}_{max}$$

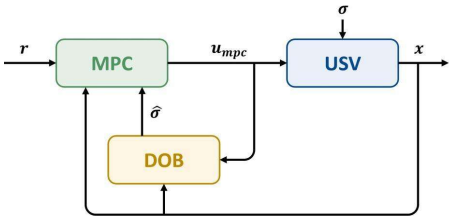

< Control diagram >

DOB-MPC

Control structure

Objective

- Make the error between system states and reference trajectory 0

$$J(t) = \sum_{i=0}^{N-1} (\| \eta_{t+i} - \mathrm{r}_{t+i} \|_Q^2 + \| \Delta \mathrm{u}_{t+i} \|_P^2) + \| \eta_{t+N} - \mathrm{r}_{t+N} \|_R^2$$

"state" "global path" "Input efforts"

$$\eta = [x, y, \psi, u, v, r]^T$$

Subject to

$$\mathrm{x}_{k+1} = f(\mathrm{x}_k, \mathrm{u}_k) + \mathrm{w}_k$$

"Estimated disturbance"

$$\mathrm{F}_{min} \le \mathrm{F} \le \mathrm{F}_{max} \qquad \dot{\mathrm{F}}_{min} \le \dot{\mathrm{F}} \le \mathrm{F}_{max}$$

$$\delta_{min} \le \delta \le \delta_{max} \qquad \dot{\delta}_{min} \le \dot{\delta} \le \dot{\delta}_{max}$$

< AURA ASV >

DOB-MPC

Representative runs (Drone view) (110 m × 55 m)

Nominal MPC

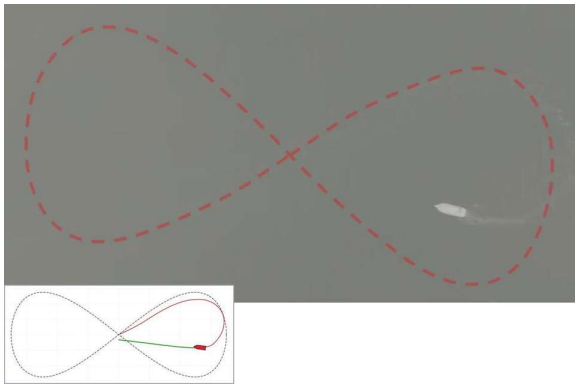

DOB-MPC (proposed)

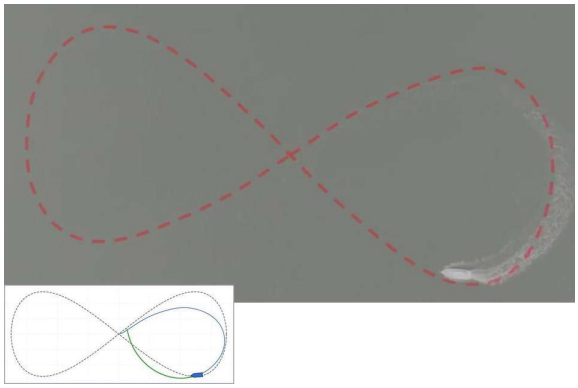

Thank you!

한국해양로봇기술연구회
2026 추계학술대회

B-P8

피드백 기반 인식 정제를 통한 열악한 해상 환경에서의 강인한 카메라-레이다 융합

PRFusion: Feedback-Driven Perception Refinement for Robust Maritime Camera-Radar Fusion

신영하 · 김진환

한국과학기술원 (KAIST)

2026 년도 KMRTS 추계학술대회

피드백 기반 인식 정제를 통한 열악한 해상 환경에서의 강인한 카메라–레이다 융합

PRFusion · Feedback-Driven Perception Refinement for Robust Maritime Camera–Radar Fusion

신영하 , 김진환 *
KAIST
* 교신 저자

PROBLEM

Association failures originate in segmentation

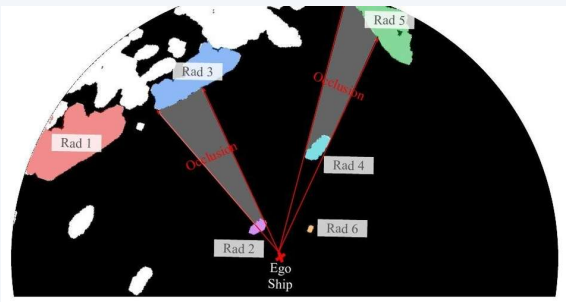

Camera-merge
Adjacent objects under occlusion collapse into one camera mask.

Radar-merge
Objects along the same bearing merge into one radar return.

Unmatched
An object is detected by only one of the two sensors.

KEY IDEA **A failed association is not the final result, but a trigger to re-segment.**

2

PROPOSED METHOD

PRFusion framework overview

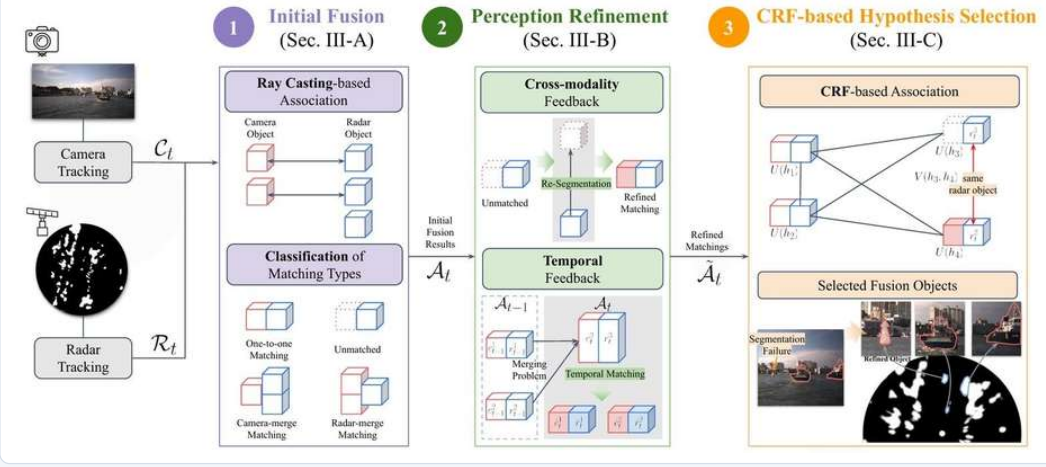

1 Initial fusion
Ray-casting association, classified into four matching types

2 Perception refinement
Re-segmentation via cross-modality and temporal feedback

3 CRF-based selection
Energy minimization selects a globally consistent object set

3

STAGES 2 & 3

Refine with feedback, then select globally

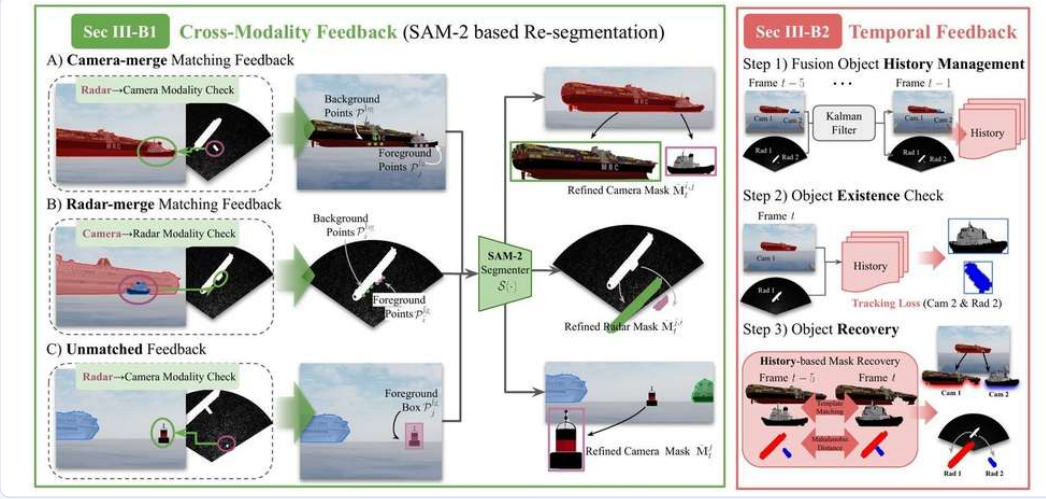

Perception refinement
Cross-modality: other-sensor objects prompt SAM 2 to split or recover masks.
Temporal: Kalman history + template matching restore lost objects.

Object-level CRF
Each fusion hypothesis is a node. Unary and pairwise energies score agreement and conflicts; mean-field + Hungarian picks one hypothesis per object.

4

RESULTS

Best F1 on all four datasets

Method	Amnam	Pohang	MOANA	Sim.	Overall F1	RadIoU	CamIoU
Bearing	76.73	97.40	70.45	84.54	83.97	0.678	0.484
Distance	80.16	97.40	83.44	87.91	87.86	0.735	0.499
D+V	70.55	96.12	77.61	87.33	86.76	0.720	0.568
AnytimeFusion	87.31	95.97	91.00	86.26	86.91	0.723	0.601
PRFusion (ours)	**95.56**	**100.00**	**96.77**	**99.29**	**99.10**	**0.902**	**0.770**

+19.9 %p

Overall recall vs. Distance
78.67 → 98.54%

+11.2 %p

Overall F1 vs. Distance
87.86 → 99.10%

+28.1 %

Camera mask IoU vs. AnytimeFusion
0.601 → 0.770 (relative)

F1 in %. Real-world: Amnam, Pohang Canal, MOANA · Simulation: Gazebo, 30 scenarios · Real-world F1 gain: 2.6–8.3 %p

5

RESULTS · QUALITATIVE

Refinement recovers missed objects

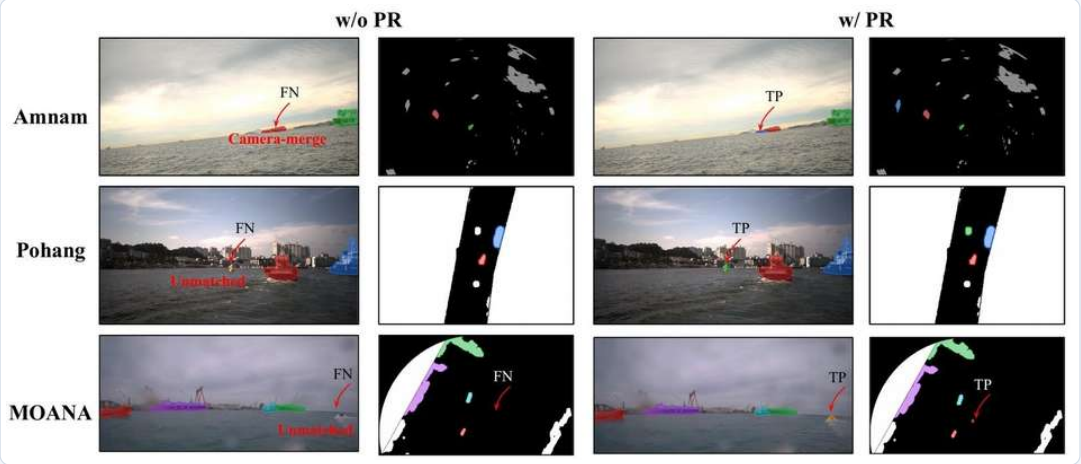

Amnam
Camera-merge split by cross-modality feedback

Pohang Canal
Radar-only buoy recovered in the camera

MOANA
Lost in both sensors; restored by temporal feedback

Simulation (day / night / fog): all three failure types, including radar-merge, are recovered consistently.

6

CONCLUSION

Refine, don’t just match

1

Failure as a trigger

Cross-modal and temporal feedback re-segments merged or missed objects at their source.

2

Global consistency

The object-level CRF keeps both precision and recall where NN or Hungarian lose one.

3

Robust at sea

Best F1 on all four datasets, with higher radar and camera mask quality.

Thank you

Benchmark & annotations: sites.google.com/view/prfusion

yeongha.shin@kaist.ac.kr

MEMO

MEMO

MEMO

MEMO

한국해양로봇기술연구회
Korea Marine Robot Technology Society

2026 추계학술대회

2026. 11. 13 | 부산 BPEX